


# PROBABILIDAD Y ESTADÍSTICA

## CONCEPTOS BÁSICOS NUEVA PROPUESTA Plan 2023 Unidad 1 - 2 - 3



AÑO 2023

Prof. Cdra. Gladys M. Rouadi -

Material adaptado por: Ing. Cecilia Savi - Lic. Roberto Infante



*Probabilidades y Estadística: conceptos básicos. 1º ed.-Córdoba. ROUADI, Gladys Margarita. Eudecor. 2013. ISBN 978-987-1536-38-2. Fecha de catalogación: 12/04/2013*

*Adaptación de los contenidos al plan estudios 2023, Probabilidad y Estadística: conceptos básicos, de la Carrera Ingeniería en Sistemas de Información a cargo de la Ing. Cecilia Savi y el Lic. Roberto Infante. Marzo 2023.*



## **CAPITULO N.º 1:**

### **Identificación, organización, presentación y análisis de Datos Estadísticos**

---

#### **Contenidos**

#### **1-Significado de estadística**

*1-1 Estadística descriptiva.*

*1-2 Estadística inferencial.*

*1-3 Población y muestra.*

#### **2- Datos estadísticos**

*2-1 Variables cuantitativas.*

*2.1.1 Discretas.*

*2.1.2 Continuas.*

*2-2 Variables cualitativas.*

*2-3 Unidad estadística o unidad de análisis.*

*2-4 Unidad de relevamiento.*

*2-5 Escalas de medida.*

*2.5.1 Escala nominal.*

*2.5.2 Escala ordinal.*

#### **3- Etapas del método científico en el análisis de datos**

*3-1 Formulación o definición del problema.*

*3-2 Diseño del experimento.*

*3-3 Recopilación de datos o relevamiento estadísticos.*

*3.3.1. Tipos de fuentes de datos.*

*3.3.2. Datos secundarios y datos primarios.*

*3.3.3. Técnicas de recogida de datos primarios: grupos de interés, teléfono, cuestionarios por correo, de puerta a puerta, abordaje en centros comerciales, registros, observaciones, entrevistas, experimentos. Ventajas y desventajas de las técnicas de recogida de datos.*

*3.3.4. Relevamiento estático y dinámico.*

*3-4 Clasificación, tabulación y descripción de los resultados.*

*3-5 Generalización o inferencia final.*

#### **4- Tablas estadísticas**

*4-1 Tipos de tablas estadísticas.*

*4-2 Partes principales de una tabla estadística.*

*4-3 Construcción de tablas estadísticas.*

#### **5- Formas de agrupar variables cuantitativas**

*5-1 Series simples o datos no agrupados.*

*5-2. Datos agrupados o distribuciones de frecuencias.*

*5.2.1. Distribuciones de frecuencias en lista.*

*5.2.1.1. Frecuencias absolutas.*

*5.2.1.2. Frecuencias relativas.*

*5.2.1.3. Frecuencias acumuladas.*

*5.2.2. Distribuciones de frecuencias en intervalos.*

*5.2.2.1. Frecuencias absolutas.*

*5.2.2.2. Frecuencias relativas.*

*5.2.2.3. Frecuencias acumuladas.*

#### **6. Formas de agrupar variables cualitativas**

*6-1 Distribuciones categóricas o tablas de contingencia.*

#### **7-. Representaciones gráficas**



**7-1 Gráficos lineales.**

*7.1.1. Gráfico de bastones.*

*7.1.2. Gráfico acumulativo de frecuencias.*

**7-2 Gráficos de superficie.**

*7.2.1. Histograma.*

*7.2.2. Polígono de frecuencias.*

*7.2.3. Curva suave.*

*7.2.4. Diagrama escalonado.*

*7.2.5. Ojivas.*

*7.2.6. Curva acumulativa.*

**7-3. Gráficos especiales**

*7.3.1 Variables categóricas.*

*7.3.1.1. Diagrama de barras horizontales.*

*7.3.1.2. Gráfica de barras de componentes de porcentajes.*

*7.3.1.3. Diagrama de pastel o círculo radiado.*



## 1. SIGNIFICADO DE ESTADÍSTICA

La noción de Estadística se derivó originalmente del vocablo *estado*, porque ha sido función tradicional de los gobiernos centrales llevar registros de población, nacimientos, defunciones, etc. Contar y medir estos hechos genera muchas clases de datos.

Diariamente se nos “bombardea” con datos. Las “estadísticas” se nutren de los números generados por los espacios informativos, la publicidad, los sondeos de opinión y los debates públicos.

La persona común concibe la Estadística como columnas de cifras o gráficos. Este concepto se asemeja a la definición tradicional de Estadística: “La compilación, organización, resumen, presentación y análisis de datos numéricos”.

Las organizaciones modernas tienen miles de conceptos de datos en sus archivos de documentos y en las computadoras. Cientos o miles de valores de datos se agregan a ese total todos los días. Algunos de los datos nuevos se generan normalmente durante el registro de las actividades; otros son el resultado de estudios en investigaciones especiales.

Sin los procedimientos estadísticos, ninguna organización podría entender la gigantesca cantidad de datos generados por su actividad.

Es importante la recopilación y el estudio de datos; por eso los conocimientos de Estadística son valiosos para una gran variedad de actividades.

Las oficinas de Estadística del gobierno publican información numérica sobre la inflación y el desempleo.

Quienes se dedican a realizar previsiones, los economistas, los asesores financieros y los que determinan la política de una empresa y del gobierno estudian estos datos para tomar decisiones basadas en la información obtenida.

Las organizaciones, cualquiera sea su naturaleza, generan una gran cantidad de datos que les permite definir indicadores para medir su gestión.

Con el fin de ofrecer un tratamiento adecuado a sus pacientes, los profesionales de la salud deben entender las estadísticas de las investigaciones que se publican en revistas médicas. En política, los funcionarios que ocupan cargos directivos se basan en las estadísticas de la opinión pública para medir su imagen y definir las exigencias de sus votantes.

Las empresas fundan sus decisiones en estudios de mercado sobre los patrones de compra de los consumidores.

Los granjeros y campesinos registran datos para estudiar nuevas composiciones de alimento o nuevas variedades de siembra.

La Estadística se estructuró, como una disciplina científica, en el siglo pasado, pero ya se conocía y se aplicaba en forma rudimentaria desde la antigüedad.

La configuración actual de la Estadística significa la culminación de un proceso en el que pueden distinguirse antecedentes que se desarrollaron en forma independiente y que luego confluyeron, mediante la obra de Laplace y sus continuadores, hacia un solo cuerpo de doctrina y una metodología.

Los estudios de probabilidad de mediados del siglo XVIII, motivados en gran medida por los juegos de azar, dieron lugar al tratamiento matemático de los errores de medición y a la teoría en la que hoy se sustenta la Estadística.

Iniciados por la escuela de estadísticos ingleses y luego continuados en otros países, se desarrollaron entre los últimos años del siglo pasado y lo que va del presente, los sectores modernos de la Estadística dando como resultado que esta disciplina llegara a constituirse en uno de los métodos más potentes de investigación tanto en las Ciencias Sociales como en las Físico-Naturales.



Se llega así al estado actual. En todas las naciones científicamente desarrolladas, se trabaja intensamente en investigaciones teóricas y de aplicación.

Todos los capítulos de la Estadística se renuevan y amplían diariamente, al mismo tiempo que se perfeccionan sus procedimientos de aplicación en diversos campos del conocimiento.

La Estadística trata de la selección, análisis y uso de datos con el fin de resolver problemas. A toda persona, tanto en su ejercicio profesional como en su actividad diaria en contacto con diferentes medios, se le ofrece información en forma de datos.

Consecuentemente, algunos conocimientos de Estadística serán de utilidad a la población en general, pero en particular, el conocimiento estadístico será de vital importancia para Ingenieros, en todas las especialidades, Científicos y Administradores, debido a que de manera rutinaria manejan y analizan datos. Es por ello la necesidad de aportar las herramientas básicas de la Estadística para ejercer sus profesiones.

Además, la Probabilidad, que estudia las variaciones al azar en diversos sistemas, se presentará necesariamente para el estudio de la Estadística Inferencial y para dar sustento a otras aplicaciones de la probabilidad y la Estadística en Ingeniería y Ciencias.

La Estadística moderna ofrece una gran variedad de herramientas analíticas en la toma de decisiones bajo la incertidumbre, es decir cuando no es factible medir con exactitud, relacionándose de esta forma con la Teoría de Probabilidades.

La Estadística propicia un criterio para lograr mejoras, debido a que sus técnicas se pueden usar para describir y comprender la variabilidad, y ésta existe en todo tipo de procesos.

Las aplicaciones de la Probabilidad y la Estadística son numerosas en todos los casos de la ciencia aplicada en donde existan variaciones y donde las conclusiones acerca de un sistema están basadas en datos observados.

En realidad, todo el trabajo experimental tiene esta naturaleza y la variabilidad es el común denominador de estos problemas.

Por Estadística y Probabilidad se entienden los métodos para describir y modelar la variabilidad además de permitir la toma de decisiones cuando la variabilidad está presente.

La Estadística Inferencial, más reciente que la Descriptiva, aporta a la Ingeniería moderna la mayoría de sus aplicaciones, incluyendo la Inferencia y la Toma de Decisiones.

Pocas áreas han experimentado tan poderosamente el impacto del desarrollo reciente de la Estadística como la Ingeniería y Administración Industrial, a través de sus contribuciones a los problemas de la producción, al uso eficaz de los materiales y fuerza de trabajo, a la investigación básica y al desarrollo de nuevos productos, convirtiéndose en una herramienta vital para los ingenieros, ya que les permite comprender fenómenos sujetos a variación y predecirlos o controlarlos eficazmente.

Otro aspecto que no podemos dejar de considerar es el referido al mejoramiento de la calidad. El mundo se encuentra en la actualidad en medio de una revolución internacional en cuanto a mejora de la calidad.

Las enseñanzas e ideas de W. Edwards Deming fueron de gran utilidad para el rejuvenecimiento de Japón. El propio Deming ha señalado (en relación con la industria estadounidense) que, si se desea sobrevivir, se debe asumir un incesante compromiso con el mejoramiento de la calidad. Del diseño a la producción, los procesos tienen que ser permanentemente mejorados. Con sus conocimientos técnicos y dotados de habilidades



estadísticas básicas para la recolección y representación gráfica de datos, ingenieros y científicos pueden participar decisivamente en el cumplimiento de esta meta.

Entonces, la función principal de la Estadística es elaborar principios y métodos que nos ayuden a tomar decisiones frente a la incertidumbre, por lo cual decimos que es el ***MÉTODO PARA LA TOMA DE DECISIONES FRENTE A LA INCERTIDUMBRE***.

Se emplea hoy en toda clase de estudios científicos, en toda situación en la cual deba sacarse una conclusión, tomarse una decisión o realizar una predicción, basada en datos empíricos.

Diremos entonces que *Estadística* es un método que, a través de la recolección en masa y el agrupamiento racional de los hechos, permite reseñar y observar los fenómenos colectivos, obtener relaciones numéricas sensiblemente independientes de las anomalías del azar y poner de manifiesto la regularidad de las variaciones.

La *Estadística* puede dividirse en dos ramas:

### **1.1. Estadística Descriptiva**

Es la que se va a encargar de la recopilación, tratamiento, presentación y análisis de los datos, con el objeto de resumirlos y describirlos para su interpretación.

Utiliza tablas y gráficos para sintetizarlos y parámetros (si se trabaja con la población) o estadísticos (si se trabaja con una muestra) para describirlos.

### **1.2. Estadística Inferencial**

Es la técnica que permite sacar conclusiones u obtener generalizaciones acerca de un parámetro de población a partir del correspondiente estadígrafo, calculado con la información provista por una muestra de esa población.

Es la que se va a encargar del proceso de utilización de los datos muestrales para la generalización sobre el parámetro, o los parámetros de la población de la cual forman parte los datos analizados.

### **1.3. Población y Muestra**

A fin de entender cómo se pueden aplicar los métodos estadísticos, se debe distinguir entre *Población* y *Muestra*.

Una *Población, Colectivo o Universo*, es la totalidad de individuos u objetos de interés, acerca de los cuales se desea información, según el objetivo del estudio.

*Una Población Es El Conjunto Completo De Individuos O Elementos De Interés*

*Una Censo Es La Medición De Todos Los Elementos De Una Población De Interés*



Los elementos de la población en sentido estadístico pueden:

1. Ser de existencia Real: automóvil, persona, casa
2. Ser de existencia Abstracta: Temperatura, voto
3. Coincidir con unidades naturales, como obreros, turistas, neumáticos.
4. Ser creados artificialmente con el propósito de la investigación. Así, cuando se analiza un campo sembrado de trigo, es común dividir el campo en cuadrados o rectángulos; en este caso los elementos de la población están dados por los cuadrados o rectángulos y no por cada planta de trigo.
5. Ser una entidad simple. Un hombre, una cosa
6. Ser una entidad compleja. Una familia, una escuela

Con respecto al tamaño de las poblaciones, diremos que pueden ser:

|                         |                                                                                                            |
|-------------------------|------------------------------------------------------------------------------------------------------------|
| <b><i>Infinitas</i></b> | <i>Comprende Un Número Infinitamente Grande De Elementos (Unidades De Análisis, Unidades Elementales).</i> |
| <b><i>Finitas</i></b>   | <i>Sólo Contiene Un Número Finito De Elementos (Unidades De Análisis, Unidades Elementales).</i>           |

Una *Muestra* es la parte de la población que se ha seleccionado para el análisis.

En la práctica es a menudo costoso, largo y en algunos casos físicamente imposible realizar un censo, en cuyo caso se recurre al muestreo como medio más práctico para realizar el estudio. Se está tratando de tomar una decisión acerca de la población, en base a los datos provenientes de la muestra, razón por la cual es necesario contar con elementos representativos del total que sólo se obtendrán si la muestra en sí, es representativa.

*Una Muestra Es Un Subconjunto  
Seleccionado De La Población*

*Un Muestreo Es La Medición De Todos Los  
Elementos De Una Muestra*

Elegir una muestra representativa es un problema importante en las investigaciones estadísticas. A menos que sea sencillo y rentable medir cada elemento de la población a través de un censo, el investigador se encuentra con el problema de cómo seleccionar una muestra representativa entre toda la población objeto de análisis. Una muestra representativa puede proporcionar una visión útil de la naturaleza de la población que se estudia, mientras que una muestra no representativa puede sugerir conclusiones totalmente incorrectas sobre esa población. La Estadística ofrece los llamados Procedimientos de Muestreo que nos indican las formas para seleccionar muestras.

Además de las observaciones anteriores, hay otros conceptos que debemos considerar para analizar información: *Dato Estadístico, Unidad de Análisis, Unidad de Relevamiento, Escalas De Medición, y Clasificación.*





## 2- **DATOS ESTADÍSTICOS**

No toda información es considerada dato estadístico. Para cumplir con este requisito debe tratarse de un conjunto o conjuntos de valores factibles de ser comparados, analizados e interpretados.

Así, el peso de una sola persona no permite comparación, en cambio, el peso de 1.000 personas sí lo permite.

Antes de poder procesar un conjunto de datos para la toma de decisiones, se deben encontrar los datos apropiados, que por lo general se obtienen contando, midiendo o clasificando individuos u objetos.

Estas medidas se llaman variables porque pueden tomar muchos valores diferentes. En contraposición, una constante tiene un valor fijo.

Entonces, una variable es toda característica o dimensión de un individuo u objeto susceptible de adoptar distintos valores o nombres (categorías).

Por ejemplo, una variable como el peso, toma valores (65 kgs., 70 kgs., etc.), mientras que otra como el sexo toma nombres, categorías (Masculino, Femenino).

En base a ello, las variables pueden clasificarse en:

### ***2.1. Variables Cuantitativas***

Son aquellas que arrojan valores numéricos, es decir, surgen de un proceso de conteo o medición.

Pueden ser, a su vez:

#### ***2.1.1. Discretas***

Son respuestas numéricas que surgen de un proceso de conteo, es decir, la unidad no es divisible, sólo puede ser definida en términos enteros o ciertos valores fraccionarios especificados.

El número de alumnos en un aula es un ejemplo, ya que la respuesta toma uno de un número finito de valores que se pueden contar. El aula tiene 1, 2, 3, ..., 40, etc. alumnos.

#### ***2.1.2. Continuas***

Son respuestas numéricas que surgen de un proceso de medición. Pueden asumir cualquier valor numérico (cualquier número real) dentro de una amplitud específica. En tal serie, valores sucesivos pueden diferir en cantidades infinitesimales.

Una serie continua es aquella en la que las unidades pueden dividirse en fracciones de cualquier tamaño, por pequeñas que sean, de modo que haya un flujo continuo de valores con graduaciones infinitamente pequeñas.



La estatura de una persona es un ejemplo de variable continua, ya que la respuesta puede tomar cualquier valor dentro de un intervalo, según sea la precisión del instrumento de medición.

El tiempo que utiliza un alumno para concluir sus estudios, es también una variable continua.


Es interesante observar que mientras el peso, la longitud, la altura, el tiempo y la temperatura son variables continuas, sus mediciones son discretas, porque el instrumento de medición tiene algún límite de precisión.

No obstante, para cálculos y análisis estadísticos las consideramos por su naturaleza, como continuas.

## 2.2. Variables Cualitativas

También llamadas variables categóricas, son aquellas que arrojan respuestas que se describen por palabras. Los individuos u objetos son poseedores o no poseedores de cierta cualidad o propiedad. Sólo pueden clasificarse, no medirse. A menudo pueden ser expresadas numéricamente fijando valores que representen a cada una de las categorías consideradas. Así, si por ejemplo trabajamos con el sexo, asignamos el valor 1 al elemento que posee la característica de nuestro interés y 0 al que no la posee. En otros casos podremos establecer otra escala de medición según sea conveniente y representativa para nuestro objetivo.

### Resumen





### **2.3. Unidad Estadística o Unidad De Análisis**

Constituida por cada uno de los elementos individuales, que en forma conjunta constituyen la población sobre la que se quiere realizar un relevamiento. En otras palabras, dentro de un relevamiento estadístico es el elemento del conjunto o universo poseedor de la característica o variable, sobre la cual queremos hacer el análisis.

Si queremos estudiar cuál es la práctica religiosa de un grupo de personas, estamos haciendo referencia a una variable: la práctica religiosa, y a unas unidades de análisis, es decir, cada una de las personas.

Cuando por ejemplo, queremos estudiar cómo cambia la práctica religiosa con el paso del tiempo, tendremos que medir a los mismos (o diferentes) individuos en distintos momentos del tiempo.

Si estudiamos la inflación en cada una de las provincias de nuestro país, la inflación será la variable y las provincias la unidad estadística o de análisis.

En los ejemplos dados, las dos variables y las dos unidades difieren entre sí, no sólo por su contenido sino también por sus propiedades técnicas, lo que implicará la aplicación de técnicas diferentes.

Así, si 100 individuos son católicos y otros 100 no lo son, podremos decir que hay un 50% en cada categoría, pero no podremos calcular una religión promedio.

En cambio, si una provincia tiene una tasa de inflación de 10 puntos y otra la tiene de 15 puntos, podremos decir que una provincia tiene más inflación que otra, con una diferencia de 5 puntos y que la inflación promedio es de 12,5 puntos  $(10 + 15) / 2$ .

De esto se desprende, que las variables tienen un nivel de medida, que hace que en algunos casos puedan calcularse promedios y en otros no.

El número de características que puede tener un individuo u objeto es infinito, por lo tanto, el número de variables es infinito, y los puntos de vista desde los que pueden ser observados son también infinitos.

### **2.4. Unidad De Relevamiento**

Están formadas por unidades estadísticas. Es el lugar donde se encuentran las unidades estadísticas o de análisis. Así, en un Censo Ganadero, la unidad de relevamiento la constituye la estancia o cabaña y en un Censo de Población, la familia.

### **2.5. Escalas De Medida**

Para preparar datos para el análisis se debe estar familiarizado con escalas de medida: Para las variables de tipo cualitativa se identifican las escalas *Nominal*, *Ordinal*. Los que menos información contienen son los datos medidos en una escala nominal.

#### **2.5.1 Escala Nominal**

Los datos medidos en una escala nominal representan el nivel más bajo de la jerarquía y consisten en categorías en las que se registra el número de observaciones.



Estas categorías no tienen un orden lógico ni una relación específica. Se dice que las categorías son *Mutualmente Excluyentes* puesto que un individuo, objeto o medida queda incluida sólo en una de ellas. El resultado que se obtiene incluye datos cualitativos casi siempre medidos por recuento.

Ejemplo: Número de empresas según tipo de actividad

| <i>Tipo De Actividad</i>                       | <i>Número De Empresas</i> |
|------------------------------------------------|---------------------------|
| <i>Servicios</i>                               | <i>250</i>                |
| <i>Construcción</i>                            | <i>120</i>                |
| <i>Financiamiento, Seguros Y Bienes Raíces</i> | <i>90</i>                 |
| <i>Venta Minorista</i>                         | <i>85</i>                 |
| <i>Venta Mayorista</i>                         | <i>65</i>                 |
| <i>No Clasificados</i>                         | <i>50</i>                 |
| <i>Producción</i>                              | <i>45</i>                 |
| <i>Transporte Y Servicios Públicos</i>         | <i>40</i>                 |
| <i>Agricultura Y Minería</i>                   | <i>35</i>                 |
| <i>Total</i>                                   | <i>780</i>                |

Los colores son otro ejemplo de datos nominales, donde las categorías podrían ordenarse según orden de preferencia. Además, si un color es rojo, no puede ser amarillo o verde. Al no importar el orden en que se presenten las categorías y ser mutuamente excluyentes, los datos se clasifican como nominales.

Otros ejemplos son: Sexo (Hombre-Mujer); Categorización por Provincias (Córdoba, Buenos Aires, Santa Fe, Mendoza); Categorización de medios de transporte (colectivo, tren, avión); Categorización de Carreras Universitarias (Medicina, Abogacía, Administración, Psicología)

*Una Escala Nominal Consiste En Categorías Mutuamente Excluyentes Que No Implican Ningún Orden Lógico.*

### 2.5.2 Escala Ordinal

Los datos medidos en una escala *Ordinal* consisten en categorías cualitativas en las que hay una progresión en orden.

Ejemplo: Calificaciones expuestas por concepto a un grupo de alumnos.

| <i>Calificación</i> | <i>Número De Alumnos</i> |
|---------------------|--------------------------|
| <i>Excelente</i>    | <i>4</i>                 |
| <i>Muy Bueno</i>    | <i>15</i>                |
| <i>Bueno</i>        | <i>25</i>                |
| <i>Suficiente</i>   | <i>10</i>                |
| <i>Insuficiente</i> | <i>2</i>                 |
| <i>Total</i>        | <i>56</i>                |

La calificación de “Excelente” es superior a la de “Muy Bueno” y así sucesivamente, es decir, existe un orden en las categorías.



Los datos medidos en una escala ordinal contienen más información que los medidos en una escala nominal, debido a que las categorías están ordenadas: los valores en una categoría son mayores o menores que los valores en otras categorías, es decir, que las categorías pueden ser ascendentes o descendentes.

Otro ejemplo que mencionaremos es el de los niveles de escolaridad, pues cada categoría implica un nivel educativo más alto que el anterior. Entonces, podemos categorizar, de la siguiente manera:

| Sin Estudios | Primario   | Secundario | Terciario  | Universitario |              |            |            |
|--------------|------------|------------|------------|---------------|--------------|------------|------------|
|              |            |            |            | Grado         | Posgrado     |            |            |
|              |            |            |            |               | Especialidad | Maestría   | Doctorado  |
|              | Incompleto | Incompleto | Incompleto | Incompleto    | Incompleta   | Incompleta | Incompleto |
|              | Completo   | Completo   | Completo   | Completo      | Completa     | Completa   | Completo   |


Registrando para un grupo sometido al estudio, el número de individuos, en cada categoría, se obtendrán datos ordinales.

*Una Escala Ordinal Se Compone De Distintas Categorías En Las Que Hay Implícito Un Orden.*

Tanto las variables nominales como ordinales tienen categorías, que han de ser:

- Colectivamente Exhaustivas*, es decir, cuando permiten clasificar a todas las unidades que estamos investigando. Para ello, se debe incluir una categoría adicional “otros”, en la que se clasifican todos los individuos que no caben en una categoría específica.
- Mutualmente Excluyentes*, es decir, cuando están definidas sin ambigüedad, pudiendo sólo ser incluidas en una sola categoría.
- Basadas en un *Único Principio Clasificador*. Si consideramos “católicos”, “protestantes” ..., “asiste regularmente a misa”, las dos primeras son variable religión, mientras que la última se relaciona con la práctica religiosa.

### *Tipos De Datos y Escalas De Medida*





### **3- ETAPAS DEL MÉTODO CIENTÍFICO EN EL ANÁLISIS DE DATOS**

En Estadística, como método para analizar la información, es necesario cumplimentar con una serie de etapas a los fines de lograr resultados congruentes, homogéneos y fáciles de interpretar.

Para ello, consideraremos cinco etapas:

Formulación o Definición del Problema

Diseño del Experimento

Recopilación de Datos Estadísticos

Clasificación, Tabulación y Descripción de los resultados

Generalización o Inferencia Final

Desarrollaremos a continuación cada una de ellas.

#### ***3.1. Formulación o Definición Del Problema***

En Estadística, la primera tarea es conocer exactamente que ha de ser investigado, es decir formular el problema o pregunta lo más clara y precisamente posible. Sólo entonces, puede decidir el investigador cuáles datos son relevantes al problema. Si se fracasa en esta formulación los datos compilados pueden ser irrelevantes o inadecuados.

La calidad de las conclusiones estadísticas depende de la corrección y precisión de los datos, que a su vez dependen de la exactitud en la formulación del problema. Las técnicas estadísticas, por muy refinadas y precisas que sean, no pueden ayudar a alcanzar decisiones si son aplicadas a datos inapropiados.

#### ***3.2. Diseño Del Experimento***

Una vez formulado con precisión el problema que requiere análisis estadístico, el investigador debe decidir si estudiar a todos los individuos u objetos involucrados, o sólo a una parte de ellos, extraída del total. En la práctica es a menudo costoso, lento o aún físicamente imposible efectuar un censo, debiendo por ello recurrir al muestreo. A partir de una muestra, inferimos sobre la población de la cual ha sido extraída, es, por este motivo, que la muestra debe ser representativa de la población, es decir, debe representar adecuadamente a la población. Supone preguntas como éstas: ¿Qué tipos de datos deben recogerse?, ¿Cómo deben ser compilados?, ¿De qué tamaño debe ser la muestra? Estas preguntas corresponden al Diseño Experimental o Diseño de Muestras.

#### ***3.3. Recopilación de Datos Estadísticos o Relevamiento Estadístico***

Se refiere a los métodos usados para obtener información pertinente de los individuos u objetos involucrados en el estudio, sea éste un censo ó un muestreo.

En otras palabras, es aquella etapa que tiene por objeto la extracción y recolección de datos a partir de las fuentes que lo suministran.



### 3.3.1. Tipos de Fuentes de Datos

### 3.3.2. Datos Secundarios y Datos Primarios

Los datos necesarios para elaborar un análisis estadístico o bien se encuentran disponibles o deben recogerse. Los datos que se encuentran disponibles se denominan **datos secundarios** y los datos que deben recogerse se llaman **datos primarios**.

*Los Datos Primarios Se Recogen Específicamente Para El Análisis Deseado. Los Datos Secundarios Ya Se Han Compilado Y Están Disponibles Para El Análisis Estadístico.*

Existen muchas fuentes de datos secundarios. Las bibliotecas son, quizá, el ejemplo más obvio. Algunas fuentes de datos secundarios incluyen redes de computadoras. Los suscriptores a estos servicios pueden tener acceso a grandes cantidades de datos secundarios por medio del teléfono o su propia computadora. Los gobiernos generan cantidades ingentes de datos cada año. También pueden encontrarse en publicaciones nacionales o internacionales.

La ventaja al usar datos secundarios para una investigación estadística es que ya se dispone de ellos y no es necesario recogerlos para un proyecto específico. Incluso la compra de ellos es, por lo general, menos costosa que recoger datos primarios. La desventaja radica en que no siempre cubren las necesidades específicas del análisis.

### 3.3.3. Técnicas De Recogida De Datos Primarios

Las técnicas que se presentan seguidamente son las más usadas en la práctica para reunir la información necesaria para el análisis y la toma de decisiones. Se requiere experiencia y habilidad para determinar qué técnica o combinación de técnicas se adecuan mejor al estudio específico. La clave para realizar una buena investigación reside, en gran medida, en la pericia a la hora de elegir la técnica adecuada.

#### *Grupos de interés*

Se usan como un método preliminar de recogida de datos. Están integrados por un reducido número de personas que se reúnen para debatir qué datos son importantes en la investigación. Un moderador conduce las sesiones y encauza el debate hacia el área de interés. Las sesiones duran entre una y dos horas y por lo general participan en ellas entre 8 a 12 personas. Como el grupo de interés es pequeño, los resultados se utilizan como guía para la investigación más profunda.

Es importante elegir participantes que reúnan las mismas características que el grupo mayor sometido a estudio.

Por ejemplo, si se desea realizar una encuesta sobre la calidad de las prestaciones ofrecidas por una Obra Social para jubilados, sería apropiado incluir en el grupo de interés sólo participantes de 65 o más años, así como elegir igual número de mujeres que de hombres, considerando diferentes áreas de la región que se quiere estudiar. Se trata entonces de obtener un perfil más o menos representativo en el grupo de interés para que sus comentarios puedan tomarse como indicadores fiables de las opiniones del conjunto de la población estudiada.



Por lo general, es aconsejable tener al menos tres grupos de interés para un tema específico. Cada grupo de interés tiene su propio carácter dependiendo de sus miembros, y es después de dos o tres sesiones cuando surgen temas comunes. Un solo grupo de interés puede ir por un camino equivocado, en especial si algunas personas con opiniones muy firmes dominan la sesión.

#### *Teléfono*

La entrevista por teléfono es otra técnica habitual para recoger opiniones de un grupo.

Las ventajas de este método son: rapidez, bajo costo, es relativamente sencillo y proporciona una tasa de respuesta bastante alta.

Las desventajas son: que sólo pueden hacerse preguntas sencillas, la entrevista debe ser breve y algunas personas consideran que esas llamadas son una invasión a su vida privada y no quieren responder.

#### *Cuestionarios por Correo*

Se usan con frecuencia para recopilar datos cuando se cuenta con una lista o cuando los entrevistados se encuentran dispersos en un área muy grande. En ellos, se pueden incluir preguntas detalladas, ya que los encuestados dispondrán de tiempo para releerlas y pensar la respuesta. Por otro lado, si el cuestionario es demasiado largo, no se molestarán en contestarlo. El mayor problema que plantea es hacer que los destinatarios lo contesten y vuelvan a remitirlo. La tasa de respuesta es casi siempre muy baja y esto puede producir resultados erróneos.

#### *De Puerta a Puerta*

Se utilizan debido a que es relativamente fácil llevarlas a cabo y generan altas tasas de respuesta. Debe tenerse cuidado al seleccionar y adiestrar a los encuestadores para garantizar la comprensión de las preguntas. No debe manejarse un cuestionario muy largo. Con este método es posible cubrir un área geográfica grande y es fácil obtener una buena distribución de los ingresos percibidos por los entrevistados, ya que los ingresos de las personas normalmente se reflejan en el tipo de casas que habitan.

#### *Abordaje en Centros Comerciales*

Se usa con frecuencia cuando los investigadores de mercado están interesados en obtener opiniones de compradores. Los entrevistadores se instalan en áreas de mucho movimiento e invitan a las personas elegidas a contestar algunas preguntas. Se pueden usar ayudas visuales o de otro tipo, como pedir a los entrevistados que prueben un nuevo producto y comenten sobre él, o mostrarles un nuevo envase y pedir su opinión.

#### *Registros*

En ocasiones, los datos se recogen mediante el registro de nuevos productos.

Se pide a los consumidores que rellenen un cuestionario cuando “registran” un producto que acaban de comprar al sellar la garantía. No todos devuelven el cuestionario, pudiendo introducirse un sesgo que puede orientar mal a la empresa que reúne los datos.

#### *Observaciones*

Los esfuerzos en este sentido incluyen el diseño de un experimento en el que se controlan las condiciones con precisión, de manera que se puedan observar y analizar los efectos al introducir cambios. Los experimentos son comunes en el campo de la ciencia, pero suelen utilizarse en algunas ocasiones en los negocios.





### *Entrevistas*

La entrevista personal se usa cuando el entrevistador necesita determinar en forma profunda las opiniones y actitudes. Aunque este enfoque proporciona datos de calidad, el costo y el tiempo necesarios para programar y hacer las entrevistas limita su utilidad.

Todos los métodos anteriores de recogida de datos extraen opiniones o actitudes de las personas. Sin embargo, muchos problemas se refieren a mediciones de objetos, como cinescopios, maderos o ensambles soldados. La medición de objetos evita la interacción y comunicación con la gente, pero debe resolver aspectos como el tamaño de la muestra y otras consideraciones.

El método de reunir datos de poblaciones no humanas a menudo es sencillo y directo. Así, si deseamos estudiar si la longitud de determinados tornillos está dentro de ciertos límites, sólo necesitamos medirlos. En otros problemas, los procedimientos para observar unidades elementales de poblaciones no humanas son muy complicados y técnicos. Así, para descubrir si existen fallas en funciones de aluminio, se requieren rayos X, en este caso la elección del método está más allá de la capacidad del estadístico, por lo tanto, lo hace el especialista.

Los datos sobre poblaciones humanas, según analizamos, pueden ser compilados haciendo observaciones directas ó formulando preguntas (entrevistas personales, cuestionarios enviados por correo, llamadas telefónicas). Luego se hacen registros apropiados de los resultados, que constituyen los datos originales de los que el estadístico prepara sus cuadros y gráficos para el análisis posterior.

Las ventajas y desventajas de los diferentes métodos varían según las circunstancias.

En general, un método es considerado el mejor, en un estudio determinado, si obtiene la información necesaria con la máxima precisión, con los costos más bajos y en el menor tiempo.

En cualquiera de los métodos el primer paso es planear el cuestionario. La mejor forma de asegurar que las preguntas sean formuladas apropiadamente es someterlas a prueba previamente con una muestra pequeña (encuesta piloto) y hacer las mejoras necesarias basándose en las respuestas antes de ser usadas en gran escala.

Deben tenerse presente algunos principios generales de buena técnica de interrogación:

- 1- Las preguntas deben formularse sencilla y claramente.
- 2- pueden formularse preguntas que el interrogado pueda responder correctamente.

A menudo se obtienen resultados erróneos e información incorrecta cuando se formulan preguntas sobre prestigio individual (ingresos, posición social), cuestiones emocionales o inclinaciones o prejuicios personales. Cuando se necesita información sobre estos temas, las preguntas deben ser formuladas para reducir la respuesta emocional y la turbación. También es de utilidad, asegurar al interrogado que la información permanecerá completamente confidencial.

- 3- Las preguntas deben ser formuladas lógicamente y orientadas de modo que faciliten la tabulación de las respuestas.



### *Experimento*

Con frecuencia, la investigación experimental genera conjuntos de datos de interés para la comunidad empresarial. Los experimentos difieren de otras técnicas de recogida de datos en términos del grado de control sobre la situación que se investiga. En un experimento se manipula una variable y se mide su efecto sobre otra, mientras que se controlan todas las demás variables.

### **Resumen**

#### ***Ventajas Y Desventajas De Las Técnicas De Recogida De Datos***

| <b><i>Técnica de Recogida de Datos</i></b>    | <b><i>Ventajas</i></b>                                                                                                                                                                                      | <b><i>Desventajas</i></b>                                                                                                              |
|-----------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------|
| <b><i>Grupo de Interés</i></b>                | <ul style="list-style-type: none"> <li>• Buena técnica preliminar</li> </ul>                                                                                                                                | <ul style="list-style-type: none"> <li>• Muestra pequeña</li> <li>• No se pueden proyectar resultados</li> </ul>                       |
| <b><i>Entrevistas por Teléfono</i></b>        | <ul style="list-style-type: none"> <li>• Rápida.</li> <li>• Poco costosa.</li> <li>• Fácil de llevar a cabo.</li> <li>• Alta tasa de respuesta.</li> <li>• Flexibilidad para el entrevistador.</li> </ul>   | <ul style="list-style-type: none"> <li>• Deben hacerse preguntas sencillas.</li> <li>• La entrevista debe ser breve.</li> </ul>        |
| <b><i>Cuestionarios por Correo</i></b>        | <ul style="list-style-type: none"> <li>• Puede cubrir un área geográfica grande</li> <li>• Poco costosa</li> <li>• Preguntas estandarizadas</li> </ul>                                                      | <ul style="list-style-type: none"> <li>• Tasas bajas de respuesta</li> <li>• Se emplea mucho tiempo</li> </ul>                         |
| <b><i>De puerta a puerta</i></b>              | <ul style="list-style-type: none"> <li>• Puede cubrir un área geográfica grande</li> <li>• Fácil de llevar a cabo</li> <li>• Alta tasa de respuesta</li> </ul>                                              | <ul style="list-style-type: none"> <li>• Se emplea mucho tiempo</li> <li>• Costosa</li> </ul>                                          |
| <b><i>Abordaje en un centro comercial</i></b> | <ul style="list-style-type: none"> <li>• Rápida</li> <li>• Poco costosa</li> <li>• Fácil de llevar a cabo</li> <li>• Pueden usarse ayudas visuales</li> <li>• Flexibilidad para el entrevistador</li> </ul> | <ul style="list-style-type: none"> <li>• No se pueden proyectar los resultados</li> <li>• La entrevista debe ser breve</li> </ul>      |
| <b><i>Entrevistas personales</i></b>          | <ul style="list-style-type: none"> <li>• Pueden usarse ayudas visuales</li> <li>• Flexibilidad para el entrevistador</li> <li>• Las preguntas se pueden analizar en profundidad</li> </ul>                  | <ul style="list-style-type: none"> <li>• Costosa</li> <li>• Se emplea mucho tiempo</li> <li>• Se obtienen muestras pequeñas</li> </ul> |



### 3.3.4. Relevamiento Estático y Dinámico

En un relevamiento estático, los datos son obtenidos a una fecha determinada, en un día fijo, obteniéndose ese día todos los datos necesarios para la investigación. Ejemplo: Censo poblacional.

En un relevamiento dinámico, los datos corresponden a aquellas operaciones que se realizan en forma continuada a través del tiempo y de forma sistemática, no en un solo día, sino en forma sucesiva. Ejemplo: Datos sobre nacimientos, defunciones, casamientos, etc.

Considerando los anteriores conceptos, podemos dividir en dos a los métodos de captación (relevamiento, recogida, levantamiento) de la información:

#### *Métodos de Captación Completo o Exhaustivo*

##### *Censo o Relevamiento Estático*

Consiste en estudiar a la Población a través de todos sus elementos en un momento determinado. Ejemplo: Censo Ganadero. Censo Poblacional.

##### *Registro Exhaustivo o Relevamiento Dinámico*

Consiste en estudiar a la Población a través de todos sus elementos en forma continua. Ejemplo: Registro Civil. Registro Prendario. Registro del Automotor.

#### *Métodos de Captación Parcial*

Consiste en tomar información sobre una parte representativa de la Población que constituye la muestra.

### 3.4. Clasificación, Tabulación Y Descripción De Los Resultados

Se refiere a la organización, presentación y descripción de los datos recopilados a los fines de facilitar la interpretación y el análisis de estos.

Cuando los datos con los que se cuentan son pocos, es posible presentar la información en forma de explicación escrita, llamada **presentación literal**.

Pero, cuando se trabaja con un gran número de datos, se hace necesaria la presentación en forma ordenada, lográndose tal objetivo al clasificarlos de manera sistemática y presentarlos en cuadros ó tablas, que llamaremos **Distribuciones de Frecuencias**, ó bien, construyendo gráficos y diagramas.

Es, además posible y fundamental, el cálculo de medidas descriptivas, tales como proporciones, promedios o desviaciones, que permiten a través de unos pocos valores, caracterizar o describir el comportamiento de grandes series de datos.

Las formas de organizar, presentar y describir la información, dependerá, según veremos, no sólo del tipo de dato con que estemos trabajando, sino del volumen de esta.



Además, los datos pueden ser recolectados a través de un Censo, es decir, la medición fue realizada para la totalidad de elementos bajo estudio, o a través de un Muestreo, es decir, la medición fue realizada para una parte de la Población. En base a ello, diremos que toda medida basada en datos de muestra se llama *Estadística o Estadígrafo*, mientras que toda medida basada en datos de población, se llama *Parámetro*.

### ***3.5. Generalización o Inferencia Final***


Si se ha trabajado con la totalidad de los elementos, censo ó enumeración completa, un estudio finaliza con el cálculo de medidas descriptivas. Entonces, puede describirse y revelarse las características de toda la población, pudiendo fácilmente arribar a conclusiones o tomar una decisión sobre el problema.

Si por el contrario, el estudio se realizó en base a una muestra, es necesaria una etapa adicional, consistente en tratar de responder, basándose en estadísticas de muestra, al problema o pregunta original formulada, que siempre se refiere a la población, en particular a su distribución y sus parámetros.

Así, el proceso de utilización de datos muestrales para inferir o generalizar sobre la población a la que pertenecen y de la cual fueron extraídos, requiere de los conocimientos y herramientas brindados por la Inferencia Estadística, a través de dos técnicas: la *Estimación Estadística* y la *Docimasia de Hipótesis*.



## Resumen





#### **4. TABLAS ESTADÍSTICAS**

Como ya mencionamos, es necesaria la organización de los datos captados, sean éstos poblacionales o muestrales, a los fines de poder interpretarlos para sacar conclusiones o tomar de decisiones.

##### ***4.1. Tipos de Tablas Estadísticas***

De acuerdo con el propósito para las cuales fueran creadas, podemos clasificarlas en:

1- *Tablas para propósitos generales o de referencia:* no se construyen con un fin específico, sino que proporcionan información que puede ser usada como referencia o uso general.

2- *Tablas para propósitos especiales o de resumen, analíticas o de texto:* se confeccionan con el fin de proporcionar información para una exposición particular.

##### ***4.2. Partes principales de una Tabla Estadística***

a) *Título:* es una descripción del contenido de la tabla. Debe ser preciso y completo y en general contar con los siguientes elementos:

- ☐ A qué corresponden los datos incluidos en la tabla
- ☐ Dónde está ubicada el área a la que corresponden los datos
- ☐ Cómo están clasificados los datos
- ☐ Cuando ocurrieron los hechos que dieron origen a la tabla

Cuando se presenta más de una tabla en el análisis, es necesaria su enumeración para que sea más fácil hacer referencia a la misma.

b) *Encabezamiento:* es la parte superior de las columnas, donde se colocan los títulos que indican los conceptos y los datos presentados en la tabla. En algunos casos existen encabezamientos y subencabezamientos.

c) *Conceptos o Columna Matriz:* son las descripciones que aparecen en las hileras de las tablas, en el extremo izquierdo de las mismas. En general, representan las clasificaciones de las cifras incluidas en el cuerpo de la tabla y la naturaleza de estas clasificaciones está incluida en el encabezamiento de esta columna. Cada concepto puede ser dividido en subconceptos si es necesario.

d) *Cuerpo:* está formado por el contenido de los datos estadísticos, los que están agrupados de acuerdo con las descripciones o clasificaciones de los encabezamientos y conceptos.

e) *Notas del encabezamiento:* se ubican sobre los encabezamientos y debajo del título y aclaran ciertos aspectos relacionados con la tabla que no han sido incluidos en el título, ni en los encabezamientos, ni en los conceptos. Por ejemplo, la unidad de medida en la que están expresados los datos, se acostumbra a indicarla como una nota del encabezamiento.

f) *Notas al pie:* debajo del cuerpo de la tabla se ubican las notas al pie, que sirven para clarificar algunos aspectos incluidos y que no son explicados en otras partes de la tabla.

g) *Fuente:* debajo de las notas al pie, se establece la fuente que sirvió para obtener la información proporcionada por la tabla.



### Ejemplo:

Identificación de los conceptos desarrollados:

| <i>Título</i>                   | <b>1. EVOLUCIÓN DEL COMERCIO EXTERIOR-<br/>EXPORTACIONES</b>                         |             |             |              |             |
|---------------------------------|--------------------------------------------------------------------------------------|-------------|-------------|--------------|-------------|
| <i>Notas del Encabezamiento</i> | <i>En millones de dólares</i>                                                        |             |             |              |             |
| <i>Cuerpo</i>                   | <b>CONCEPTO</b>                                                                      | <b>2000</b> | <b>2001</b> | <b>-----</b> | <b>2010</b> |
|                                 | <i>Productos Primarios</i>                                                           | 1436        | 1618        | -----        | 3677        |
|                                 | -----                                                                                | -----       | -----       | -----        | -----       |
|                                 | -----                                                                                | -----       | -----       | -----        | -----       |
|                                 | Sin clasificar                                                                       | 0           | 5           | -----        | 15          |
|                                 | <b><i>Total de Exportaciones</i></b>                                                 | <b>2942</b> | <b>3916</b> | <b>-----</b> | <b>8396</b> |
| <i>Notas al Pie</i>             | <b><i>Nota:</i> Las cifras pueden no coincidir con el total por redondeo</b>         |             |             |              |             |
| <i>Fuente</i>                   | <b><i>Fuente:</i> Organismo gubernamental encargado de producir esta información</b> |             |             |              |             |

### 4.3. Construcción de Tablas Estadísticas

Una vez que los datos recopilados han sido ordenados convenientemente, es necesario antes de la construcción efectiva de la tabla, y con el fin de que la misma cumpla cabalmente con su cometido, considerar una serie de elementos, entre ellos:

- Simplicidad en la presentación de la tabla
- Tratamiento de un tema por vez en cada tabla
- Ordenamiento adecuado de las clasificaciones. Pueden ser ordenados de acuerdo con cuatro bases:

1- *Cronológica:* Los datos clasificados por intervalos de tiempo se ordenan generalmente tomando en consideración el orden cronológico, ya sea iniciando la tabla con el período más antiguo o el más reciente; no obstante, se acostumbra a comenzar con el período más antiguo.

2- *Geográfica:* se acostumbra a ordenarlas por orden alfabético o de acuerdo con la importancia de las áreas consideradas.

3- *Cualitativas:* son ordenadas teniendo en cuenta la importancia de las clases individuales, no obstante, si no interesa enfatizar tal circunstancia, se prefiere el orden alfabético.

4- *Cuantitativas:* Se ordenan, ya sea de menor a mayor o de mayor a menor, teniendo en cuenta el valor relativo de los datos.

- Facilitar al máximo las comparaciones
- Destacar cifras importantes
- Redondear cifras cuando no se requiere mayor detalle

En muchos casos, las tablas se diseñan sin necesidad de establecer cifras exactas, sobre todo si la información básica cuenta con muchos dígitos en sus datos. En tal caso, se utilizan cifras aproximadas y se procede a redondear las cantidades exactas de forma que los dígitos



posteriores o las comas o puntos sean aproximaciones a unidades. Existen distintas reglas que se utilizan en el redondeo de cifras, pero la más sencilla y práctica es la siguiente:

- Si la porción de dígitos a ser eliminada comienza con 4 ó menos, se mantiene el dígito precedente a los que se eliminan, sin cambio. Ejemplo: 7.386.432.....7.386 millones.
- Si la porción de dígitos a eliminar comienza con 5 ó más, se agrega una unidad al dígito precedente. Ejemplo: 7.386.532.....7.387 millones.


Lo importante a tener en cuenta, es que las cifras sufran la menor variación posible a consecuencia del redondeo.

Frecuentemente, el total de cifras redondeadas en una tabla no concuerda exactamente con el total redondeado de las cifras originales. En este caso, se puede adoptar uno de los siguientes criterios:

- Agregar una aclaración en la Nota al Pie, en la que se especifique la razón por lo que no concuerdan, como por ejemplo: “La suma de las cifras detalladas no concuerda con los totales indicados debido a redondeo”.
- Ajustar uno de los sumandos, de tal manera que el total de los números redondeados concuerde con el total redondeado, teniendo especial cuidado en que el número ó los números a ser ajustados provoquen el menor cambio.

### **5. FORMAS DE AGRUPAR VARIABLES CUANTITATIVAS**

Según ya analizamos, la variable es una entidad que varía y de la que hay que distinguir entre *Valores posibles* y *valores realmente observados*:



Para ejemplificar, utilizaremos las notas de un examen. Ellas pueden variar, en números enteros, del 0 al 10, entonces los valores posibles serán: 0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10. Si se han tomado cinco exámenes y las notas fueron 5, 3, 8, 6, 9; éstos serán los valores realmente observados.

Las formas para agrupar datos que desarrollaremos seguidamente, son aplicables para cuando contamos con los valores observados de la variable, sea esta Discreta o Continua.

La cantidad de valores observados, así como el comportamiento de estos, nos indicarán el tipo de agrupamiento que debemos realizar para resumir la información obtenida.





### 5.1. Series Simples o Datos No Agrupados

Se utilizan cuando la serie de datos con que contamos es pequeña, y en general, todos los valores son distintos, es decir, que cada uno de ellos se presenta una sola vez, con independencia del tipo de variable. En estos casos no se requiere agrupamiento de los datos analizados, es por ello que hablamos también de datos *No Agrupados*.

Cada valor de la serie representa una observación, la que designaremos, para el caso de una muestra, por  $x_1, x_2, \dots, x_n$  conforme al orden en que se presenten.

En general  $x_i$ ,  $i = 1, 2, \dots, n$ , representa la  $i$ -ésima observación.

Entonces:

|       |                                    |
|-------|------------------------------------|
| $x_1$ | Primera medición de la Variable    |
| $x_2$ | Segunda medición de la Variable    |
| $x_3$ | Tercera medición de la Variable    |
| ..... | .....                              |
| $x_n$ | $n$ -ésima medición de la variable |

Es decir que, a través de  $x$ , representamos la característica bajo estudio o variable, y con el subíndice, el orden en que esa característica o valor ha sido observado.

Este conjunto de observaciones constituye una muestra de tamaño  $n$  procedente de la población que contiene el total de elementos bajo estudio.

Cabe aclarar que si realizáramos un censo las notaciones serían las mismas, solo que usaríamos letras mayúsculas, es decir  $X$  para la variable y  $N$  para el tamaño de la población.

#### Ejemplo:

Variable: Número de Hijos por familia

Muestra:  $n = 10$  familias

Valores Observados:

$$x_1 = 2; x_2 = 1; x_3 = 3; x_4 = 1; x_5 = 2; x_6 = 1; x_7 = 3; x_8 = 0; x_9 = 2; x_{10} = 1$$

Podemos observar a simple vista, que la mayoría de las familias tienen 1 hijo (4), luego 2 hijos (3), luego 3 hijos (2) y ningún hijo (1).

### 5.2. Datos Agrupados o Distribuciones de Frecuencias

Cuando el número de datos es muy grande, el simple análisis de ellos no nos permite obtener ninguna conclusión de interés. Es por ello, que prácticamente todo el análisis se practica a través de tablas que se conocen como *Distribuciones de Frecuencias*, cuyo objetivo es condensar y simplificar la información sin perder muchos detalles. Es decir, se hace necesario realizar un agrupamiento de los datos analizados, razón por la cual hablamos de *Datos Agrupados*.



Las Distribuciones de Frecuencias, pueden ser:

- *Unidimensionales*: analizan una variable por vez. Por ejemplo, peso o altura o edad.
- *Bidimensionales*: analizan dos variables por vez, por ejemplo, relación entre peso y altura, peso y edad, altura y edad.
- *Multidimensionales*: analizan más de dos variables por vez, como por ejemplo, relación entre peso, altura y edad.

En este curso trabajaremos solamente, con *Distribuciones Unidimensionales*. Este agrupamiento puede realizarse de dos maneras:

*En Forma De Lista*  
*En Forma De Intervalos*

La elección entre ellas, como ya dijimos, dependerá fundamentalmente de la cantidad de valores observados y de su comportamiento.

### ***5.2.1. Distribuciones De Frecuencias En Lista***

Consiste en construir una tabla de dos columnas. En la primera de ellas, se listan los diferentes valores que asumió la variable, en las observaciones realizadas, ordenados por su magnitud, en orden descendente o ascendente, con independencia de la naturaleza de la variable. En la segunda columna se indica el número de veces que cada valor distinto se ha repetido, o bien la proporción que cada cantidad de valores distintos representa en el total de las observaciones. Estos números constituyen desde dos ópticas, una en valores absolutos, y la otra en valores relativos, la frecuencia de presentación, según veremos seguidamente.

Simbolizaremos con  $y_i, i = 0, 1, 2, \dots, m$ , a los distintos valores que se hayan presentado en las observaciones realizadas, donde  $m$  representa la cantidad de estos valores distintos. Nótese que  $m$  será siempre menor que  $n$ , número total de observaciones.

#### ***5.2.1.1. Frecuencias Absolutas***

Cuando la segunda columna de la tabla construida, muestre el número de veces que se han repetido los distintos valores de la variable, la llamaremos Frecuencia Absoluta y la simbolizaremos por  $n_i, i = 0, 1, 2, \dots, m$ .

Necesariamente  $n_i$ , será menor o a lo sumo igual que  $n$ , ( $n_i \leq n$ ), y mayor o igual a 0 ( $n_i \geq 0$ ). Además, la suma de todas las frecuencias absolutas será igual al tamaño de la muestra (o población), es decir al total de las observaciones. Por lo tanto, para el caso de una muestra:

$$\sum_{i=1}^m n_i = n.$$

Simbólicamente, la tabla queda construida de la siguiente forma:



|       |                        |
|-------|------------------------|
| $y_i$ | $n_i$                  |
| $y_1$ | $n_1$                  |
| $y_2$ | $n_2$                  |
| ...   | ...                    |
| $y_m$ | $n_m$                  |
|       | $\sum_{i=1}^m n_i = n$ |

Entonces, debe verificarse:

$$\begin{aligned} n_i &\leq n \\ n_i &\geq 0 \\ \sum_{i=1}^m n_i &= n \end{aligned}$$

#### 5.2.1.2. Frecuencias Relativas

Cuando la segunda columna de la tabla construida, muestre la proporción de los distintos valores de la variable, la llamaremos Frecuencia relativa y la simbolizaremos por  $h_i$ ,  $i = 0, 1, 2, \dots, m$ .

Su cálculo se reduce a obtener el cociente entre el valor de cada frecuencia absoluta ( $n_i$ ) por el total de observaciones ( $n$ ).

Entonces

$$h_i = \frac{n_i}{n}$$

El resultado es una fracción que no puede ser mayor que 1 ( $h_i \leq 1$ ), ni menor que 0 ( $h_i \geq 0$ ), y la suma de todas las frecuencias relativas será siempre igual a 1.

Simbólicamente, la tabla queda construida de la siguiente forma:

|       |                        |
|-------|------------------------|
| $y_i$ | $h_i$                  |
| $y_1$ | $h_1$                  |
| $y_2$ | $h_2$                  |
| ...   | ...                    |
| $y_m$ | $h_m$                  |
|       | $\sum_{i=1}^m h_i = 1$ |

Entonces, debe verificarse:

$$\begin{aligned} h_i &\leq 1 \\ h_i &\geq 0 \\ \sum_{i=1}^m h_i &= 1 \end{aligned}$$

#### 5.2.1.3. Frecuencias Acumuladas

Tanto las frecuencias absolutas como las relativas que hemos definido, pueden acumularse, es decir, que se pueden ir sumando los distintos valores hasta el correspondiente subíndice de la variable que nos interese. De esta manera podemos distinguir entre:

##### Frecuencias Absolutas Acumuladas

La simbolizaremos por  $N_i$ ,  $i = 0, 1, 2, \dots, m$ , valor que corresponde a  $y_i$ , siendo por definición:

$$N_i = n_1 + n_2 + \dots + n_i$$

Entonces:



La primera frecuencia acumulada será  $N_1 = n_1$   
 La segunda  $N_2 = n_1 + n_2$   
 La tercera  $N_3 = n_1 + n_2 + n_3$   
 ...  
 Y así sucesivamente hasta la última  $N_m = n_1 + n_2 + n_3 + \dots + n_m = \sum_{i=1}^m n_i = n$

### Frecuencias Relativas Acumuladas

La simbolizaremos por  $H_i$  para  $i = 0, 1, 2, \dots, m$  valor que corresponde a  $y_i$ , siendo por definición:

$$H_i = h_1 + h_2 + \dots + h_i$$

Entonces:

La primera frecuencia acumulada será  $H_1 = h_1$   
 La segunda  $H_2 = h_1 + h_2$   
 La tercera  $H_3 = h_1 + h_2 + h_3$   
 ...  
 Y así sucesivamente hasta la última  $H_m = h_1 + h_2 + h_3 + \dots + h_m = \sum_{i=1}^m h_i = 1$

Entonces:

| $y_i$ | $N_i$                                                        | $H_i$                                                        |
|-------|--------------------------------------------------------------|--------------------------------------------------------------|
| $y_1$ | $N_1 = n_1$                                                  | $H_1 = h_1$                                                  |
| $y_2$ | $N_2 = n_1 + n_2$                                            | $H_2 = h_1 + h_2$                                            |
| ...   | ...                                                          | ...                                                          |
| $y_m$ | $N_m = n_1 + n_2 + n_3 + \dots + n_m = \sum_{i=1}^m n_i = n$ | $H_m = h_1 + h_2 + h_3 + \dots + h_m = \sum_{i=1}^m h_i = 1$ |

Ejemplo: Sea la siguiente distribución del número de hijos en  $n = 10$  familias observadas, donde  $y_i$  representa el número de hijos y  $n_i$  la cantidad de familias.

| $y_i$ | $n_i$ | $h_i$       | $h_i \times 100$ | $N_i$ | $H_i$ |
|-------|-------|-------------|------------------|-------|-------|
| 0     | 1     | $1/10=0,10$ | 10%              | 1     | 0,10  |
| 1     | 4     | $4/10=0,40$ | 40%              | 5     | 0,50  |
| 2     | 3     | $3/10=0,30$ | 30%              | 8     | 0,80  |
| 3     | 2     | $2/10=0,20$ | 20%              | 10    | 1     |
|       | 10    | 1           | 100              |       |       |

Para ciertos fines, es conveniente disponer de los datos acumulados. Puede que deseemos contestar: ¿Cuántas personas ganan \$ 1.000 o menos al mes? ¿Cuántos vendedores venden una cantidad dada o más por semana?

Pueden formarse frecuencias acumuladas sobre la base de “menos que” o “más que” y pueden ser absolutas o relativas.

Se ejemplificarán estas acotaciones cuando se desarrollen gráficos estadísticos.



### 5.2.2. Distribuciones De Frecuencias En Intervalos

Si el número de observaciones es grande y el número de valores distintos que asumió la variable es casi tan grande como el total de observaciones, el recorrido de las variables ya no puede ser descripto por unas pocas categorías distintas de medidas, como lo hicimos en el caso anterior, sea la variable de naturaleza discreta o continua.

Entonces como en el caso anterior, construiremos una tabla de dos columnas, pero en la primera de ellas, los valores de la variable se presentan a través de intervalos o clases. En la segunda columna se indica la cantidad de valores contenidos por intervalos, o bien la proporción que esa cantidad de valores representa en el total de las observaciones. Estos números, al igual que antes, constituyen desde dos ópticas, una en valores absolutos, y otra en valores relativos, las frecuencias de presentación.

Para la construcción de estas tablas, definiremos los siguientes conceptos:

*Intervalos De Clases o Clases:* Los valores de la variable aparecen separados en intervalos de clases es decir que, para condensar y simplificar los datos, se utilizan las tablas de distribuciones de frecuencias, en las cuales se agrupan convenientemente los valores de la variable, en intervalos.

Intervalos de clases, que simbolizaremos por  $y'_{i-1} - y'_i$ , donde  $y'_{i-1}$  es el extremo o límites inferiores del intervalo, es decir los números que aparecen a la izquierda y  $y'_i$ , es el extremo o límite superiores, es decir los números que aparecen a la derecha.

*Amplitud Del Intervalo:* Está dada por la diferencia entre los valores extremos del intervalo.

Lo simbolizaremos y calcularemos por:  $c_i = y'_{i-1} - y'_i$ .

Su tamaño depende del problema analizado y también del interés del investigador en condensar más o menos esos datos.

Cuanto menor sea la amplitud del intervalo, mayor será la cantidad de clases que tendremos, y viceversa.

A medida que los datos se agrupen más, se va perdiendo no sólo información, sino precisión en los resultados.

*Marcas De Clase:* Son los puntos medios del intervalo.

Las simbolizaremos y calcularemos por:  $y_i = \frac{y'_{i-1} + y'_i}{2}$

Es decir, es la media aritmética de los valores extremos del intervalo.

Obsérvese que los distintos subíndices de las marcas de clases coincidirán con los del extremo superior del intervalo de clase respectivo. Por trabajar con  $y_i$ , se dice que perdemos precisión, pues este valor, representa a los datos originales y los valores de frecuencia absoluta no corresponden exactamente a  $y_i$ , sino a los valores originales comprendidos entre los extremos en los cuales se encuentra  $y_i$ .

*Recorrido De La Serie:* Es la diferencia entre el valor superior ( $y_{máx}$ ) y el valor inferior ( $y_{mín}$ ) de la serie. Es decir:

$$R = y_{máx} - y_{mín}$$



Al construir los intervalos de clase se amplía el recorrido para evitar que los límites inferior y superior coincidan con los valores extremos que adopta la variable y por convención se establece: “Si un valor de la variable cae en el extremo superior del intervalo, corresponde al intervalo siguiente”. Generalmente los intervalos tienen igual amplitud y su número oscila entre 5 y 12.

El número de intervalos se fija arbitrariamente y la amplitud de cada uno de ellos ( $c_i$ ), será igual a:

$$c_i = \frac{R}{N^\circ \text{ de Intervalos}} = \frac{y_{\text{máx}} - y_{\text{mín}}}{m}$$

Si el resultado es un número decimal se amplía el intervalo hasta lograr que su amplitud sea una cifra entera y cómoda de utilizar.

La cantidad que se agrega a  $R$  para llegar a  $R'$  (recorrido ampliado), se divide en partes iguales al comienzo y al final de la distribución.

Presentaremos a continuación las correspondientes frecuencias, mencionando las interpretaciones que le daremos para este tipo de presentación:

#### *5.2.2.1. Frecuencias Absolutas*

Indican ahora, la cantidad de valores comprendidos en cada intervalo. Se simbolizan y responden a iguales condiciones que las vistas en Frecuencias Absolutas para Distribuciones de Frecuencias en Lista.

#### *5.2.2.2. Frecuencias Relativas*

Indican ahora, la proporción de valores comprendidos en cada intervalo. Se simbolizan y responden a iguales condiciones que las vistas Frecuencias Relativas para Distribuciones de Frecuencias en Lista.

#### *5.2.2.3. Frecuencias Acumuladas*

##### *Frecuencias Absolutas Acumuladas*

Indican ahora, la cantidad de valores menores desde el límite superior de cada intervalo.

##### *Frecuencias Relativas Acumuladas*

Indican ahora, la proporción de valores menores desde el límite superior de cada intervalo.

Se simbolizan y responden a iguales condiciones que las vistas en Frecuencias tanto absolutas como relativas acumuladas vistas en la distribución de Frecuencias en Lista.

Pueden también acumularse considerando al límite inferior de cada clase indicando en este caso, la cantidad o proporción, según corresponda de valores mayores o iguales a partir del límite considerado.



Presentaremos una tabla conteniendo los conceptos analizados

| <i>Intervalos De Clase</i> | <i>Marcas De Clase</i> | <i>Frecuencia Absoluta</i> | <i>Frecuencia Relativa</i> | <i>Frecuencia Absoluta Acumulada</i> | <i>Frecuencia Relativa Acumulada</i> |
|----------------------------|------------------------|----------------------------|----------------------------|--------------------------------------|--------------------------------------|
| $y'_{i-1} - y'_i$          | $y_i$                  | $n_i$                      | $h_i$                      | $N_i$                                | $H_i$                                |
| $y'_0 - y'_1$              | $y_1$                  | $n_1$                      | $h_1$                      | $N_1$                                | $H_1$                                |
| $y'_1 - y'_2$              | $y_2$                  | $n_2$                      | $h_2$                      | $N_2$                                | $H_2$                                |
| $y'_2 - y'_3$              | $y_3$                  | $n_3$                      | $h_3$                      | $N_3$                                | $H_3$                                |
| ...                        | ...                    | ...                        | ...                        | ...                                  | ...                                  |
| $y'_{m-1} - y'_m$          | $y_m$                  | $n_m$                      | $h_m$                      | $N_m = N$                            | $H_m = 1$                            |
|                            |                        | $\sum_{i=1}^m n_i = n$     | $\sum_{i=1}^m h_i = 1$     |                                      |                                      |

### Ejemplo:

Supongamos que tenemos 20 datos para analizar, correspondientes a las edades de un grupo de personas:

$y_1 = 74; y_2 = 47; y_3 = 67; y_4 = 82; y_5 = 67; y_6 = 65; y_7 = 70; y_8 = 55; y_9 = 57; y_{10} = 85; y_{11} = 69; y_{12} = 58; y_{13} = 71; y_{14} = 61; y_{15} = 52; y_{16} = 76; y_{17} = 79; y_{18} = 77; y_{19} = 88; y_{20} = 94.$

Contamos con 20 observaciones para la variable, entonces  $n = 20$

Convengamos en construir una tabla con 5 intervalos, entonces  $m = 5$

### Procedimiento:

1- Ordenamos los datos de la serie en forma ascendente o descendente, a los fines de detectar el mínimo ( $y_{\min}$ ) y el máximo ( $y_{\max}$ ) valor: 47, 52, 55, 57, 58, 61, 65, 67, 67, 69, 70, 71, 74, 76, 77, 79, 82, 85, 88, 94.

2- Obtenemos el Recorrido de la serie:  $R = y_{\max} - y_{\min} = 94 - 47 = 47$

3- Determinamos la amplitud que deberá tener cada intervalo en función del Recorrido ( $R$ ) y del número de intervalos definidos ( $m$ ):

4-

$$c_i = \frac{R}{N^{\circ} \text{ de Intervalos}} = \frac{y_{\max} - y_{\min}}{m} = \frac{47}{5} = 9,4$$

Hemos encontrado una amplitud de intervalo que resulta inadecuada. Por lo general, se trata de que sean números enteros y sobre todo divisibles por 2, para que al dividir la amplitud del intervalo por 2, nos dé una marca de clase o punto medio no fraccionario.

Entonces, tomaremos como amplitud a 10, lo cual modifica el recorrido, pasando a ser un recorrido ampliado igual a:  $5 \times 10 = 50$  ( $m \times c'_i = R'$ ). Para llegar a este recorrido de 50, debemos tomar en la serie, en lugar de 47, 45 (47-2), como punto mínimo y en lugar de 94, 95



(94+1), como punto máximo. Es decir, que hemos ampliado la serie en 3, 1 por arriba y 2 por abajo, que corresponde al incremento del nuevo recorrido (95-45).

Tenemos ya determinados los elementos necesarios para construir la tabla, que en resumen son:  $y_{\min} = 45$ ;  $y_{\max} = 95$ ;  $m = 5$  y  $c_i = 10$ .

| (1)<br>$y'_{i-1} - y'_i$ | (2)<br>$y_i$ | $n$ | $h$         | $N_i$ | $H$  |
|--------------------------|--------------|-----|-------------|-------|------|
| 45-55                    | 50           | 2   | $2/20=0,10$ | 2     | 0,10 |
| 55-65                    | 60           | 4   | $4/20=0,20$ | 6     | 0,30 |
| 65-75                    | 70           | 7   | $7/20=0,35$ | 13    | 0,65 |
| 75-85                    | 80           | 4   | $4/20=0,20$ | 17    | 0,85 |
| 85-95                    | 90           | 3   | $3/20=0,15$ | 20    | 1    |
|                          |              | 20  | 1           |       |      |

Los intervalos se construyen de la siguiente forma: El límite superior del primer intervalo coincide con el valor inferior de la serie ( $y_{\min}$ ), que en este caso es de 45. A este valor se le suma la amplitud del intervalo y se obtiene el límite superior del primer intervalo ( $45+10=55$ ).

Procedemos de igual forma para el resto de los intervalos, hasta llegar al último, en donde el límite superior debe coincidir con el valor máximo de la serie (95).

Es decir, a cada límite inferior le sumaremos la amplitud para obtener el límite superior. (Columna 1).

Una vez determinados los intervalos de clase, obtenemos para cada uno de ellos la marca de clase, Columna (2), haciendo:

$$\text{Primer Intervalo} \quad y_1 = \frac{45 + 55}{2} = 50 \quad \text{Segundo Intervalo} \quad y_2 = \frac{55 + 65}{2} = 60$$

Y así sucesivamente.

Para distribuir una masa de datos brutos entre las clases que ya han sido establecidas, a los fines de conocer la frecuencia absoluta, podemos usar:

### Hoja de Cuenta

Supone establecer clases y representar cada unidad que corresponde a cada clase por una raya diagonal, entonces contamos el número de unidades de cada clase:

| Clase |                    |    |
|-------|--------------------|----|
| 45-55 | //                 | 2  |
| 55-65 | ////               | 4  |
| 65-75 | <del>////</del> // | 7  |
| 75-85 | ////               | 4  |
| 85-95 | ///                | 3  |
|       |                    | 20 |





Es decir, el primer dato es 47, el cual está incluido en el primer intervalo, el segundo dato es 52, también incluido en el primer intervalo, lo que hemos dejado representado por ambas barras, y así sucesivamente se van ubicando el resto de las observaciones. El total debe coincidir con el número de datos.

### Forma de Asiento

Las clases se disponen horizontalmente en la parte superior por orden ascendente de izquierda a derecha. Las unidades reales son anotadas en las clases correspondientes. Las respectivas unidades son anotadas en la parte inferior de dicha clase. Las cifras totales de las clases constituyen las frecuencias de clases.

| <i>45-55</i> | <i>55-65</i> | <i>65-75</i> | <i>75-85</i> | <i>85-95</i> |
|--------------|--------------|--------------|--------------|--------------|
| 47           | 55           | 65           | 76           | 85           |
| 52           | 57           | 67           | 77           | 88           |
|              | 58           | 67           | 79           | 94           |
|              | 61           | 69           | 82           |              |
|              |              | 70           |              |              |
|              |              | 71           |              |              |
|              |              | 74           |              |              |
| <b>2</b>     | <b>4</b>     | <b>7</b>     | <b>4</b>     | <b>3</b>     |

Es más laboriosa que la anterior, pero ofrece ciertas ventajas:

- Pueden hallarse registros en las columnas inapropiadas con sólo examinarlas.
- Pueden hacerse nuevas clasificaciones si las clases originales son insatisfactorias.
- Puede saberse cuán estrechamente concuerda el valor medio con el promedio de las unidades de dicha clase.

Vamos a considerar ahora, nuevos ejemplos, mostrados en las siguientes tablas, a partir de los cuales realizaremos algunas consideraciones, introduciendo otros conceptos importantes:

| $y_{i-1} - y_i$ | $y_i$ | $n$ | $h$   | $N$ | $H$   |
|-----------------|-------|-----|-------|-----|-------|
| 0 - 4           | 2     | 34  | 0,829 | 34  | 0,829 |
| 4 - 8           | 6     | 4   | 0,098 | 38  | 0,927 |
| 8 - 12          | 10    | 2   | 0,049 | 40  | 0,976 |
| 12 - 16         | 14    | 0   | 0     | 40  | 0,976 |
| 16 - 20         | 18    | 0   | 0     | 40  | 0,976 |
| 20 - 24         | 22    | 0   | 0     | 40  | 0,976 |
| 24 - 28         | 26    | 1   | 0,024 | 41  | 1     |
| 28 - 32         | 30    | 0   | 0     | 41  | 1     |
|                 |       | 41  | 1     |     |       |

En este caso, vemos a simple vista que esta distribución realizada no es la más conveniente, pues la mayoría de los valores están concentrados en el primer intervalo (0-4), representados por  $y_i = 2$ .

### Ejemplo:

Suponemos la distribución de los Salarios para 2.720 trabajadores.



| <i>Clase</i><br>$y'_{i-1} - y'_i$ | <i>Amplitud</i><br>$c$ | $n_i$ | <i>Densidad de Frecuencia</i><br>(Por cada mil)<br>$n_i / c$ |
|-----------------------------------|------------------------|-------|--------------------------------------------------------------|
| <i>Menos de 5000</i>              | 5000                   | 100   | $100/5,0=20$                                                 |
| 5000-6000                         | 1000                   | 150   | $150/1,0=150$                                                |
| 6000-7000                         | 1000                   | 200   | $200/1,0=200$                                                |
| 7000-8000                         | 1000                   | 250   | $250/1,0=250$                                                |
| 8000-9500                         | 1500                   | 200   | $200/1,5=133,33$                                             |
| 9500-11000                        | 1500                   | 250   | $250/1,5=166,67$                                             |
| 11000-12500                       | 1500                   | 500   | $500/1,5=333,33$                                             |
| 12500-14500                       | 2000                   | 350   | $350/2=175$                                                  |
| 14500-16500                       | 2000                   | 400   | $400/2=200$                                                  |
| 16500-19500                       | 3000                   | 200   | $200/3=66,67$                                                |
| 19500-22500                       | 3000                   | 100   | $100/3=33,33$                                                |
| 22500 o más                       |                        | 20    | 0                                                            |
|                                   |                        | 2720  |                                                              |

En situaciones donde hay unos pocos valores extraordinariamente pequeños o grandes; o todos juntos, en los que los datos poseen grandes vacíos, y cuando el número de observaciones llega a ser de millares y aún de millones, con ventajas pueden utilizarse clases de extremo abierto e intervalos no uniformes.

En estos casos deben considerarse algunos otros conceptos:

- A veces puede formarse una distribución sin el límite inferior para la primera clase o sin el límite superior para la última clase, o sin ambos límites. Se dice entonces, que son *Clases De Extremo Abierto*. La amplitud del intervalo para una clase de extremo abierto es el infinito y su punto medio es  $\pm \infty$ .
- No es necesario que los intervalos tengan la misma amplitud, es decir sean *Uniformes*.

Pueden usarse intervalos con distinta amplitud, llamados *No Uniformes*. Cuando se usan intervalos no uniformes, debemos calcular lo que se conoce como *Densidad De Frecuencia*, estimando cuáles serían las frecuencias de clase si se usaran intervalos de clase uniformes.

Las densidades de frecuencia se han calculado en el supuesto de un intervalo de clase uniforme de \$1000. La densidad de frecuencia para la primera clase es 20, porque no es realmente de extremo abierto, ya que se trata de salarios, y su límite inferior es 0.

Entonces, como la amplitud es de 5000, o sea 5 veces 1000, la densidad es  $100/5=20$ .

La densidad de frecuencia para la última clase es 0, porque hemos supuesto que el límite superior es  $\infty$ .

Cuando se emplean clases de extremo abierto, es recomendable dar los valores mínimo o máximo, o ambos, y el valor o los valores en tal clase, en una nota al pie.

Otra solución es asegurarse que todas las clases que tienen por lo menos una observación sean cerradas, es decir, asegurarse de que todas las clases de extremo abierto estén vacías de observaciones, entonces, el supuesto del punto medio puede aplicarse a todos los datos, y los problemas causados por las clases de extremo abierto podrán evitarse.



Podemos utilizar la densidad de frecuencia, expresada por unidad de intervalo.

En ese caso la definimos como el número de casos por unidad de tamaño de clase. Es un promedio en cada clase de cuántas unidades hay por unidad de ancho del intervalo. Se obtiene como la frecuencia de clase dividido por el ancho del verdadero intervalo.

Si la frecuencia considerada es absoluta ( $n_i$ ), entonces  $n_i/c$  define la densidad de frecuencia absoluta. Si en cambio, la frecuencia considerada es relativa ( $h_i$ ), entonces  $h_i/c$  define la densidad de frecuencia relativa.

Ejemplo:

| $y'_{i-1} - y'_i$ | $n_i$ | $c$ | $n_i/c$     |
|-------------------|-------|-----|-------------|
| 50-60             | 8     | 10  | $8/10=0,8$  |
| 60-70             | 10    | 10  | $10/10=1$   |
| 70-90             | 8     | 20  | $8/20=0,4$  |
| 90-150            | 3     | 60  | $3/60=0,05$ |

En resumen

| <i>Densidad de Frecuencia</i> | <i>Simbología y Cálculo</i> | <i>Interpretación</i>                                                                            |
|-------------------------------|-----------------------------|--------------------------------------------------------------------------------------------------|
| <i>Absoluta</i>               | $dfr = n_i/c$               | Indica el promedio en cada clase de cuántas unidades hay por unidad de ancho del intervalo.      |
| <i>Relativa</i>               | $dfr = h_i/c$               | Indica el promedio en cada clase de la proporción de unidades por unidad de ancho del intervalo. |

En ambos casos, se ha considerado cada unidad de ancho del intervalo, pudiéndose calcular en el supuesto de intervalos de clase uniformes de 10, 100, 1000, etc., según convenga.

## 6 FORMAS DE AGRUPAR VARIABLES CUALITATIVAS

### 6.1 Distribuciones Categóricas o Tablas de Contingencia

Hasta acá hemos trabajado con variables cuantitativas. Veremos ahora, el caso de variables cualitativas o categóricas, donde hablaremos de Distribuciones Categóricas o Tablas de Contingencia.

Una Distribución de Frecuencias Categóricas muestra el número, o la proporción de observaciones que corresponde a cada una de las clases cualitativas, mutuamente excluyentes, que hayamos determinado.

El observador puede limitarse a anotar la presencia o ausencia de un cierto atributo en una serie de objetos o individuos y contar el número de los que lo poseen y el de los que no lo poseen.

Ejemplo:

Argentinos - No Argentinos  
Ciegos - Videntes



Estatura, considerando altos a los que exceden cierta estatura y bajos a todos los demás (Transformación de series cuantitativas y series cualitativas).

Es decir, se forman dos clases distintas, siendo éste el caso más simple, pero si se consideran varios atributos, el proceso de clasificación puede extenderse indefinidamente.

La clasificación en la que cada clase se subdivide en dos subclases se denomina dicotómica, caso contrario, se habla de clasificación múltiple.

El hecho de la clasificación no implica necesariamente, la existencia de una línea divisoria natural o claramente definida entre ambas clases. Puede ser totalmente arbitraria. La clasificación puede ser vaga o imprecisa. Ejemplo: Demencia y Cordura.

Puede haber discrepancias sobre la clase en que determinado individuo debe incluirse. Por ejemplo, al estudiar las distintas clases de alimentos vendidos por un comercio, podríamos adoptar clases tales como: “carnes y productos cárnicos”, “alimentos congelados”, etc.; tendríamos dificultad entonces para decidir a qué clase corresponde un producto tal como “carne congelada”.

Así, debemos tener cuidado al diseñar un conjunto de clases que deben ser *mutuamente excluyentes*, es decir, no pueden presentarse juntas, pues no tienen elementos en común, y *colectivamente exhaustivas*, pues consideran todo el espectro de posibilidades.

#### Ejemplo:

Un periódico muy conocido efectuó una encuesta telefónica para estudiar las opiniones de los ciudadanos de Córdoba, en relación con varias problemáticas. Se seleccionó un total de 419 personas, a través de una muestra aleatoria simple. Los siguientes datos reflejan las respuestas a una de las preguntas realizadas sobre lo adecuado de la protección brindada por la policía y los bomberos: “¿Es adecuada la protección brindada por la policía y los bomberos?”

| <i>Respuestas</i>            | <i>n</i>          |
|------------------------------|-------------------|
| <i>Sí</i>                    | <i>80</i>         |
| <i>No</i>                    | <i>293</i>        |
| <i>No sabe / No contesta</i> | <i>46</i>         |
| <b><i>Totales</i></b>        | <b><i>419</i></b> |

A menudo, es necesario examinar variables en forma simultánea. Por ejemplo, en un mazo de cartas francesas, con un total de 52 naipes, elaboramos para las variables “color” y “as”, la siguiente tabla:

|                       | <i>Rojo</i>      | <i>Negro</i>     | <b><i>Totales</i></b> |
|-----------------------|------------------|------------------|-----------------------|
| <i>As</i>             | <i>2</i>         | <i>2</i>         | <b><i>4</i></b>       |
| <i>No As</i>          | <i>24</i>        | <i>24</i>        | <b><i>48</i></b>      |
| <b><i>Totales</i></b> | <b><i>26</i></b> | <b><i>26</i></b> | <b><i>52</i></b>      |

Estas tablas, de dos sentidos, de clasificación cruzada, se conocen como *Tablas de Contingencia*.



## 7. REPRESENTACIONES GRÁFICAS

*Gráficos Lineales*, para agrupamientos en lista

- Gráfico de Bastones (Frecuencias absolutas o relativas)
- Gráfico Acumulativo de Frecuencias (Frecuencias acumuladas, sean absolutas o relativas)

*Gráficos de Superficie*, para agrupamiento en intervalos

- Histograma
- Polígono de Frecuencias
- Curva Suave



*Frecuencias absolutas*  
*Frecuencias relativas*  
*Densidades de Frecuencias*

- Diagrama Escalonado
- Ojiva menor que y Ojiva mayor que
- Curva Acumulativa Suavizada



*Frecuencias Acumuladas*  
*Absolutas*  
*Relativas*

*Gráficos Especiales*

Para variables categóricas

- Diagrama de Barras Horizontales
- Gráfica de Barras de Componentes de Porcentajes o Barra Porcentual
- Diagrama de Pastel o Círculo Radiado

### 7.1. Gráficos Lineales

#### 7.1.1. *Gráfico de Bastones*

Utilizamos esta gráfica cuando tenemos unos pocos valores distintos correspondientes a un agrupamiento en lista.

Consisten en líneas o segmentos de líneas. Para su construcción trabajaremos con el cuadrante positivo de un Sistema de Coordenadas Cartesianas Ortogonales, cuyos ejes “x” e “y” deberán ser rotulados claramente. Convenimos que el eje “x” representará los valores de la variable y el eje “y” los valores correspondientes a las frecuencias, ya sean absolutas o relativas, según se elija una u otra.


Una vez determinadas las escalas de ambas coordenadas, se marcan los puntos en el plano, correspondientes a cada uno de los pares de valores (variable y su respectiva frecuencia) que aparecen en la tabla. Luego, se eleva una perpendicular al eje de las abscisas hasta intersectar el punto marcado en el plano y que indica la observación. La altura de estas ordenadas o bastones, nos indican las frecuencias absolutas o relativas, ya que es indistinto el valor que tomemos en la ordenada, si las escalas son proporcionales a los valores que representan.



### Ejemplo:

Trabajaremos con el ejemplo dado en Distribuciones de Frecuencias en lista, o sea el Número de Hijos en 10 familias observadas.

| $y_i$ | $n_i$ | $h_i$       |
|-------|-------|-------------|
| 0     | 1     | $1/10=0,10$ |
| 1     | 4     | $4/10=0,40$ |
| 2     | 3     | $3/10=0,30$ |
| 3     | 2     | $2/10=0,20$ |
|       | 10    | 1           |



*Gráfico de Bastones*

Podríamos haber utilizado  $h_i$ , rotulando convenientemente.

### **7.1.2. Gráfico Acumulativo De Frecuencias**

Si se consideran las frecuencias absolutas o relativas acumuladas, la representación gráfica, se efectúa mediante el Gráfico Acumulativo de Frecuencias.

Al igual que para el caso anterior, utilizaremos el cuadrante positivo de un Sistema de Coordenadas, cuyos ejes deberán ser rotulados claramente.


También convendremos que en el eje “ $x$ ” representará los valores de la variable y el eje “ $y$ ” mostrará ahora, la frecuencia acumulada absoluta o relativa. Luego de marcar sobre el eje horizontal los valores de la variable, se levanta en cada uno de estos puntos una vertical de longitud igual a la frecuencia acumulada respectiva, completando con tramos horizontales la parte de los intervalos en que no se presentan observaciones, quedando indicada una línea poligonal escalera.

### Ejemplo:

Continuamos con el ejercicio planteado en el caso anterior.



| $y_i$ | $N_i$ | $H_i$ |
|-------|-------|-------|
| 0     | 1     | 0,10  |
| 1     | 5     | 0,50  |
| 2     | 8     | 0,80  |
| 3     | 10    | 1     |



**Gráfico Acumulativo de Frecuencias**



Podríamos haber utilizado  $H_i$ , rotulando convenientemente.

A partir de esta información y recurriendo a la Planilla Excel construiremos el gráfico de bastones y el gráfico acumulativo de frecuencias.

### **Gráfico de Bastones**

En primer lugar, utilizaremos la frecuencia absoluta, que indica en este caso el número de familias.

Podríamos haber utilizado  $h_i$ , rotulando convenientemente, lo que indicará la proporción de familias.







### Gráfico Acumulativo de Frecuencias

En primer lugar utilizaremos la frecuencia absoluta, que indica en este caso el número de familias:

Podríamos haber utilizado  $h_i$ , rotulando convenientemente, lo que indicará la proporción de familias.

### Gráfico Acumulativo de Frecuencias



## 7.2. Gráficos de Superficie

### 7.2.1. Histograma

Características especiales para su construcción

1- Las frecuencias de clase suelen representarse en el eje “y”, y la escala de los intervalos en el eje “x”. Los ejes “x” e “y” deben comenzar en 0, con interrupciones de escala si son necesarias. Ambos ejes, deben ser rotulados, clara y completamente.

2- Un espacio de la mitad al tamaño completo del intervalo de clase, se deja en cada extremo del eje “x”.

3- Las designaciones de escala “x” suelen ser colocadas como los verdaderos límites de clase. Las barras deben tocarse unas con otras, sin brechas, excepto para clases vacías. A veces, se rotula la escala “x” colocando el valor medio de cada clase en el centro de la base de la barra.

La escala “x”, es igualmente espaciada cuando los intervalos de clase son uniformes. En una distribución donde los intervalos son variables, la escala “x” debe ser ajustada apropiadamente. Por ejemplo, si se usan dos intervalos, de amplitud 100 y 500, el espacio para clases de 500 debe ser 5 veces más ancho que los espacios con intervalos de amplitud 100.

4- El eje “y” debe ser completamente rotulado para mostrar si representa frecuencia o densidad de frecuencia. Si los intervalos son **uniformes**, el patrón visual del gráfico será igual, tanto si se representan frecuencias como densidades de frecuencias. Sin embargo, es conveniente rotular el eje “y” de modo que el lector conozca cuál está siendo representado. Si los intervalos son **no uniformes**, el patrón visual del gráfico diferirá según si se representan frecuencias o densidades de frecuencias. Es conveniente utilizar densidades, de manera de






homogeneizar las unidades, puesto que en este caso se habla de individuos o proporción de individuos, por unidad de intervalo, o intervalo estándar, mientras que con las frecuencias, se tiene cantidad o proporción por cada intervalo que tiene distinta amplitud.

5- Un histograma se representa siempre como compuesto de barras, tanto si se muestran explícitamente como si no se muestran. Entonces, se construye utilizando un segmento de la escala horizontal para representar cada intervalo de clase, erigiendo un rectángulo igual en altura a la frecuencia absoluta o relativa o densidad correspondiente a esa clase.

### Ejemplo:

Utilizaremos el ejercicio desarrollado en Distribuciones de Frecuencias en Intervalos



**Histograma**

Hemos utilizado en este caso, frecuencias absolutas, pero podría haberse construido con frecuencias relativas, o densidades, siguiendo igual procedimiento.

Esta alternativa es válida siempre que los intervalos sean uniformes, pues si la amplitud de clase es distinta deberá construirse con densidad de frecuencia, sea absoluta o relativa.

Analizaremos seguidamente cuál es la interpretación de las partes del Histograma:

| Concepto                          | Interpretación                                                                                |
|-----------------------------------|-----------------------------------------------------------------------------------------------|
| <b>Base o Ancho de cada Barra</b> | Mide la amplitud del intervalo de clase, o sea $c$ , cualquiera sea la rotulación del eje "y" |
| <b>Altura de cada Barra</b>       | Su significado varía, según como se rotula el eje "y"                                         |
| $n_i$                             | Cantidad de unidades que hay en dicha clase.                                                  |
| $h_i$                             | Proporción de unidades que hay en dicha clase.                                                |
| $n_i/c$                           | Promedio en cada clase de cuántas unidades hay por unidad de ancho de intervalo               |
| $h_i/c$                           | Promedio en cada clase de la proporción de unidades hay por unidad de ancho de intervalo      |




|                                  |                                                                                                                                    |
|----------------------------------|------------------------------------------------------------------------------------------------------------------------------------|
| <b>Área de cada Barra</b>        | Su significado varía, según como se rotula el eje “y”                                                                              |
| $n_i$                            | Carece de significado                                                                                                              |
| $h_i$                            | Carece de significado                                                                                                              |
| $n_i/c$                          | La frecuencia absoluta para dicha clase, pues $n_i/c \times c = n_i$                                                               |
| $h_i/c$                          | La frecuencia relativa para dicha clase, pues $h_i/c \times c = h_i$                                                               |
|                                  |                                                                                                                                    |
| <b>Área Total del Histograma</b> | Su significado varía, según como se rotula el eje “y”                                                                              |
| $n$                              | Carece de significado                                                                                                              |
| $h$                              | Carece de significado                                                                                                              |
| $n/c$                            | $n$ , puesto que si el área de cada barra es $n_i$ , la sumatoria de los $n_i$ ( $i=1,2,...,m$ ) es igual al tamaño de la muestra. |
| $h/c$                            | 1, puesto que si el área de cada barra es $h_i$ , la sumatoria de los $h_i$ ( $i=1,2,...,m$ ) es igual a 1                         |

### 7.2.2. Polígono de Frecuencias

Si disponemos de una Histograma, construimos el Polígono uniendo con líneas rectas los puntos medios de cada barra del histograma.

Con mucha frecuencia, se construyen sin trazar los rectángulos. Sin el Histograma obtenemos el Polígono localizando las coordenadas: las ordenadas que son las frecuencias de clases y las abscisas, que son los puntos medios. Estos puntos son unidos después por líneas rectas.



No representa muy bien los datos básicos. La diferencia más notable es que las áreas situadas debajo de él, generalmente no son proporcionales a las frecuencias. Un remedio es cerrar el Polígono en la base prolongando ambos extremos de la curva hasta los puntos medios de dos clases hipotéticas situadas en los extremos de la distribución que tienen frecuencia 0.




Razones para usar el Polígono:

- 1- Cuando han de compararse varias distribuciones sobre el mismo gráfico, es mucho más claro superponer polígonos que Histogramas, especialmente cuando todas las distribuciones tienen los mismos límites de clase.
- 2- El Polígono sugiere el empleo de una curva suave como una representación idealizada de la distribución de la población.


Una muestra consta de sólo un número limitado de unidades, porque su distribución se caracteriza por irregularidades.

Sin embargo, si las unidades de la muestra se incrementan y la amplitud de los intervalos se disminuye continuamente, podemos esperar que la distribución sea cada vez más suave y cada vez más regular, porque las irregularidades que afectan a una pequeña cantidad de datos serían eliminadas gradualmente.

Recurriendo Excel, se obtienen los siguientes gráficos:



**Histograma**



**Polígono de Frecuencias**



### 7.2.3. Curva Suave

Cuando la muestra es muy grande, los intervalos de clase son muy estrechos ( $c$  muy pequeño), pero cada uno contendrá un número sustancial de unidades. Al mismo tiempo, si la escala vertical que mide la frecuencia es reducida de modo que el área del histograma para esta muestra extraordinariamente grande sea igual al área de la pequeña muestra original, el Histograma de la muestra grande formará prácticamente una curva suave.

La Curva Suave adquiere importancia porque se considera que representa la verdadera distribución de la población de la que se extrae la muestra. Pero la derivación de una curva suave ampliando la muestra es generalmente una imposibilidad práctica. Lo que solemos hacer, es aproximar la distribución de la población sobre la base de los datos de la muestra, suavizando las puntas del Polígono de Frecuencia, dibujando a mano o introduciendo una curva suave a los datos de la muestra con alguna fórmula matemática.

Debido a la sorprendente libertad para ajustar la curva, la Curva Suave debe presentarse siempre con el Histograma.

Son llamadas alternativamente Modelos de Población, porque describen las características importantes de las distribuciones de población.


Estas generalizaciones son de gran utilidad en el análisis estadístico porque proporcionan métodos simplificados de describir las características básicas de las poblaciones.

Otras razones de interés por los Modelos de Población:

- 1- Son necesarios para la toma de decisiones.
- 2- Las inferencias estadísticas a menudo requieren que conozcamos Modelos de Población.
- 3- Un Modelo de Población, estando representado por una curva suave, a veces se presta más fácilmente a un tratamiento matemático.

Algunos Modelos de Población son:

a)




Tiene forma de campana, las densidades de frecuencia más grandes están en el centro. Hay densidades muy pequeñas en ambos extremos. Es una Distribución Simétrica, llamada Curva de Distribución Normal o Curva Normal.

Ejemplo: Estatura, Inteligencia.



b)




**Distribución Bimodal.** Significa que tiene dos picos. Este caso de distribución aparece cuando una población contiene ciertos elementos que pueden ser divididos en dos clases que difieren entre sí en las características que se miden. La población no es homogénea.


Ejemplo:

Saldos de depósitos a la vista. Un pico destacado se encuentra en un valor relativamente bajo para los saldos mantenidos por unidades de consumo y otro pico distinto, para un valor relativamente alto para saldos mantenidos por empresas comerciales.

c)



d)



**Modelos de Distribuciones Asimétricas.** Generalmente tienen un solo pico situado en la parte inferior o superior de la curva.

Cuando la cola más larga está a la derecha (c), la distribución es asimétrica derecha o positivamente asimétrica.

Ejemplo:


Distribución de sueldos, indicando que algunos empleados (relativamente pocos en comparación con el grupo general) reciben sueldos más altos que los recibidos por la mayoría de los empleados.

Cuando la cola más larga está a la izquierda (d), la distribución es asimétrica izquierda o negativamente asimétrica.



Ejemplo:


Describe bien una población cuyas variables tienen un límite superior. El límite superior de la razón de costo de ventas (Costo de Ventas/Ventas), sería la unidad, o 100x100.



Describe una distribución que contienen predominantemente valores bajos y altos, siendo relativamente escasos los valores intermedios.

Ejemplo:

La distribución de las naciones del mundo según sus etapas de desarrollo económico revelaría abultamientos en dos extremos, con solo unos pocos en las etapas intermedias.



Curva en forma de J o J invertida, en que las frecuencias de ocurrencia aumentan o disminuyen continuamente a lo largo de la escala horizontal.

Ejemplo:

Distribución de corporaciones clasificadas según el tamaño del activo.

Distribución de quiebras comerciales con el eje  $x$  como tiempo de operación.

Si bien la mayor parte de las veces no conocemos las verdaderas distribuciones de población, podemos aproximar sus modelos trazando una curva suave a los datos de la muestra o por puro razonamiento deductivo.



### Distribuciones Relativas De Frecuencias

El gráfico de una distribución relativa (Histograma, Polígono, Curva Suave), se presta más fácilmente a la comparación de diferentes distribuciones, especialmente si difieren mucho en el número total de observaciones.

#### Ejemplo:

Distribución de Médicos y Abogados según ingresos diarios medios.

| <b>Ingresos en U\$S</b> | <b>Médicos</b>          |                           | <b>Abogados</b>         |                           |
|-------------------------|-------------------------|---------------------------|-------------------------|---------------------------|
|                         | <b><math>n_i</math></b> | <b><math>n_i/n</math></b> | <b><math>n_i</math></b> | <b><math>n_i/n</math></b> |
| 20-30                   | 0                       | 0,000                     | 11                      | 0,003                     |
| 30-40                   | 0                       | 0,000                     | 135                     | 0,042                     |
| 40-50                   | 1                       | 0,001                     | 247                     | 0,077                     |
| 50-60                   | 24                      | 0,024                     | 466                     | 0,145                     |
| 60-70                   | 150                     | 0,150                     | 658                     | 0,205                     |
| 70-80                   | 322                     | 0,322                     | 596                     | 0,185                     |
| 80-90                   | 185                     | 0,185                     | 579                     | 0,180                     |
| 90-100                  | 120                     | 0,120                     | 379                     | 0,118                     |
| 100-110                 | 78                      | 0,078                     | 115                     | 0,036                     |
| 110-120                 | 66                      | 0,066                     | 25                      | 0,008                     |
| 120-130                 | 22                      | 0,022                     | 3                       | 0,001                     |
| 130-140                 | 17                      | 0,017                     | 0                       | 0,000                     |
| 140-150                 | 15                      | 0,015                     | 0                       | 0,000                     |
| <b>TOTAL</b>            | <b>1000</b>             | <b>1</b>                  | <b>3214</b>             | <b>1</b>                  |




GRÁFICO I




GRÁFICO II

Es muy difícil descubrir en el Gráfico I, las similitudes o diferencias entre las dos distribuciones. Más grave es el hecho de que pueden obtenerse algunas impresiones incorrectas de ellas.

Pero cuando se consultan los polígonos de las dos distribuciones relativas pueden extraerse varias conclusiones fácil y precisamente:

- 1- La distribución para los abogados tiende a localizarse en valores más bajos que para los médicos.
- 2- Ambas distribuciones son positivamente asimétricas, pero el grado de asimetría para los médicos es mayor.
- 3- Aunque la distribución de los médicos está más compactamente distribuida alrededor del pico, la de los abogados semeja una cima plana.
- 4- Una mayor proporción de médicos que de abogados tienen ingresos medios entre U\$S 60 y U\$S 100. Una mayor proporción de médicos tienen ingresos medios diarios inferiores a U\$S 60, mientras que una mayor proporción de médicos que de abogados tienen ingresos medios diarios superiores a U\$S 100.

La comparación de frecuencias relativas resulta aún más reveladora cuando tratamos distribuciones cuyos valores mínimo y máximo, o ambos, difieren mucho entre sí.

#### 7.2.4. Diagrama escalonado

Representa a una distribución de frecuencias acumuladas mediante una serie de líneas horizontales trazadas en las correspondientes clases a la altura de las respectivas frecuencias, con las coordenadas que presentan las escalas de la misma forma que para los Histogramas. Los puntos finales de las líneas horizontales pueden ser unidos o no por líneas verticales.






### Ejemplo:


Utilizaremos los datos dados para la construcción del Histograma

| $y'_{i-1} - y'_i$ | $y_i$ | $N_i$ | $H$  |
|-------------------|-------|-------|------|
| 45-55             | 50    | 2     | 0,10 |
| 55-65             | 60    | 6     | 0,30 |
| 65-75             | 70    | 13    | 0,65 |
| 75-85             | 80    | 17    | 0,85 |
| 85-95             | 90    | 20    | 1    |



*Diagrama Escalonado*

Utilizando Excel, la gráfica es la siguiente:



*Diagrama Escalonado*



### 7.2.5. Ojiva

Es un polígono que representa una distribución acumulada en forma de un diagrama de líneas.


Puede ser:

- Ojiva Mayor que
- Ojiva Menor que

En el caso de “Menor que”, las frecuencias son acumuladas usando límites de clase superior,  $y'_i$ .

En el caso de “Mayor que”, las frecuencias son acumuladas usando los límites de clase inferior,  $y_{i-1}$ .

| $y'_{i-1} - y'_i$ | $y_i$ | $N_i$ |    | $H$  |       |
|-------------------|-------|-------|----|------|-------|
|                   |       | <     | >  | <    | >     |
| 45-55             | 50    | 2     | 20 | 0,10 | 20/20 |
| 55-65             | 60    | 6     | 18 | 0,30 | 18/20 |
| 65-75             | 70    | 13    | 14 | 0,65 | 14/20 |
| 75-85             | 80    | 17    | 7  | 0,85 | 7/20  |
| 85-95             | 90    | 20    | 3  | 1    | 3/20  |



Una ojiva se usa principalmente para interpolaciones, que pueden hacerse de dos modos:

- 1- Menor que: Si se escoge un punto de la escala horizontal, el número o proporción correspondiente de observaciones en la distribución cuyos valores son iguales o menores que el valor indicado por el punto escogido puede encontrarse en la escala vertical.



Por ejemplo, si escogemos el punto 60 de la escala horizontal, trazamos una línea vertical hasta cortar la ojiva y de esta intersección trazamos una línea horizontal a la escala vertical de la izquierda, obtenemos el valor 4. Esto significa que aproximadamente 4 observaciones de la muestra tienen valores iguales o menores de 60.

2- Mayor que: Esta vez nos desplazamos del eje vertical al eje horizontal para hallar el valor debajo del cual encontraremos un número, o proporción dado de observaciones. Supongamos que trazamos una línea horizontal desde 10 para que corte la ojiva y, luego, bajamos una perpendicular de la intersección a la escala horizontal (70).


Esto significa que 10 observaciones de la muestra tienen valores iguales o menores de 70 (o también 10 tienen valores iguales o mayores de 70).

#### 7.2.6. Curva Acumulativa Suavizada


También el Diagrama Escalonado o una Ojiva pueden ser suavizados para representar una Distribución de Población.

Formas:

a- Distribución Uniforme




b- Distribución en forma de campana






### c- Distribuciones Positivamente Asimétricas



### d- Distribuciones Negativamente Asimétricas



## 7.3 Gráficos Especiales

### 7.3.1. Distribuciones Categóricas


#### 7.3.1.1. Diagrama de Barras Horizontales

La escala horizontal mide la frecuencia, absoluta o relativa, de cada categoría. La longitud de cada barra es la frecuencia de dicha categoría. Los anchos de las barras son enteramente arbitrarios y no tienen significado práctico. Las barras pueden ser verticales, en vez de horizontales, con tal que, por supuesto, los ejes sean apropiadamente definidos.

Consideraremos el ejemplo sobre la “*Opinión sobre la Protección de la Policía y los Bomberos*”:

| <i>Respuestas</i>          | <i>n</i>   | <i>%</i>      |
|----------------------------|------------|---------------|
| <i>Si</i>                  | 80         | 19,09         |
| <i>No</i>                  | 293        | 69,93         |
| <i>No sabe/No contesta</i> | 46         | 10,98         |
|                            | <b>419</b> | <b>100,00</b> |


Haciendo uso de la planilla de cálculo Excel, obtenemos la siguiente gráfica:



### 7.3.1.2. *Gráfica de Barras de Componentes de Porcentajes*


También llamado Barra Porcentual, se representa mediante un rectángulo horizontal, donde la superficie del rectángulo representa el 100% del fenómeno analizado.

Lo graficaremos a través de una planilla de cálculo, encontrando:



### 7.3.1.3 *Diagrama de Pastel o Círculo Radiado*

También indica porcentajes del fenómeno estudiado y para su construcción utilizaremos los datos dados en el ejemplo anterior. Utilizando una planilla de cálculo obtenemos:



### Ejemplo:

Se está analizando la aplicación de los Ingresos de una Universidad Estatal y de una Universidad Privada.

Supongamos que los Ingresos de la Universidad Estatal son de \$10.000, distribuyéndose de la siguiente manera: Sueldos de Docentes: \$3000; Sueldos de No Docentes: \$2000; y Otros Gastos: \$5000, y que los Ingresos de la Universidad Privada son de \$15000, distribuyéndose de la siguiente manera: Sueldos de Docentes: \$3500; Sueldos de No Docentes: \$4000; y Otros Gastos: \$5500.



Para graficar la anterior información, construiremos dos Barras, una para la Universidad Estatal y la otra para la Universidad Privada.

#### *Universidad Estatal*

| <i>Aplicación de Ingresos<br/>(1)</i> |              | <i>Porcentaje<br/>(2)</i> |
|---------------------------------------|--------------|---------------------------|
| <i>Sueldos Docentes</i>               | <i>3000</i>  | <i>30</i>                 |
| <i>Sueldos No Docentes</i>            | <i>2000</i>  | <i>20</i>                 |
| <i>Otros</i>                          | <i>5000</i>  | <i>50</i>                 |
| <i>Total</i>                          | <i>10000</i> | <i>100</i>                |

#### *Universidad Privada*

| <i>Aplicación de Ingresos<br/>(1)</i> |              | <i>Porcentaje<br/>(2)</i> |
|---------------------------------------|--------------|---------------------------|
| <i>Sueldos Docentes</i>               | <i>5500</i>  | <i>37</i>                 |
| <i>Sueldos No Docentes</i>            | <i>4000</i>  | <i>26</i>                 |
| <i>Otros</i>                          | <i>5500</i>  | <i>37</i>                 |
| <i>Total</i>                          | <i>15000</i> | <i>100</i>                |





Luego, podemos comparar dentro de cada Barra y entre Barras. Así, observamos que en la Universidad Privada es mayor el porcentaje de los Ingresos destinados a Sueldos Docentes y No Docentes y menor el destinado a otros gastos, en comparación con la Universidad Estatal. Por otro lado, la Universidad Estatal aplica iguales porcentajes a sueldos que a gastos.

Ahora, construiremos el círculo radiado

| Aplicación de Ingresos<br>(1) |       | Porcentaje<br>(2) |
|-------------------------------|-------|-------------------|
| Sueldos Docentes              | 3000  | 30                |
| Sueldos No Docentes           | 2000  | 20                |
| Otros                         | 5000  | 50                |
| Total                         | 10000 | 100               |



Haciendo uso de la Planilla Excel:







## CAPITULO N.º 2 Medidas Descriptivas

---

### Contenidos

#### **1- Parámetros y Estadísticos**

#### **2- Medidas de centralidad y de posición**

##### **2.1. Media aritmética:**

*Simbología. Definición. Formas de cálculo para series simples y distribuciones de frecuencias en lista. Interpretación. Propiedades.*

##### **2.2. Mediana:**

*Simbología. Definición. Formas de cálculo para series simples y distribuciones de frecuencias en lista. Interpretación. Propiedad.*

##### **2.3. Moda, modo o valor modal:**

*Simbología. Definición. Formas de cálculo para series simples y distribuciones de frecuencias en lista. Interpretación.*

##### **2.4. Fractiles:**

*Cuartiles, deciles y percentiles simbología. Definición. Formas de cálculo para series simples y distribuciones de frecuencias en lista. Interpretaciones.*

#### **3. Medidas de asimetría**

*Simetría. Asimetría positiva o derecha. Asimetría negativa o izquierda.*

#### **4- Medidas de dispersión o de concentración**

##### **4.1. Recorrido:**

*Simbología. Definición. Formas de cálculo para series simples y distribuciones de frecuencias en lista.*

##### **4.2. Desviación media:**

*Simbología. Definición. Formas de cálculo para series simples y distribuciones de frecuencias en lista.*

##### **4.3. Varianza:**

*Simbología. Definición. Formas de cálculo para series simples y distribuciones de frecuencias en lista. Propiedades.*

##### **4.4. Desviación estándar:**

*Simbología. Definición. Formas de cálculo para series simples y distribuciones de frecuencias en lista. Propiedades.*

##### **4.5. Coeficiente de variación:**

*Simbología. Definición. Formas de cálculo para series simples y distribuciones de frecuencias en lista.*

#### **5- Medidas de apuntamiento o puntiagudez** *Platicúrtica. Mesocúrtica. Leptocúrtica.*



## 1- PARÁMETROS Y ESTADÍSTICOS

Se expuso cómo podían ser reducidos los datos muestrales o poblacionales a forma compacta, comprensible y comunicable a través de las distribuciones de frecuencias. Esto no es sólo un método para organizar datos, sino también una medida descriptiva del modelo de distribución de una variable. Realmente, puede ser considerada como un conjunto de medidas descriptivas, porque cada número que muestra la frecuencia (o densidad) de observaciones de una clase, es una estadística. Pero a menudo se necesitan medidas descriptivas en forma de números que pueden concentrar mejor la atención en varias propiedades de un conjunto de datos que se investiga.

Si estas medidas de resumen descriptivas se calculan con una *Muestra* de datos se llaman *Estadísticos, Estadísticas o Estadígrafos*. Si estas medidas descriptivas se calculan a partir de toda una *Población* de datos, se llaman *Parámetros*.

Estadísticas y parámetros son calculados con las mismas ecuaciones, por lo tanto, definiremos que:

- 1- Las variables que corresponden a una *Población* se representarán por mayúsculas, tales como X, Y, Z; y las que corresponden a una muestra por letras minúsculas, tales como x, y, z.
- 2- Los tamaños de *Población Y Muestra* se representarán por *N* y *n*, respectivamente.
- 3- Los parámetros se representarán con letras mayúsculas, tales como  $\bar{X}$  o bien  $M(X)$ , para la media de población; mientras que las estadísticas por letras minúsculas, tales como  $\bar{x}$  o bien  $M(x)$ , para la media de la muestra.

### En Resumen

| <i>Concepto</i>                  | <i>Población</i> | <i>Muestra</i>   |
|----------------------------------|------------------|------------------|
| <i>Variables</i>                 | <i>X, Y, Z</i>   | <i>x, y, z</i>   |
| <i>Cantidad de Observaciones</i> | <i>N</i>         | <i>n</i>         |
| <i>Media</i>                     | $\bar{X} = M(X)$ | $\bar{x} = M(x)$ |

Como por lo general, trabajaremos con muestras, la preferencia será por los estadísticos.

En términos de análisis estadístico y de aplicación, nos interesan cuatro propiedades básicas, que a menudo son suficientes para caracterizar las distribuciones de frecuencias unidimensionales.



#### Medidas De Centralidad y Posición

*Se Refieren Al Valor De La Variable  
Que Representa Al Conjunto De Datos.*

*Población: Parámetros De Posición y centralidad  
Muestra: Estadísticos De Posición y centralidad*

#### Medidas De Dispersión o De Concentración

*Se Refieren Al Grado De Variación De Los Valores Individuales  
Alrededor Del Centro De La Distribución, o A La Tendencia De Los  
Valores Individuales A Desviarse De La Medida De Tendencia Central.*

*Población: Parámetros De Dispersión  
Muestra: Estadísticos De Dispersión*

#### Medidas De Asimetría

*Se Refieren A La Falta De Asimetría De Ambos Lados Del Pico, Es Decir,  
Del Punto Con Más Alta Densidad De Frecuencia, De Una Distribución.*

*Población: Parámetros De Asimetría  
Muestra: Estadísticos De Asimetría*

#### Medidas De Puntigudez

*Se Refieren Al Grado De Variación, o La Velocidad Con Que Sube y Baja La  
Distribución De Izquierda A Derecha.*

*Población: Parámetros De Puntigudez  
Muestra: Estadísticos De Puntigudez*



Desarrollaremos seguidamente, cada una de estas medidas, para el caso de trabajar con muestras, recordando que para la población tendrán el mismo tratamiento, sólo que las simbolizaremos con letras mayúsculas.

## **2. Medidas de Centralidad**

Son valores típicos, en el sentido que se emplean para representar a todos los valores individuales de una serie o de una variable.

No pasan de ser un valor más de la variable, por lo tanto, tendrán las mismas dimensiones que ella.

Deberán tenerse en cuenta los siguientes aspectos:

- a) Deben definirse rigurosamente y no ser susceptibles de diferentes interpretaciones.
- b) Debe basarse en todas las observaciones, de lo contrario no sería una característica de toda la distribución.
- c) Que sea claro y sencillo en su estructura.
- d) Que pueda calcularse con facilidad y rapidez.
- e) Que esté influenciado lo menos posible por “fluctuaciones muestrales”.
- f) Se preste fácilmente al cálculo algebraico.

### **2.1. Media Aritmética**

Indica la localización del centro de la distribución, o la medida de tendencia central.

#### *Definición*

Se define y calcula dividiendo la suma de los valores de la variable por el número de observaciones.

#### *Simbología*

|           |                       |
|-----------|-----------------------|
| Población | $M(X) = \overline{X}$ |
| Muestra   | $M(x) = \overline{x}$ |

#### *Formas de Cálculo*

##### *a) Series Simples o Datos No Agrupados*

$$M(x) = \overline{x} = \frac{x_1 + x_2 + \dots + x_n}{n} = \frac{\sum_{i=1}^n x_i}{n}$$



### Ejemplo:

Utilizaremos el mismo ejemplo dado para series simples, es decir que consideraremos el número de hijos en 10 familias observadas.

$$n = 10$$

$x_i$  = número de hijos por familia

$$x_1 = 2; x_2 = 1; x_3 = 3; x_4 = 1; x_5 = 2; x_6 = 1; x_7 = 3; x_8 = 0; x_9 = 2; x_{10} = 1$$

$$\bar{x} = \frac{\sum_{i=1}^{10} x_i}{10} = \frac{x_1 + x_2 + \dots + x_{10}}{10} = \frac{2+1+3+1+2+1+3+0+2+1}{10} = \frac{16}{10} = 1,6$$

$$\bar{x} = 1,6 \text{ hijos}$$

### b) Datos Agrupados

#### b.1) Distribuciones de Frecuencias en Lista

$$M(y) = \bar{y} = \frac{y_1 n_1 + y_2 n_2 + \dots + y_m n_m}{n} = \frac{\sum_{i=1}^m y_i n_i}{n}$$

O bien, teniendo en cuenta que  $\frac{n_i}{n} = h_i$ , o sea considerando la frecuencia relativa:

$$M(y) = \bar{y} = y_1 h_1 + y_2 h_2 + \dots + y_m h_m = \sum_{i=1}^m y_i h_i$$

### Ejemplo:

Considerando el ejemplo anterior, podemos construir la siguiente tabla:

| $y_i$ | $n_i$ | $h_i$ | $y_i n_i$        | $y_i h_i$              |
|-------|-------|-------|------------------|------------------------|
| 0     | 1     | 0,10  | $0 \times 1 = 0$ | $0 \times 0,10 = 0$    |
| 1     | 4     | 0,40  | $1 \times 4 = 4$ | $1 \times 0,40 = 0,40$ |
| 2     | 3     | 0,30  | $2 \times 3 = 6$ | $2 \times 0,30 = 0,60$ |
| 3     | 2     | 0,20  | $3 \times 2 = 6$ | $3 \times 0,20 = 0,60$ |
|       | 10    | 1     | 16               | 1,60                   |

Utilizando cualquiera de las fórmulas dadas:

$$M(y) = \bar{y} = \frac{y_1 n_1 + y_2 n_2 + y_3 n_3 + y_4 n_4}{n} = \frac{\sum_{i=1}^4 y_i n_i}{n} = \frac{16}{10} = 1,6 \text{ hijos}$$

$$M(y) = \bar{y} = y_1 h_1 + y_2 h_2 + y_3 h_3 + y_4 h_4 = \sum_{i=1}^4 y_i h_i = 1,6 \text{ hijos}$$



Los resultados que se obtienen con a) y b.1) son idénticos, lo cual es lógico ya que en el caso de la tabla de distribución de frecuencias, sólo hemos agrupado a aquellos valores que se repiten. Luego, a) es un caso particular, donde  $n_i$  es igual a 1.

### Propiedades

1- La suma de las desviaciones con respecto a la media aritmética es igual a 0, cualquiera sea la distribución. Cuando decimos sumas, es necesario considerar las desviaciones tantas veces como se presenten.

$$\sum_{i=1}^m (y_i - \bar{y}) n_i = 0$$

#### Ejemplo

| $y_i$ | $n_i$ | $y_i - \bar{y}$ | $(y_i - \bar{y}) n_i$                  |
|-------|-------|-----------------|----------------------------------------|
| 0     | 1     | -1,60           | -1,60                                  |
| 1     | 4     | -0,60           | -2,40                                  |
| 2     | 3     | 0,40            | 1,20                                   |
| 3     | 2     | 1,40            | 2,80                                   |
|       | 10    |                 | $\sum_{i=1}^m (y_i - \bar{y}) n_i = 0$ |

2- La suma de los cuadrados de las desviaciones es mínima cuando dichas desviaciones son obtenidas con respecto a la media aritmética.

$$\sum_{i=1}^m (y_i - \bar{y})^2 n_i < \sum_{i=1}^m (y_i - a)^2 n_i$$

Donde  $a$  es cualquier valor distinto de  $\bar{y}$ .

#### Ejemplo:

Consideraremos  $a = 1$  y  $\bar{y} = 1,6$

| $y_i$ | $n_i$ | $y_i - \bar{y}$ | $(y_i - \bar{y})^2 n_i$                     | $y_i - a$ | $(y_i - a)^2 n_i$                   |
|-------|-------|-----------------|---------------------------------------------|-----------|-------------------------------------|
| 0     | 1     | -1,60           | 2,56                                        | -1        | 1                                   |
| 1     | 4     | -0,60           | 1,44                                        | 0         | 0                                   |
| 2     | 3     | 0,40            | 0,48                                        | 1         | 3                                   |
| 3     | 2     | 1,40            | 3,92                                        | 2         | 8                                   |
|       | 10    |                 | $\sum_{i=1}^m (y_i - \bar{y})^2 n_i = 8,40$ |           | $\sum_{i=1}^m (y_i - a)^2 n_i = 12$ |

3- La media de una muestra es igual a la media ponderada de las submuestras, siendo las ponderaciones los tamaños de dichas sub muestras.

$$\bar{y} = \frac{\bar{y}_{(1)} n_{(1)} + \bar{y}_{(2)} n_{(2)} + \bar{y}_{(3)} n_{(3)} + \dots + \bar{y}_{(k)} n_{(k)}}{n}$$



Ejemplo:

| $y_i$ | $n_i$     |
|-------|-----------|
| 0     | 1         |
| 1     | 4         |
| 2     | 3         |
| 3     | 2         |
|       | <b>10</b> |

Donde  $\bar{y} = 1,6$

Supongamos, además:

$$n_{(1)} = 4$$

$$y_1 = 0; y_2 = 1; y_3 = 1; y_4 = 2$$

$$n_{(2)} = 6$$

$$y_1 = 1; y_2 = 1; y_3 = 2; y_4 = 2; y_{(5)} = 3; y_{(6)} = 3$$

En base a ello, calculamos:

$$\bar{y}_{(1)} = \frac{0+1+1+2}{4} = 1$$

$$\bar{y}_{(2)} = \frac{1+1+2+2+3+3}{6} = \frac{12}{6} = 2$$

Entonces:

$$\bar{y} = \frac{\bar{y}_{(1)} n_{(1)} + \bar{y}_{(2)} n_{(2)}}{n} = \frac{1(4) + 2(6)}{10} = \frac{4+12}{10} = \frac{16}{10} = \underline{1,6}$$

Otra aplicación de esta propiedad podemos encontrarla, considerando una Carrera de 5 años de duración, en donde contamos con los Promedios de notas por año, de materias aprobadas. ¿Cuál es el promedio de la Carrera?

| <i>Años de una carrera</i> | <i>Promedios anuales de notas de materias aprobadas</i><br>$\bar{y}_i$ | <i>Cantidad de materias aprobadas</i><br>$n_i$ | $\bar{y}_i n_i$ |
|----------------------------|------------------------------------------------------------------------|------------------------------------------------|-----------------|
| 1º                         | 7,54                                                                   | 6                                              | 45,24           |
| 2º                         | 7,98                                                                   | 7                                              | 55,86           |
| 3º                         | 8,45                                                                   | 8                                              | 67,6            |
| 4º                         | 9,09                                                                   | 10                                             | 90,9            |
| 5º                         | 9,45                                                                   | 12                                             | 113,4           |
|                            |                                                                        | <b>43</b>                                      | <b>373</b>      |

Luego:  $\bar{y} = \frac{373}{43} = 8,67$

4- La media aritmética de una constante es igual a dicha constante.

$$M(k) = k$$

Si  $y_i = k \rightarrow \bar{y} = k$   
 $i=1, 2, \dots, n$



Ejemplo:

$$y_i = 6, 6, 6, 6, 6$$

| $y_i$ | $n_i$ | $y_i n_i$ |
|-------|-------|-----------|
| 6     | 5     | 30        |
|       |       | <b>30</b> |

$$\bar{y} = \frac{\sum_{i=1}^5 y_i n_i}{n} = \frac{30}{5} = 6$$

5- La media aritmética del producto de una constante por una variable es igual al producto de la constante por la media aritmética de la variable.

$$M(y k) = k \bar{y}$$

Ejemplo:

| $y_i$<br><b>Salarios</b> | $n_i$     | $y_i n_i$   |
|--------------------------|-----------|-------------|
| 200                      | 4         | 800         |
| 300                      | 4         | 1200        |
| 400                      | 2         | 800         |
|                          | <b>10</b> | <b>2800</b> |

Calculamos:

$$\bar{y} = \frac{\sum_{i=1}^3 y_i n_i}{n} = \frac{2800}{10} = 280$$

Luego, se incrementan al doble todos los sueldos, entonces definimos  $y'_i = 2y_i$

| $y'_i = 2y_i$ | $n_i$     | $y'_i n_i$  |
|---------------|-----------|-------------|
| 400           | 4         | 1600        |
| 600           | 4         | 2400        |
| 800           | 2         | 1600        |
|               | <b>10</b> | <b>5600</b> |

Y calculamos:

$$\bar{y}' = \frac{\sum_{i=1}^3 y'_i n_i}{n} = \frac{5600}{10} = 560$$

Entonces la media de esta nueva variable es igual a 560, resultado al que arribamos por aplicación de la propiedad:

$$M(k y) = M(2y) = 2 M(Y) = 2 \times 280 = 560$$

6- La media aritmética de la suma algebraica de dos o más variables es igual a la suma algebraica de las medias aritméticas de dichas variables:





$$M\left[\sum_{j=1}^k x_{(j)i}\right] = \sum_{j=1}^k M(x_j)_i$$

Nota: no es extensible al multiplicatorio.

Ejemplo:

|                         |         |                                                                         |
|-------------------------|---------|-------------------------------------------------------------------------|
| $x_{(1)i}$              | 1 2 3 2 | $M[x_{(1)i}] = \frac{\sum_{i=1}^4 x_{(1)i}}{4} = \frac{1+2+3+2}{4} = 2$ |
| $x_{(2)i}$              | 1 2 2 3 | $M[x_{(2)i}] = \frac{\sum_{i=1}^4 x_{(2)i}}{4} = \frac{1+2+2+3}{4} = 2$ |
| $x_{(3)i}$              | 2 1 3 2 | $M[x_{(3)i}] = \frac{\sum_{i=1}^4 x_{(3)i}}{4} = \frac{2+1+3+2}{4} = 2$ |
| $\sum_{j=1}^3 x_{(j)i}$ | 4 5 8 7 | $\sum_{j=1}^3 x_{(j)i} = 6$                                             |

$$M\left[\sum_{j=1}^3 x_{(j)i}\right] = \frac{\sum_{i=1}^4 \left[\sum_{j=1}^3 x_{(j)i}\right]}{4} = \frac{4+5+8+7}{4} = \frac{24}{4} = 6$$

7- Se puede utilizar para estimar una cantidad total en una población. Por ejemplo, la tarifa media de salario por hora para una muestra de  $n=6$  secretarias ejecutivas es de \$8,00. Si en esta compañía hay 200 secretarias, el costo total por hora de la mano de obra secretarial se calcula como:

$\sum x = N \bar{x}$  Donde N: Tamaño de la Población y  $\bar{x}$  : media aritmética de la muestra

$$\sum x = 200 \times 8 = 1.600$$

Llamamos “Total” a la expresión  $\sum x$

8- Su cálculo se base en cada observación, por lo tanto la media se ve afectada por cualquier valor o valores extremos.

Ejemplo:

$$y_1 = 2 ; y_2 = 7 ; y_3 = 8 ; y_4 = 7 ; y_{(5)} = 9$$

$$\bar{y} = \frac{2+7+8+7+9}{5} = 6,6$$

Se observa, que un solo valor extremadamente pequeño da por resultado una gran reducción en  $\bar{y}$ . Por supuesto, ocurriría el caso inverso si el valor extremo fuera mucho mayor que las otras observaciones.



## 2.2. Mediana

### Definición

Es el valor central de la variable cuando los datos están ordenados por su magnitud, siendo indistinto que el ordenamiento sea ascendente o descendente.

Dicho de otra manera, es el valor de la variable que supera a no más de la mitad de las observaciones y es superado por no más de la mitad de las observaciones.

### Simbología

|           |      |
|-----------|------|
| Población | $Me$ |
| Muestra   | $me$ |

Presenta los siguientes inconvenientes:

- Es necesario ordenar previamente los elementos por su magnitud, tarea que suele insumir mucho tiempo.
- Está influenciada solamente por el número de elementos, no por el valor de los mismos.
- Se usa generalmente cuando se trata de atributos.

### Formas de Cálculo

#### a) Series Simples o Datos No Agrupados

1. Ordenar los datos por su magnitud de menor a mayor o viceversa.
2. Encontrar el orden de la mediana, o sea su posición en la serie, a través de:

$$\left( \frac{n+1}{2} \right)^{\circ}$$

Se pueden presentar dos casos, en función de si la cantidad de datos es impar o par, entonces:

#### a.1) Número de Datos Impar

#### Ejemplo:

$$y_i = 1, 4, 10, 8, 10$$

1. Ordenamos por su magnitud, en este caso de menor a mayor: 1, 4, 8, 10, 10
2. Establecemos la posición que en la serie tendrá el valor de la mediana:

$$\left( \frac{n+1}{2} \right)^{\circ} = \left( \frac{5+1}{2} \right)^{\circ} = (3)^{\circ}$$

Entonces, la mediana es el valor de la variable que ocupa el tercer lugar, luego:

$$me = 8$$



Vemos que hay dos elementos (1,4) antes de la mediana y dos elementos (10,10) después de la mediana.

Ejemplo:

$$y_i = 1, 2, 3, 4, 5, 5, 5, 6, 7, 8, 9$$

$$\text{Entonces: } \left( \frac{n+1}{2} \right)^{\circ} = \left( \frac{11+1}{2} \right)^{\circ} = (6)^{\circ} \Rightarrow me = 5$$

Puede que la mediana tenga valores idénticos al suyo, a ambos lados. Con estas características se puede definir a la mediana como “Aquel valor de la variable que divide a la serie de tal forma que por lo menos el 50% de los valores sean menores o iguales a él, y por lo menos el 50% de los valores sean mayores o iguales a él”.

*a.2) Número de Datos Par*

No existe una mediana verdadera, ya que existen dos valores centrales de la variable que cumplen con la condición de la definición.

Por ello, se conviene que la mediana es igual al promedio de los dos valores centrales de la variable, luego de ordenarlos por su magnitud.

Ejemplo

$$y_i = 9, 6, 2, 5, 18, 12$$

- 1- Ordenamos: 2, 5, 6, 9, 12, 18
- 2- Determinamos el orden de la mediana

$$\left( \frac{n+1}{2} \right)^{\circ} = \left( \frac{6+1}{2} \right)^{\circ} = (3,5)^{\circ} \Rightarrow me = \frac{6+9}{2} = \frac{15}{2} = 7,5$$

*b) Datos Agrupados*

*b.1) Distribución de Frecuencias En Lista*

Vamos a llamar  $N_j$  a la primera frecuencia absoluta acumulada que supere a  $\frac{n}{2}$ . De tal manera que  $N_{j-1} \leq \frac{n}{2} \leq N_j$ .

Entonces, pueden presentarse dos casos:

$$\text{b.1.1)} \quad N_{j-1} < \frac{n}{2} \Rightarrow me = y_j$$



Donde  $y_j$  es el valor de  $y_i$ , que corresponde a la primera frecuencia absoluta acumulada que supera a  $\frac{n}{2}$  ( $N_j$ )

### Ejemplo

|           | $y_i$ | $n_i$ | $N_i$ |           |
|-----------|-------|-------|-------|-----------|
|           | 0     | 2     | 2     |           |
| $y_{j-1}$ | 1     | 4     | 6     | $N_{j-1}$ |
| $y_j$     | 2     | 6     | 12    | $N_j$     |
|           | 3     | 3     | 15    |           |
|           | 4     | 5     | 20    |           |
|           |       | 20    |       |           |

$$\frac{n}{2} = \frac{20}{2} = 10 \Rightarrow N_{j-1} < \frac{n}{2} \Rightarrow me = y_j = 2$$

Si transformamos los datos en una serie simple, y obtenemos el orden de la mediana, según vimos,  $\left(\frac{n+1}{2}\right)^o = \left(\frac{21}{2}\right)^o = (10,5)^o$


La mediana será el valor de la variable que ocupa el lugar 10,5, por lo tanto, resulta del promedio de los elementos centrales de la serie.

00 1111 2222 ↓ 22 333 44444

$$me = \frac{2+2}{2} = 2$$

Como puede observarse es idéntico al encontrado a través de la Distribución de Frecuencias.

Este valor, puede también determinarse gráficamente, para lo cual debe utilizarse el Gráfico Acumulativo de Frecuencias, ya explicado. Una vez construido, se identifican los valores de  $N_j$ ,  $N_{j-1}$ , y  $\frac{n}{2}$ , en la ordenada, y se traza una horizontal a la altura de  $\frac{n}{2}$ , hasta intersectar el polígono y bajando la vertical, se obtiene el valor de la mediana, que en nuestro caso es 2.





$$b.1.2) \quad N_{j-1} = \frac{n}{2} \Rightarrow me = \frac{y_{j-1} + y_j}{2}$$

Donde todos los valores del intervalo cerrado  $y_{j-1} - y_j$  son valores que corresponden a la definición de mediana.

### Ejemplo

|           | $y_i$ | $n_i$ | $N_i$ |                         |
|-----------|-------|-------|-------|-------------------------|
|           | 0     | 2     | 2     |                         |
|           | 1     | 4     | 6     |                         |
| $y_{j-1}$ | 2     | 4     | 10    | $N_{j-1} = \frac{n}{2}$ |
| $y_j$     | 3     | 7     | 17    | $N_j$                   |
|           | 4     | 3     | 20    |                         |
|           |       | 20    |       |                         |


$$\frac{n}{2} = \frac{20}{2} = 10 \Rightarrow N_{j-1} = \frac{n}{2} \Rightarrow me = \frac{y_{j-1} + y_j}{2} = \frac{2+3}{2} = 2,5$$

Si trabajamos con serie simple, el orden de la misma es  $\left(\frac{n+1}{2}\right)^o = \left(\frac{21}{2}\right)^o = (10,5)^o$

00 1111 2222 ↓ 3333333 444

Entonces  $me = \frac{2+3}{2} = 2,5$ , igual que antes.

Gráficamente, también se utiliza el Gráfico Acumulativo de Frecuencias, con igual procedimiento que el aplicado en el caso anterior. De esta manera la  $me = 2,5$ .





Una ventaja definitiva del uso de la mediana en relación con la media, como medida representativa con datos agrupados, es que se puede tener aproximación a la mediana con la fórmula anterior, sin importar que la distribución de frecuencia tenga o no anchos iguales de intervalos de clase o clases con un extremo abierto.

### Interpretación

El 50% de los valores son menores a la mediana y el otro 50% son mayores a la mediana.

### Propiedades

La suma de los valores absolutos de las desviaciones con respecto a la mediana es mínima.

$$\sum_{i=1}^m |y_i - me| \leq \sum_{i=1}^m |y_i - a|$$

Donde  $a$  es un valor cualquiera.

Aplicación: Decisión sobre la localización óptima de una fábrica.

### Ejemplo:

Supongamos que una organización en cadena de restaurantes tiene siete de ellos en cierta carretera, como se indica en el cuadro:

| (1)     | (2) | De A | De B | De C | De D | De E | De F | De G |
|---------|-----|------|------|------|------|------|------|------|
| A       | 12  | 0    | 28   | 64   | 84   | 112  | 120  | 136  |
| B       | 40  | 28   | 0    | 36   | 56   | 84   | 92   | 108  |
| C       | 76  | 64   | 36   | 0    | 20   | 38   | 56   | 72   |
| D       | 96  | 84   | 56   | 20   | 0    | 28   | 36   | 52   |
| E       | 124 | 112  | 84   | 48   | 28   | 0    | 8    | 24   |
| F       | 132 | 120  | 92   | 56   | 36   | 8    | 0    | 16   |
| G       | 148 | 136  | 108  | 72   | 52   | 24   | 16   | 0    |
| Totales |     | 544  | 404  | 296  | 276  | 294  | 328  | 408  |

(1) Restaurante

(2) Distancia En Kilómetros De La Entrada Al Restaurante.

Diariamente, cada restaurante debe buscar alimentos frescos de un almacén central.

Además, supongamos que el servicio requiera dos camiones cada día, entonces para minimizar la distancia total de los siete restaurantes al almacén central, ¿dónde debe estar ubicado éste?

Recordando que las desviaciones absolutas con relación a la mediana es un mínimo, podemos decir fácilmente que el almacén central debe estar situado en el Restaurante “D” o en su vecindad. La distancia mediana del restaurante a la entrada de la carretera es de 96 km., y del restaurante “D” al recorrido total para reabastecer a cada restaurante una vez, se minimizaría en 276 km., en cada sentido. Si el almacén central está ubicado en cualquier otro punto, la suma de la distancia será mayor.

La mediana de la serie es “D” = 96 km., pues se trata de una serie impar, por lo que el valor de variable que ocupa el 4° lugar corresponde a la mediana.



### 2.3. Moda, Modo o Valor Modal

#### Definición

Es el valor más frecuente, más comúnmente observado en un conjunto de datos.

#### Simbología

|           |      |
|-----------|------|
| Población | $Md$ |
| Muestra   | $md$ |

Presenta los siguientes inconvenientes:

- Puede que dos o más valores se repitan un número iguales de veces. En tal situación, no hay forma lógica de determinar qué valor debe ser escogido como la moda.
- Puede que no hallemos ningún valor que aparezca más de una vez.
- Es un valor muy inestable, puede cambiar con el método de redondeo de los datos.

| <i>Peso Real</i>               | <i>Redondeo hasta el Kg. más próximo</i> | <i>Truncado</i>            |
|--------------------------------|------------------------------------------|----------------------------|
| 3,000                          | 3                                        | 3                          |
| 3,500                          | 4                                        | 3                          |
| 3,571                          | 4                                        | 3                          |
| 3,784                          | 4                                        | 3                          |
| 4,500                          | 5                                        | 4                          |
| 4,831                          | 5                                        | 4                          |
| 6,115                          | 6                                        | 6                          |
| 6,115                          | 6                                        | 6                          |
| <b><math>md = 6,115</math></b> | <b><math>md = 4</math></b>               | <b><math>md = 3</math></b> |

#### Formas de Cálculo

##### a) Series Simples o Datos No Agrupados

#### Ejemplos:

$x_i = 1, 4, 10, 8, 10$      **$md = 10$** , pues ocurre más veces

$x_i = 1, 3, 3, 7, 7, 8$      **$md = 3$**      **$md = 7$** , puesto que cada uno ocurre dos veces

$x_i = 1, 2, 4, 9$     No hay moda, puesto que ninguno de los valores ocurre más de una vez

##### b) Datos Agrupados

##### b.1) Distribuciones de Frecuencias en Lista

$$md = y_j \quad \text{Si se cumple que} \quad n_{j-1} < n_j > n_{j+1}$$




Con lo cual son valores de variable que presentan picos en sus frecuencias.

Hablando en sentido riguroso, cualquier valor se llama moda, si aparece más a menudo que cualquiera de los valores adyacentes. Sin embargo, mientras la frecuencia de los valores modales no sea igual, podríamos decidir escoger el valor con la frecuencia más alta como la moda para la serie.


Ejemplo:

| $y_i$ | $n_i$ | $n_{j-1} < n_j > n_{j+1} \Rightarrow md = 2$ |
|-------|-------|----------------------------------------------|
| 0     | 2     |                                              |
| 1     | 3     |                                              |
| 2     | 6     |                                              |
| 3     | 5     |                                              |
| 4     | 4     |                                              |


En una distribución de frecuencias de gran recorrido, pueden presentarse una o más modas, que corresponderán a uno o más máximos que se presenten, es decir, que pueden existir distribuciones:



Unimodal



Bimodal



Multimodal

Otros ejemplos:

1-

| $y_i$ | $n_i$ | $n_{j-1} < n_j > n_{j+1} \Rightarrow md = 1$ |
|-------|-------|----------------------------------------------|
| 0     | 2     |                                              |
| 1     | 3     |                                              |
| 2     | 1     | $n_{j-1} < n_j > n_{j+1} \Rightarrow md = 3$ |
| 3     | 5     |                                              |
| 4     | 2     |                                              |
| 5     | 1     |                                              |





2-

| $y_i$ | $n_i$ |             |
|-------|-------|-------------|
| 0     | 2     | No hay moda |
| 1     | 2     |             |
| 2     | 2     |             |

3-

| $y_i$ | $n_i$ |                                              |
|-------|-------|----------------------------------------------|
| 0     | 2     |                                              |
| 1     | 5     | $n_{j-1} < n_j > n_{j+1} \Rightarrow md = 1$ |
| 2     | 2     |                                              |
| 3     | 5     | $n_{j-1} < n_j > n_{j+1} \Rightarrow md = 3$ |
| 4     | 3     |                                              |
| 5     | 1     |                                              |

4-

| $y_i$ | $n_i$ |                                                                                        |
|-------|-------|----------------------------------------------------------------------------------------|
| 0     | 16    | $n_{j-1} < n_j > n_{j+1} \Rightarrow md = 0$ , ya que la frecuencia hacia arriba es 0. |
| 1     | 5     |                                                                                        |
| 2     | 4     |                                                                                        |
| 3     | 3     |                                                                                        |

5-

| $y_i$ | $n_i$ |                                                                                       |
|-------|-------|---------------------------------------------------------------------------------------|
| 0     | 4     |                                                                                       |
| 1     | 4     |                                                                                       |
| 2     | 3     |                                                                                       |
| 3     | 5     | $n_{j-1} < n_j > n_{j+1} \Rightarrow md = 3$                                          |
| 4     | 1     |                                                                                       |
| 5     | 9     | $n_{j-1} < n_j > n_{j+1} \Rightarrow md = 5$ , ya que la frecuencia hacia abajo es 0. |

En los dos últimos casos, la moda puede corresponder a valores extremos, y entonces difícilmente podría ser considerada como medida de tendencia central.



## 2.4. Fractiles (Medidas de Posición)

En una distribución de frecuencias, cierta cantidad de los datos cae en un fractil o por debajo de éste. Hemos definido anteriormente a la Mediana como el valor central de la variable una vez que los datos han sido ordenados por su magnitud, dividiendo de esta manera a la serie en dos partes iguales. Es decir, que la mediana, es el fractil que queda en medio, puesto que la mitad de los datos está por debajo de este valor y la otra mitad está por arriba de él.

Otros fractiles, como los Cuartiles, Deciles o Percentiles, se parecen mucho a la Mediana porque también subdividen una distribución de mediciones de acuerdo con la proporción de frecuencias observadas. Mientras que la Mediana divide a la distribución en dos mitades, los Cuartiles la dividen en cuatro cuartos, los Deciles la dividen en diez décimos y los Percentiles la dividen en cien partes.

Se emplean con más frecuencia en variables continuas, siempre que el número de intervalos sea grande y se desee obtener un promedio que corresponda a una determinada parte de la distribución.

### Cuartiles

Los cuartiles de una distribución son los valores de la variable que dividen a los datos (ordenados de menor a mayor) en cuatro partes iguales.

Para su cálculo procederemos de manera idéntica que para el cálculo de la Mediana, sólo que ahora dividiremos a la serie en cuatro partes iguales, de tal modo que cada parte contenga el mismo número de observaciones, es decir un 25%.

Los simbolizaremos por  $Q_k$  para  $k = 1, 2, 3$ , que indica el número de Cuartil

| <i>Símbolo</i> | <i>Nombre</i>                      | <i>Definición</i>                                                                                     |
|----------------|------------------------------------|-------------------------------------------------------------------------------------------------------|
| $Q_1$          | <i>Primer Cuartil</i>              | <i>Valor de la variable que supera al 25% de las observaciones y es superado por el 75% restante.</i> |
| $Q_2$          | <i>Segundo Cuartil<br/>Mediana</i> | <i>Valor de la variable que supera al 50% de las observaciones y es superado por el 50% restante.</i> |
| $Q_3$          | <i>Tercer Cuartil</i>              | <i>Valor de la variable que supera al 75% de las observaciones y es superado por el 25% restante.</i> |



## Formas de cálculo

### a) Datos no agrupados

| Cuartiles           | Orden de cada cuartil                                                                      |                                                                                                |
|---------------------|--------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------|
|                     | N° de datos Par                                                                            | N° de datos Impar                                                                              |
|                     | $\left[ k \left( \frac{n}{4} \right) \right]^{\circ}$                                      | $\left[ k \left( \frac{n+1}{4} \right) \right]^{\circ}$                                        |
| General             | K: Número de cuartil: 1, 2, 3                                                              |                                                                                                |
| 1° Cuartil<br>$Q_1$ | $\left[ 1 \left( \frac{n}{4} \right) \right]^{\circ}$                                      | $\left[ 1 \left( \frac{n+1}{4} \right) \right]^{\circ}$                                        |
| 2° Cuartil<br>$Q_2$ | $\left[ 2 \left( \frac{n}{4} \right) \right]^{\circ} = \left( \frac{n}{2} \right)^{\circ}$ | $\left[ 2 \left( \frac{n+1}{4} \right) \right]^{\circ} = \left( \frac{n+1}{2} \right)^{\circ}$ |
| 3° Cuartil<br>$Q_3$ | $\left[ 3 \left( \frac{n}{4} \right) \right]^{\circ}$                                      | $\left[ 3 \left( \frac{n+1}{4} \right) \right]^{\circ}$                                        |

### Ejemplo 1:

Supongamos que la altura de 8 árboles, ordenadas de menor a mayor son las siguientes:  
150 - 151- 152 - 154 - 155 - 156 - 157 - 159 cms.

#### 1- Determinación de $Q_1$

Determinamos el Orden:  $\left[ 1 \left( \frac{8}{4} \right) \right]^{\circ} = 2^{\circ}$

El primer cuartil,  $Q_1$ , es el valor de la variable que divide a la primera mitad de la serie en dos partes iguales. Luego:

$$Q_1 = \frac{151+152}{2} = 151,5$$

#### 2- Determinación de $Q_2$

Determinamos el Orden:  $\left[ 2 \left( \frac{8}{4} \right) \right]^{\circ} = 4^{\circ}$



El segundo cuartil,  $Q_2$  es el valor de la variable que divide a la serie en dos partes iguales. Luego:

$$Q_2 = \frac{154 + 155}{2} = 154,5$$

Obsérvese que la mediana de este conjunto de datos, es el valor de la variable que ocupa el siguiente el orden:

$$\left( \frac{n+1}{2} \right)^{\circ} = \left( \frac{8+1}{2} \right)^{\circ} = 4,5^{\circ}$$

Por lo tanto es el valor de la variable ubicado entre el 4° y 5° lugar, es decir  $Me = 154,5$  cms. Entonces  $Q_2$  es la Mediana.

### 3- Determinación de $Q_3$

Determinamos el Orden:  $\left[ 3 \left( \frac{8}{4} \right) \right]^{\circ} = 6^{\circ}$

El tercer cuartil,  $Q_3$  es el valor de la variable que divide a la segunda mitad en dos partes iguales. Luego:

$$Q_3 = \frac{156 + 157}{2} = 156,5$$

Resumiendo:

| 1º Cuarto     | 2º Cuarto           | 3º Cuarto     | 4º Cuarto |
|---------------|---------------------|---------------|-----------|
| 150 - 151     | 152 - 154           | 155 - 156     | 157 - 159 |
| $Q_1 = 151,5$ | $Q_2 = 154,5$<br>Me | $Q_3 = 156,5$ |           |

### Ejemplo 2:

Si ahora consideramos la altura de 9 árboles, ordenados de menor a mayor:

150 - 151 - 152 - 153 - 154 - 155 - 156 - 157 - 159 cms.

### 1- Determinación de $Q_1$

Determinamos el Orden:  $\left[ 1 \left( \frac{9+1}{4} \right) \right]^{\circ} = 2,5^{\circ}$

El primer cuartil,  $Q_1$ , es el valor de la variable que divide a la primera mitad de la serie en dos partes iguales. Luego:

$$Q_1 = \frac{151 + 152}{2} = 151,5$$



## 2- Determinación de $Q_2$

Determinamos el Orden:  $\left[ 2 \left( \frac{9+1}{4} \right) \right]^\circ = \left( \frac{9+1}{2} \right)^\circ = 5^\circ$

El segundo cuartil,  $Q_2$  es el valor de la variable que divide a la serie en dos partes iguales. Luego:

$$Q_2 = 154$$

Obsérvese que la mediana de este conjunto de datos es el valor de la variable que ocupa el siguiente el orden:

$$\left( \frac{n+1}{2} \right)^\circ = \left( \frac{9+1}{2} \right)^\circ = 5^\circ$$

Por lo tanto, es el valor de la variable ubicado en el  $5^\circ$  lugar, es decir  $Me = 154$  cm. Entonces  $Q_2$  es la Mediana.

## 3- Determinación de $Q_3$

Determinamos el Orden:  $\left[ 3 \left( \frac{9+1}{4} \right) \right]^\circ = 7,5^\circ$

El tercer cuartil,  $Q_3$  es el valor de la variable que divide a la segunda mitad en dos partes iguales. Luego:

$$Q_3 = \frac{156+157}{2} = 156,5$$

Resumiendo:

| 1º Cuarto | 2º Cuarto     |                   | 3º Cuarto | 4º Cuarto     |
|-----------|---------------|-------------------|-----------|---------------|
| 150 - 151 | 1525 - 153    | 154               | 155 - 156 | 157 - 158     |
|           | $Q_1 = 151,5$ | $Q_2 = 154$<br>Me |           | $Q_3 = 156,5$ |

## b) Datos Agrupados

Seguiremos igual procedimiento que para el cálculo de la mediana. Considerando ahora que para ubicar el orden de  $Q_1$  se debe considerar  $\frac{n}{4}$  y para ubicar el orden de  $Q_3$  se debe considerar  $3\frac{n}{4}$ .



b.1) Distribución de Frecuencias en Lista

| Cuartiles           | Formas de Cálculo                        |                                                              |
|---------------------|------------------------------------------|--------------------------------------------------------------|
| General             | $N_{j-1} < k \frac{n}{4}$                | $N_{j-1} = k \frac{n}{4}$                                    |
|                     | $Q_k = y_j$                              | $Q_k = \frac{y_{j-1} + y_j}{2}$                              |
|                     | K: Número de cuartil: 1, 2, 3            |                                                              |
| 1° Cuartil<br>$Q_1$ | $N_{j-1} < 1 \frac{n}{4}$<br>$Q_1 = y_j$ | $N_{j-1} = 1 \frac{n}{4}$<br>$Q_1 = \frac{y_{j-1} + y_j}{2}$ |
| 2° Cuartil<br>$Q_2$ | $N_{j-1} < 2 \frac{n}{4}$<br>$Q_2 = y_j$ | $N_{j-1} = 2 \frac{n}{4}$<br>$Q_2 = \frac{y_{j-1} + y_j}{2}$ |
| 3° Cuartil<br>$Q_3$ | $N_{j-1} < 3 \frac{n}{4}$<br>$Q_3 = y_j$ | $N_{j-1} = 3 \frac{n}{4}$<br>$Q_3 = \frac{y_{j-1} + y_j}{2}$ |

Ejemplo:

Tabla de frecuencias para el Número de hijos de 56 familias observadas

|       | Número de Hijos | $n$ | $N$ | $Q_1$     | $Q_3$     |
|-------|-----------------|-----|-----|-----------|-----------|
|       | 0               | 5   | 5   | $N_{j-1}$ |           |
| $Q_1$ | 1               | 11  | 16  | $N_j$     | $N_{j-1}$ |
| $Q_3$ | 2               | 35  | 51  |           | $N_j$     |
|       | 3               | 2   | 53  |           |           |
|       | 4               | 2   | 55  |           |           |
|       | 5               | 1   | 56  |           |           |
|       | Total           | 56  |     |           |           |

Cálculo del primer cuartil  $Q_1$

Orden:  $\frac{n}{4} = \frac{56}{4} = 14$



$$N_{j-1} = 5; \text{ por lo cual } N_{j-1} < \frac{n}{4} = 14$$

$$Q_1 = y_j = 1 \text{ Hijo}$$

Cálculo del tercer cuartil  $Q_3$

$$\text{Orden: } 3\frac{n}{4} = 3\frac{(56)}{4} = 42$$

$$N_{j-1} = 16$$

$$Q_3 = y_j = 2 \text{ Hijos}$$

### Deciles

En relación con los Deciles de una distribución, diremos que, como su nombre lo indica, son valores de la variable, que dividen al conjunto de observaciones (ordenadas de menor a mayor) en diez partes iguales. Tienen el mismo significado y la misma forma de cálculo que los cuartiles.

Los simbolizaremos por  $D_k$  para  $k = 1, 2, \dots, 9$  que indica el número de Decil

| Simbología              | Definición                                                                                                                |
|-------------------------|---------------------------------------------------------------------------------------------------------------------------|
| $D_1$                   | Valor de la variable que agrupa el 10% de los datos.<br>(10% de los datos a la izquierda y 90% de los datos a la derecha) |
| $D_2$                   | Valor de la variable que agrupa el 20% de los datos.                                                                      |
| $D_3$                   | Valor de la variable que agrupa el 30% de los datos.                                                                      |
| $D_4$                   | Valor de la variable que agrupa el 40% de los datos.                                                                      |
| $D_5$<br><b>Mediana</b> | Valor de la variable que agrupa el 50% de los datos.                                                                      |
| $D_6$                   | Valor de la variable que agrupa el 60% de los datos.                                                                      |
| $D_7$                   | Valor de la variable que agrupa el 70% de los datos.                                                                      |
| $D_8$                   | Valor de la variable que agrupa el 80% de los datos.                                                                      |
| $D_9$                   | Valor de la variable que agrupa el 90% de los datos.                                                                      |
| $D_{10}$                | Valor de la variable que agrupa el 100% de los datos.                                                                     |

### Formas de Cálculo

a) Datos No Agrupados





| Deciles           | Orden de cada Decil                                                                         |                                                                                                 |
|-------------------|---------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------|
|                   | Número de datos par                                                                         | Número de datos impar                                                                           |
| General           | $\left[ k \left( \frac{n}{10} \right) \right]^{\circ}$                                      | $\left[ k \left( \frac{n+1}{10} \right) \right]^{\circ}$                                        |
|                   | K: Número de Decil: 1, 2,..., 9                                                             |                                                                                                 |
| 1° Decil<br>$D_1$ | $\left[ 1 \left( \frac{n}{10} \right) \right]^{\circ}$                                      | $\left[ 1 \left( \frac{n+1}{10} \right) \right]^{\circ}$                                        |
| 5° Decil<br>$D_5$ | $\left[ 5 \left( \frac{n}{10} \right) \right]^{\circ} = \left( \frac{n}{2} \right)^{\circ}$ | $\left[ 5 \left( \frac{n+1}{10} \right) \right]^{\circ} = \left( \frac{n+1}{2} \right)^{\circ}$ |
| 7° Decil<br>$D_7$ | $\left[ 7 \left( \frac{n}{10} \right) \right]^{\circ}$                                      | $\left[ 7 \left( \frac{n+1}{10} \right) \right]^{\circ}$                                        |

b) Datos Agrupados

Seguiremos igual procedimiento que para el cálculo de la mediana. Considerando ahora que para ubicar el orden de  $D_i$  se debe considerar  $\frac{n}{10}$  y para ubicar el orden de  $D_5$  se debe considerar  $5 \frac{n}{10}$ .

b.1) Distribuciones de Frecuencias en Lista

| Deciles           | Formas de Cálculo                         |                                                               |
|-------------------|-------------------------------------------|---------------------------------------------------------------|
| General           | $N_{j-1} < k \frac{n}{10}$                | $N_{j-1} = k \frac{n}{10}$                                    |
|                   | $D_k = y_j$                               | $D_k = \frac{y_{j-1} + y_j}{2}$                               |
|                   | K: Número de Decil: 1, 2,..., 9           |                                                               |
| 1° Decil<br>$D_1$ | $N_{j-1} < 1 \frac{n}{10}$<br>$D_1 = y_j$ | $N_{j-1} = 1 \frac{n}{10}$<br>$D_1 = \frac{y_{j-1} + y_j}{2}$ |
| 5° Decil<br>$D_5$ | $N_{j-1} < 5 \frac{n}{10}$<br>$D_5 = y_j$ | $N_{j-1} = 5 \frac{n}{10}$<br>$D_5 = \frac{y_{j-1} + y_j}{2}$ |
| 7° Decil<br>$D_7$ | $N_{j-1} < 7 \frac{n}{10}$<br>$D_7 = y_j$ | $N_{j-1} = 7 \frac{n}{10}$<br>$D_7 = \frac{y_{j-1} + y_j}{2}$ |





## Percentiles

Por último, y en relación a los Percentiles de una distribución, también, como su nombre lo indica, son valores de la variable, que dividen al conjunto de observaciones (ordenadas de menor a mayor) en cien partes iguales. Tienen el mismo significado y la misma forma de cálculo que los cuartiles.

Así, cuando se habla del percentil 15, se quiere expresar que es el valor de la variable que deja el 15% de los datos a su izquierda y el 85% de los mismos a su derecha.

Los simbolizaremos por  $P_k$  para  $k = 1, 2, \dots, 99$  que indica el número de Percentil

### Formas de Cálculo

#### a) Datos No Agrupados

| Percentiles               | Orden de cada Percentil                                                                   |                                                                                               |
|---------------------------|-------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------|
| General                   | Número de datos par                                                                       | Número de datos impar                                                                         |
|                           | $\left[ k \left( \frac{n}{100} \right) \right]^\circ$                                     | $\left[ k \left( \frac{n+1}{100} \right) \right]^\circ$                                       |
|                           | K: Número de Percentil: 1, 2, ..., 99                                                     |                                                                                               |
| 1° Percentil<br>$P_1$     | $\left[ 1 \left( \frac{n}{100} \right) \right]^\circ$                                     | $\left[ 1 \left( \frac{n+1}{100} \right) \right]^\circ$                                       |
| 50° Percentil<br>$P_{50}$ | $\left[ 50 \left( \frac{n}{100} \right) \right]^\circ = \left( \frac{n}{2} \right)^\circ$ | $\left[ 50 \left( \frac{n+1}{100} \right) \right]^\circ = \left( \frac{n+1}{2} \right)^\circ$ |
| 70° Percentil<br>$P_{70}$ | $\left[ 70 \left( \frac{n}{100} \right) \right]^\circ$                                    | $\left[ 70 \left( \frac{n+1}{100} \right) \right]^\circ$                                      |

#### b) Datos Agrupados

Seguiremos igual procedimiento que para el cálculo de la mediana. Considerando ahora que para ubicar el orden de  $P_i$  se debe considerar  $\frac{n}{100}$  y para ubicar el orden de  $D_{50}$  se debe considerar  $50 \frac{n}{100}$ .



*b.1) Distribución de Frecuencias en Lista*

| Percentiles               | Formas de Cálculo                           |                                                                 |
|---------------------------|---------------------------------------------|-----------------------------------------------------------------|
| General                   | $N_{j-1} < k \frac{n}{100}$                 | $N_{j-1} = k \frac{n}{100}$                                     |
|                           | $P_k = y_j$                                 | $P_k = \frac{y_{j-1} + y_j}{2}$                                 |
|                           | <i>K: Número de Percentil: 1, 2,..., 99</i> |                                                                 |
| 1° Percentil<br>$P_1$     | $N_{j-1} < 1 \frac{n}{100}$<br>$P_1 = y_j$  | $N_{j-1} = 1 \frac{n}{100}$<br>$P_1 = \frac{y_{j-1} + y_j}{2}$  |
| 50° Percentil<br>$P_{50}$ | $N_{j-1} < 50 \frac{n}{100}$<br>$P_5 = y_j$ | $N_{j-1} = 50 \frac{n}{100}$<br>$P_5 = \frac{y_{j-1} + y_j}{2}$ |
| 70° Percentil<br>$P_{70}$ | $N_{j-1} < 70 \frac{n}{100}$<br>$P_7 = y_j$ | $N_{j-1} = 70 \frac{n}{100}$<br>$P_7 = \frac{y_{j-1} + y_j}{2}$ |

**3. Medidas de Asimetría**

Cuando dos distribuciones coinciden en sus medidas de posición y dispersión, no tenemos datos analíticos para ver si son distintas. Una manera de compararlas es mediante su forma.

Entonces, las medidas de asimetría son medidas de forma de una distribución.

Permiten identificar y describir la manera en que los datos tienden a reunirse, en función de su frecuencia, dentro de la distribución. Presenta las siguientes formas, en comparación con la distribución normal estandarizada, con media 0 y desviación estándar 1:

*Simetría*

Se da cuando en una distribución se reúne aproximadamente la misma cantidad de los datos a ambos lados de la media aritmética. No tiene alargamiento o sesgo. Se representa por una curva normal en forma de campana llamada campana de Gauss (matemático Alemán 1777-1855) o también conocida como de Laplace (1749-1827).

Igualmente se dice que una distribución es simétrica cuando su media aritmética, su mediana y su moda son iguales, en símbolos

$$\bar{x} = m_e = m_d$$



Una distribución simétrica significa que la clase central tiene la mayor frecuencia y que las frecuencias, arriba de la clase central de la distribución, corresponden exactamente a las frecuencias debajo de la clase central.

Si la distribución de frecuencias se muestra mediante una gráfica de barras (Histograma), o un gráfico de líneas (Polígono), una recta vertical a través del punto medio de la clase central puede dividir la gráfica en dos mitades iguales. La intersección de la recta vertical y el eje de las  $x$ , da los valores de la Media, Mediana y Moda.


### *Asimetría Negativa o a la Izquierda*

Se da cuando en una distribución la minoría de los datos está en la parte izquierda de la media. Este tipo de distribución presenta un alargamiento o sesgo hacia la izquierda, es decir, la distribución de los datos tiene a la izquierda una cola más larga que a la derecha.

También se dice que una distribución es simétrica a la izquierda o tiene sesgo negativo cuando el valor de la media aritmética es menor que la mediana y ésta es menor que la moda, en símbolos

$$\bar{x} < m_e < m_d$$

Gráficamente:



La moda es el valor que más frecuentemente se presenta, por lo tanto, está siempre bajo el punto más alto de la curva.

La media aritmética está afectada por los valores bajos de la distribución, y su posición sobre la escala de las  $x$  es estirada hacia la izquierda o hacia valores más bajos de la escala.

La mediana no es afectada tan grandemente por los valores bajos como lo es la media, y por definición se encuentra al medio de la distribución. Si bien tiene un valor menor a la moda, se ubica entre ella y la media.




### Asimetría Positiva o a la Derecha

Se da cuando en una distribución la minoría de los datos está en la parte derecha de la media aritmética. Este tipo de distribución presenta un alargamiento o sesgo hacia la derecha, es decir, la distribución de los datos tiene a la derecha una cola más larga que a la izquierda.

También se dice que una distribución es simétrica a la derecha o tiene sesgo positivo cuando el valor de la media aritmética es mayor que la mediana y ésta es mayor que la moda, en símbolos

$$\bar{x} > m_e > m_d.$$

Gráficamente:



La moda es el valor que más frecuentemente se presenta, y está siempre bajo el punto más alto de la curva.

La media, en este caso está afectada por los valores altos de la distribución, y su posición sobre la escala de las  $x$  es estirada hacia la derecha o hacia valores más altos de la escala.

La mediana, como ya dijimos, no es afectada tan grandemente por los valores altos como lo es la media, puesto que la mediana es el elemento central y divide a la curva en dos áreas iguales. Ahora es un valor más alto que la moda, pero siempre se ubica entre la moda y la media.

**Nota:** Sesgo es el grado de asimetría de una distribución, es decir, cuánto se aparta de la simetría.

### Coeficiente de asimetría de Karl Pearson

Esta medida, la medida parsoniana de asimetría, se basa en las relaciones entre la media, la mediana y la moda. Según lo visto anteriormente, para una distribución unimodal simétrica, estas medidas son iguales, pero en las distribuciones asimétricas la media se aleja de la moda según la asimetría, manteniéndose la mediana entre ambas.



Entonces, una medida de la asimetría sería la diferencia entre la media y la moda. Mientras mayor sea esa distancia, positiva o negativa, más asimétrica será la distribución.

Pero esta medida tiene dos defectos en su aplicación:

- 1- Al ser una medida dada en valor absoluto, mantiene sus unidades de medida.
- 2- La misma cantidad absoluta de asimetría tiene un diferente significado para distintas series con distintos grados de variabilidad.

Para eliminar ambos defectos se trabaja con una medida relativa de asimetría, llamado coeficiente de Pearson, que simbolizamos y calculamos de la siguiente manera:

$$k_p = \frac{3(\bar{x} - m_d)}{\hat{s}}$$

Dónde:

$\bar{x}$  : media aritmética

$m_d$  : moda

$\hat{s}$  : desviación estándar muestral corregida

Como el valor modal de muchas distribuciones solo es una aproximación, en su lugar se utiliza la mediana

$$k_p = \frac{3(\bar{x} - m_d)}{\hat{s}}$$

Como vimos anteriormente la moda por el método empírico se determina:

$$m_d = \bar{x} - 3(\bar{x} - m_e)$$

Reemplazando

$$\bar{x} - m_d = \bar{x} - [\bar{x} - 3(\bar{x} - m_e)] = 3(\bar{x} - m_e)$$

Entonces, podemos escribir:

$$k_p = \frac{3(\bar{x} - m_e)}{\hat{s}}$$

Por esta medida:  $3(\bar{x} - m_e)$ , el coeficiente de Pearson puede asumir los siguientes resultados:

Si  $k_p < 0$  la distribución será asimétrica negativa.

Si  $k_p = 0$  la distribución será simétrica.

Si  $k_p > 0$  la distribución será asimétrica positiva.



El Coeficiente de Pearson varía entre -3 y 3. Sin embargo, en raras ocasiones supera los límites de  $\pm 1$ .

*Coeficiente de Asimetría de Fisher*

$$k_3 = \frac{\mu_3}{\hat{s}^3}, \quad \text{donde} \quad \mu_3 = \frac{\sum_{i=1}^m (y_i - \bar{y})^3 n_i}{n} = \sum_{i=1}^m (y_i - \bar{y})^3 h_i$$

Pudiendo  $k$  arrojar los siguientes resultados:

Cuando  $\bar{x} = m_d = m_e$ ,  $\mu_3 = 0$  y  $k$  podrá asumir los siguientes resultados:

$k < 0$ ; indica asimetría negativa

$k = 0$ ; indica simetría

$k > 0$ ; indica asimetría positiva

#### 4. Medidas de Dispersión o De Concentración


Llamadas también medidas de variabilidad

Son útiles porque:

1. Permiten juzgar la confiabilidad de la medida de tendencia central.
2. Los datos demasiados dispersos tienen un comportamiento especial.
3. Es posible comparar la dispersión de diversas distribuciones.

Los parámetros o estadígrafos de posición no son suficientes para caracterizar totalmente una cierta distribución de frecuencias, ya que los valores incluidos en un grupo de datos en general varían significativamente en magnitud; es decir, algunos de ellos son pequeños y otros grandes, estableciéndose lo que se llama dispersión o concentración de los valores. Dos ó más conjuntos de datos pueden diferir tanto en tendencia central como en dispersión o pueden tener las mismas medidas de tendencia central, pero pueden tener grandes diferencias de dispersión.

Ejemplo:





*Las Medidas De Tendencia Central Tienen Como Objetivo El Sintetizar Los Datos En Un Valor Representativo.*

*Las Medidas De Dispersión Nos Dicen Hasta Qué Punto Estas Medidas De Tendencia Central Son Representativas Como Síntesis De La Información. Las Medidas De Dispersión Cuantifican La Separación, La Dispersión, La Variabilidad De Los Valores De La Distribución Respecto Al Valor Central.*

L

as figuras *A*, *B* y *C*, si bien son iguales en cuanto a su promedio, los datos en *C* están más concentrados alrededor del promedio que la figura *B*) y los de ésta más que los de la figura *A*), o dicho de otro modo, los datos de la figura *A*) están más dispersos que los de la figura *B*) y éstos más que los de la *C*).

Una medida de dispersión es importante por dos razones:

- 1- Indica el grado de variación entre los valores de la serie de datos recopilados, en relación con alguna medida de posición. Utilizaremos generalmente a la media aritmética.
- 2- Es utilizada como complemento de la medida de posición para caracterizar un conjunto de datos o para compararlos con respecto a otro conjunto cualquiera. Cuando la dispersión es grande, el promedio tiene muy poca significación, en cambio si la dispersión es baja, es decir los datos están muy concentrados alrededor el promedio, éste se vuelve altamente significativo, ya que en este caso la medida de posición corresponde a un valor muy representativo del conjunto.

Toda medida de dispersión es un número real y nunca puede ser menor a 0. Si es 0 todos los datos son idénticos. Va en aumento según los datos se hacen más diversos.

#### ***4.1. Recorrido***

También llamado Amplitud o Campo de Variación, es la medida más simple y bruta de dispersión.

Se define como la diferencia entre el valor máximo y el valor mínimo de los valores observados. Mide la distancia entre un punto y otro. Es una medida posicional de dispersión ya que está basada en las posiciones de ciertos elementos.

*Simbología*

*R*

*Formas De Cálculo*

*a) Series Simples o Datos No Agrupados*

$$R = x_{\text{máx}} - x_{\text{mín}} \quad R = x_n - x_1$$



$$x_i \ (i = 1, 2, \dots, n); x_1, x_2, \dots, x_n$$

$x_{m\acute{a}x}$  : *valor mximo observado*

$x_{m\acute{i}n}$  : *valor mnimo observado*

b) *Datos Agrupados*

*Distribuciones De Frecuencias En Lista o En Intervalos*

|                                         |                 |
|-----------------------------------------|-----------------|
| $R = y_{m\acute{a}x} - y_{m\acute{i}n}$ | $R = y_m - y_1$ |
|-----------------------------------------|-----------------|

$$y_i \ (i = 1, 2, \dots, m); y_1, y_2, \dots, y_m$$

$y_{m\acute{a}x}$  : *valor mximo observado*

$y_{m\acute{i}n}$  : *valor mnimo observado*

Presenta los siguientes inconvenientes:

- Se ve muy influenciado por valores no usuales de los datos. Si aparece un valor fuera de lo comn ya sea muy grande o pequeo, no es posible utilizarlo como medida de dispersin, porque su resultado est deformado por estos valores fuera de serie.
- No es una medida de dispersin de los datos intermedios con relacin al valor tpico.
- Es sensible al tamao de muestra. Tiende a cambiar, aunque no proporcionalmente, en la misma direccin en que vara el tamao de la muestra. Cuando aumenta el nmero, es posible que algn dato pueda tener mayor valor que el mximo y algn otro dato un valor que el mnimo de la muestra anterior.

A pesar de sus numerosas deficiencias, puede ser usado muy provechosamente como medida de dispersin para muchos fines:

- En situaciones en las que se desea conocer slo la extensin de la dispersin extrema en condiciones ordinarias. Si el dato mximo o mnimo no es usual, la amplitud no revela nada acerca de la distribucin ordinaria de los datos.

Ejemplo:

Los informes de mercado de acciones se expresan frecuentemente en trminos de su amplitud, cotizando precios altos y bajos de acciones durante un perodo de tiempo.

Cuando no se producen movimientos excepcionales de los precios de las acciones, la amplitud cotizada puede medir la variacin ordinaria. Pero, cuando ocurren movimientos excepcionales, la amplitud revela los efectos de condiciones trastornadoras temporales en el mercado.





- Para medir la dispersión de una serie simétrica y casi continua. En tal caso puede ser aproximada la medida, tomando el promedio de los dos valores extremos, llamado *Amplitud Media*.

Ejemplo:

Temperatura media diaria. Se promedia la máxima y la mínima, en vez de usar las veinticuatro lecturas horarias del día.

- Cuando la muestra es pequeña, especialmente cuando la misma operación de muestreo se repite a menudo y es utilizado un promedio de cada resultado sucesivo.

Ejemplo:

Control Estadístico de la Calidad

En general, se desea una medida de variabilidad que dependa de todas las observaciones y no de unas pocas. Por ello es razonable medir la variación en términos de las desviaciones con respecto a alguna medida de localización. En base a ello, podemos definir:

## 4.2. Desviación Media

### Definición

Es la media aritmética de los valores absolutos de las desviaciones entre los valores de la variable y una medida de tendencia central. Las desviaciones deben considerarse tantas veces como se presentan. Entonces, podemos identificar tres desviaciones medias:

#### 1- Desviación Media Respecto a La Media:

$$DM_{\bar{x}} = \frac{\sum_{i=1}^m |y_i - \bar{x}| n_i}{n}$$

#### 2- Desviación Media Respecto a La Mediana:

$$DM_{me} = \frac{\sum_{i=1}^m |y_i - me| n_i}{n}$$

#### 3- Desviación Media Respecto a La Moda:

$$DM_{md} = \frac{\sum_{i=1}^m |y_i - md| n_i}{n}$$

La desviación media da cuenta de la distancia promedio que existe entre los valores de la variable y la medida de tendencia central.



Generalmente para determinar las desviaciones se toma como medida de localización a la media aritmética.

Entonces la Desviación Media con respecto a la media aritmética se define como la media aritmética de los valores absolutos de las desviaciones entre los valores de la variable con respecto a la media aritmética.

De esta manera esta medida se basa en todos los elementos y permite medir la dispersión alrededor de un promedio.

### Simbología

|                  |         |
|------------------|---------|
| <i>Población</i> | $DM(X)$ |
| <i>Muestra</i>   | $DM(x)$ |

### Formas De Cálculo

#### a) Series Simples o Datos No Agrupados

$$DM(x) = M\left[ \left| x_i - \bar{x} \right| \right] = \frac{\sum_{i=1}^n |x_i - \bar{x}|}{n}$$

Se ignoran los signos positivos o negativos de las desviaciones ya que como se vio al estudiar las propiedades de la media:

$$\sum_{i=1}^n (x_i - \bar{x}) = 0 \quad \text{ó} \quad \sum_{i=1}^m (y_i - \bar{y}) n_i = 0$$

#### a) Datos Agrupados

#### Distribuciones De Frecuencias En Lista o En Intervalos

$$DM(y) = M\left[ \left| y_i - \bar{y} \right| \right] = \frac{\sum_{i=1}^m |y_i - \bar{y}| n_i}{n}$$

Donde  $y_i$  será:

- Los distintos valores que asumió la variable si se trata de una Distribución de Frecuencias en Lista
- Las marcas de clase si se trata de una Distribución de Frecuencias en Intervalos



Procedimiento:

- 1- Obtener la media aritmética
- 2- Obtener las desviaciones de cada valor de la variable o cada marca de clase, según corresponda, con respecto a la media aritmética
- 3- Obtener la suma de los valores absolutos de las desviaciones (multiplicada por  $n$  para el caso de datos agrupados).
- 4- Dividir la suma por el número de datos.

### 4.3. Varianza

#### Definición

Se define como la Media Aritmética de los cuadrados de las desviaciones con respecto a la media aritmética.

#### Simbología

|           |                     |
|-----------|---------------------|
| Población | $V(X) = \sigma_x^2$ |
| Muestra   | $V(x) = s_x^2$      |

Como ya vimos  $\frac{\sum_{i=1}^n (x_i - \bar{x})}{n} = 0$ , en series simples, y  $\frac{\sum_{i=1}^m (y_i - \bar{y}) n_i}{n} = 0$ , en datos agrupados, cualquiera sea la distribución. El que esta media valga 0, se debe a las compensaciones de las desviaciones positivas con las negativas. Esta compensación, ya fue evitada considerando el valor absoluto de las desviaciones.

La otra forma de evitarlas es tomar una potencia par para dichas desviaciones. Si tomamos la potencia 2, se transforma en la varianza, haciendo uso de esta manera de la propiedad de los mínimos cuadrados de la media:

$$\sum_{i=1}^n (x_i - \bar{x})^2 = \text{mínimo} \quad \text{ó} \quad \sum_{i=1}^m (y_i - \bar{y})^2 n_i = \text{mínimo}$$

Por lo cual, como medidas de las diferencias promedio al cuadrado en torno a la media, la varianza y la desviación estándar, deben ser menores que cualquier otra medida de diferencias promedio al cuadrado en torno a cualquier otro indicador de tendencia central.

Dado que en el cálculo precedente se elevó al cuadrado, ni la varianza, ni la desviación estándar, podrán ser nunca negativas y solo alcanzarán el valor 0 si cada observación realizada es exactamente igual.



## Formas De Cálculo

### a) Series Simples o Datos No Agrupados

$$V(x) = M\left[\left(x_i - \bar{x}\right)^2\right] = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$$

#### Ejemplo:

Sean:

$n = 10$

$x_i$  = número de hijos por familia = 2, 1, 3, 1, 2, 1, 3, 0, 2, 1

Aplicamos la fórmula de cálculo

$$V(x) = \frac{\sum_{i=1}^n x_i^2}{n} - \bar{x}^2$$

Obtenemos

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n} = \frac{16}{10} = 1,6$$

Elevamos al cuadrado cada  $x_i$  y sumamos

$$\bar{x}^2 = 4, 1, 9, 1, 4, 1, 9, 0, 4, 1 \quad y \quad \sum_{i=1}^{10} x_i^2 = 34$$

Luego reemplazamos:

$$V(x) = \frac{34}{10} - (1,6)^2 = \underline{0,84}$$

### b) Datos Agrupados

$$V(y) = M\left[\left(y_i - \bar{y}\right)^2\right] = \frac{\sum_{i=1}^m (y_i - \bar{y})^2 n_i}{n}$$

Que corresponde a la fórmula definicional, a partir de la cual, y realizando igual procedimiento que para series simples, arribamos a:

$$V(y) = \frac{\sum_{i=1}^m y_i^2 n_i}{n} - \bar{y}^2 = M(y^2) - [M(y)]^2$$



O bien, considerando las frecuencias relativas:

$$V(y) = \sum_{i=1}^m (y_i - \bar{y})^2 h_i = \sum_{i=1}^m y_i^2 h_i - \bar{y}^2$$

*Nota: En la Inferencia Estadística para el cálculo de la varianza muestral y en consecuencia, de la desviación estándar muestral, se utiliza como denominador a n-1 en vez de n. Esto se debe a que con una muestra tomada de una población grande se pretende descubrir cuánto varían los datos alrededor de la media poblacional. Sin embargo, cuando no se conoce la media de la población se estima a través de la media aritmética de la muestra y esto hace que parezca menos variable de lo que es en realidad. Al dividir por n-1 se está compensando por la variabilidad más pequeña que se observa en la muestra. Por este motivo la varianza muestral calculada con n-1 es considerada un estimador más eficiente para la varianza poblacional.*

Ejemplo:

| $y_i$ | $n_i$ | $y_i n_i$ | $y_i (y_i n_i) = y_i^2 n_i$ | $h_i$ | $y_i^2 h_i$ |
|-------|-------|-----------|-----------------------------|-------|-------------|
| 0     | 1     | 0         | 0                           | 0,10  | 0           |
| 1     | 4     | 4         | 4                           | 0,40  | 0,40        |
| 2     | 3     | 6         | 12                          | 0,30  | 1,20        |
| 3     | 2     | 6         | 18                          | 0,20  | 1,80        |
|       | 10    | 16        | 34                          | 1     | 3,40        |

#### b.1) Distribuciones De Frecuencias En Lista

Con los datos dados en Serie Simple, construimos la siguiente Tabla:

$$V(y) = \frac{\sum_{i=1}^m y_i^2 n_i}{n} - \bar{y}^2 = \frac{34}{10} - (1,6)^2 = \underline{0,84}$$

O bien

$$V(y) = \sum_{i=1}^m y_i^2 h_i - \bar{y}^2 = 3,40 - (1,6)^2 = \underline{0,84}$$

#### Propiedades

1- La Varianza es siempre una cantidad no negativa.

$$V(y) \geq 0$$



2- La Varianza de una constante es 0, cualquiera sea la constante.

$$V(k) = 0$$

Si todas las observaciones son iguales ( $k$ ), es decir iguales, la media coincide con el valor común y las desviaciones son todas nulas.

3- La Varianza del producto de una constante por una variable, es igual al producto del cuadrado de la constante por la varianza de la variable.

$$V(ky) = k^2 V(y)$$

Ejemplo:

| $y_i$ | $n_i$ |
|-------|-------|
| 0     | 1     |
| 1     | 4     |
| 2     | 3     |
| 3     | 2     |
|       | 10    |

$$V(y) = 0,84$$

Supongamos que multiplicamos a la variable por 2. Simbolizaremos por  $y'$  a la nueva variable y obtendremos la varianza.

| $y_i \times 2 = y'_i$ | $n_i$ | $y'_i n_i$ | $y'_i (y'_i n_i)$ |
|-----------------------|-------|------------|-------------------|
| 0                     | 1     | 0          | 0                 |
| 2                     | 4     | 8          | 16                |
| 4                     | 3     | 12         | 48                |
| 6                     | 2     | 12         | 72                |
|                       | 10    | 32         | 136               |

$$\bar{y}' = \frac{\sum_{i=1}^m y'_i n_i}{n} = \frac{32}{10} = 3,20$$

$$V(y') = \frac{\sum_{i=1}^m y_i'^2 n_i}{n} - \bar{y}'^2 = \frac{136}{10} - (3,20)^2 = \underline{3,36}$$

Luego:  $V(2y) = 2^2 V(Y) = 4 \times 0,84 = \underline{3,36}$



- 4- La Varianza de la suma de una variable y una constante es igual a la varianza de la variable. Si a todos los valores de la variable se le suma un número igual, la varianza no se altera.

$$V(k + y) = V(y)$$

Ejemplo:

Supongamos que, en el caso dado anteriormente, sumamos 2 a los valores originales

| $y_i + 2 = y'_i$ | $n_i$ | $y'_i n_i$ | $y'_i (y'_i n_i)$ |
|------------------|-------|------------|-------------------|
| 2                | 1     | 2          | 4                 |
| 3                | 4     | 12         | 36                |
| 4                | 3     | 12         | 48                |
| 5                | 2     | 10         | 50                |
|                  | 10    | 36         | 138               |

$$\bar{y}' = \frac{\sum_{i=1}^m y'_i n_i}{n} = \frac{36}{10} = 3,60$$

$$V(y') = \frac{\sum_{i=1}^m y_i'^2 n_i}{n} - \bar{y}'^2 = \frac{138}{10} - (3,60)^2 = 0,84$$

Esta propiedad se hace extensiva a la diferencia:

$$V(y - k) = V(y)$$

- 5- Si “x” e “y” son dos variables independientes, entonces la varianza de la suma o diferencia es igual a la suma de las varianzas.

$$V(x + y) = V(x) + V(y)$$

y

$$V(x - y) = V(x) + V(y)$$

- 6- Si “x” e “y” son dos variables dependientes, entonces la varianza de la suma es igual a la suma de las varianzas más dos veces la covarianza de x, y.

$$V(x + y) = V(x) + V(y) + 2 \text{Cov} (x, y)$$

y

$$V(x - y) = V(x) + V(y) - 2 \text{Cov} (x, y)$$



### Observaciones

- 1) La varianza, al igual que la media, es un índice muy sensible a las puntuaciones extremas.
- 2) En los casos en que no se pueda hallar la media, tampoco será posible hallar la varianza.
- 3) La varianza no viene expresada en las mismas unidades que los datos, ya que las desviaciones están elevadas al cuadrado.

### 4.4. Desviación Estándar

También llamada Desviación Típica ó Desviación Cuadrática Media.

#### Definición

Se define como el valor positivo de la raíz cuadrada de la Varianza.

#### Simbología

|           |                    |
|-----------|--------------------|
| Población | $DS(X) = \sigma_x$ |
| Muestra   | $DS(x) = s_x$      |

Esta medida ha sido definida con el fin de hacer comparable su resultado o valor con los valores de la variable, dado que, en el caso de la Varianza, por ser su valor de un orden superior a los valores de la variable, debido a que es un promedio de cuadrados, no es comparable. A los fines de reducir dicho valor a la misma dimensión que los valores de la variable, se le extrae la raíz cuadrada y se define la Desviación Estándar.

Mide, al igual que la Varianza, la dispersión de los valores de la variable respecto a su media aritmética. Es simplemente el promedio o variación esperada con respecto a la media aritmética.

Ninguna, Varianza y Desviación Estándar, tiene una interpretación intuitivamente obvia.

Cuando comparamos dos o más conjuntos de datos cuyas unidades de medición son idénticas, podemos decir que una muestra tiene un menor grado de dispersión que otra, si la primera tiene una menor Varianza, ó Desviación Estándar. Sin embargo, dudaríamos de hacer una declaración precisa acerca de un conjunto de datos cuando se da un valor específico de una u otra medida.

Por ejemplo, si hallamos la desviación estándar de  $n$  observaciones de gastos de consumo familiar de alimentos, por día, de \$ 10, no podemos decir si este valor implica un grado de variabilidad alto, moderado o bajo de gastos de consumo de alimentos. Para vencer esta dificultad es necesario utilizar la regla empírica para la interpretación de la Desviación Estándar.

Los problemas experimentales van a ser estudiados mediante las distribuciones de probabilidades, como modelos teóricos explicativos de los hechos reales. Así en el tema





Distribución Normal que veremos más adelante introduciremos la regla referida para interpretar la Desviación Estándar

### Formas de Cálculo

#### a) Series Simples o Datos No Agrupados

$$DS(x) = s_x = \sqrt{V(x)} = \sqrt{\frac{\sum_{i=1}^n x_i^2}{n} - \bar{x}^2}$$

### Propiedades

1- La desviación típica será siempre un valor positivo.

$$D(y) \geq 0$$

2- La desviación típica será siempre cero, en el caso de que las puntuaciones sean iguales.

$$D(k) = 0$$

3- Si a todos los valores de la variable se les suma un mismo número la desviación típica no varía

$$D(k + y) = D(y)$$

Esta propiedad se hace extensiva a la diferencia

$$D(y - k) = D(y)$$

Si todos los valores de la variable se multiplican por un mismo número la desviación típica queda multiplicada por dicho número.

$$D(k y) = k D(y)$$

4- Si “x” e “y” son dos variables independientes, entonces la desviación típica de la suma o diferencia es igual a la suma de las desviaciones.

$$D(x + y) = \sqrt{V(x) + V(y)}$$

$$D(x - y) = \sqrt{V(x) + V(y)}$$



### Observaciones

- 1- La desviación típica, al igual que la media, es un índice muy sensible a las puntuaciones extremas.
- 3- En los casos en que no se pueda hallar la media, tampoco será posible hallar la desviación típica.
- 4- Cuanto menor sea la desviación típica mayor será la concentración de los datos alrededor de la media.

### 4.5. Coeficiente de Variación

#### Definición

El Coeficiente de Variación es en realidad una Medida de Dispersión o de variabilidad relativa, pero de gran importancia, y de gran versatilidad, ya que su interpretación está basada en porcentajes, y nos da la relación existente entre la medida de posición y su precisión. Se suele expresar en "tanto" por ciento.

El coeficiente de variación es, al igual que la desviación estándar, una medida de dispersión o variabilidad y análogamente indica que tan dispersos o no, se encuentran los datos con respecto al promedio.

Es más precisa que la misma desviación estándar ya que está en proporción a la media, es decir señala qué tan grande es la magnitud de la desviación estándar respecto al promedio del conjunto de datos que se examina.

Por otro lado, las medidas de dispersión expresadas en valores absolutos son útiles para describir la dispersión de un solo conjunto de valores, mientras que el coeficiente de variación nos permite comparar la variabilidad de dos o más conjuntos de datos.

Si se comparan dos conjuntos de cifras, los valores absolutos son convenientes sólo si los promedios de los dos conjuntos son aproximadamente del mismo tamaño y las unidades de medida son iguales.

Por ejemplo, si nos piden comparar la dispersión de los pesos de las poblaciones de elefantes de dos circos diferentes, la desviación estándar nos dará información útil.

¿Pero, qué ocurre si lo que comparamos es la altura de unos elefantes con respecto a su peso? Tanto la media como la desviación típica se expresan en las mismas unidades que la variable. Por ejemplo, en la variable altura podemos usar como unidad de longitud el metro y en la variable peso, el kilogramo. Comparar una desviación (con respecto a la media) medida en metros con otra en kilogramos no tiene ningún sentido.

El problema no deriva sólo de que una de las medidas sea de longitud y la otra sea de masa. La misma dificultad se plantea si medimos cierta cantidad, por ejemplo, la masa de dos poblaciones, pero con distintas unidades. Este es el caso en que comparamos el peso en *toneladas* de una población de 100 elefantes con el correspondiente en *miligramos* de una población de 50 hormigas.



Este inconveniente no se resuelve tomando las mismas escalas para ambas poblaciones.

Por ejemplo, se nos puede ocurrir medir a las hormigas con las mismas unidades que los elefantes (toneladas). Lo lógico es que la dispersión de la variable *peso de las hormigas* sea prácticamente nula (¡Aunque haya algunas que sean 1.000 veces mayores que otras!)

En los dos primeros casos mencionados anteriormente, el problema viene de la *dimensionalidad* de las variables, y en el tercero de la diferencia enorme entre las medias de ambas poblaciones. El *coeficiente de variación* es lo que nos permite evitar estos problemas, pues elimina la dimensionalidad de las variables y tiene en cuenta la proporción existente entre medias y desviación típica.

En síntesis, si los promedios son diferentes, aunque las unidades sean las mismas, o bien, si los promedios son similares, pero las unidades de medida son distintas, la comparación de grados de dispersión basados en valores absolutos no se puede realizar.

En estos casos, es necesario un valor relativo, a fin de obtener una cifra independiente de las unidades empleadas, es decir, un número abstracto, que puede incluso establecerse en forma de porcentaje.

Puesto que tanto la desviación estándar como la media se miden en las unidades originales, el *CV* es una medida independiente de las unidades de medición.

Debido a la propiedad anterior el *CV* es la cantidad más adecuada para comparar la variabilidad de dos conjuntos de datos.

#### Ejemplo:

Si tengo que el peso promedio de los elefantes es de 7500 kg con una desviación estándar de 500kg y también tengo que el peso promedio de los ratones es de 30g con una desviación estándar de 5 g, podré suponer (erróneamente) que los elefantes tienen mayor desviación que los ratones, sin embargo, si calculamos el coeficiente de variación de cada muestra se tendrá que el de los elefantes es de 6,7% y el de los ratones de 16,67%, es decir, es mayor la variación entre los pesos de los ratones.

De esta manera, se define la dispersión relativa ó coeficiente de variación.

#### *Simbología*

|           |         |
|-----------|---------|
| Población | $CV(X)$ |
| Muestra   | $CV(x)$ |

#### *Formas de Cálculo*

##### *a) Series Simples o Datos No Agrupados*

$$CV(x) = \frac{DS(x)}{M(x)}$$



## b) Datos Agrupados

$$CV(y) = \frac{DS(y)}{M(y)}$$

Basta dar una rápida mirada a la definición del coeficiente de variación, para ver que las siguientes consideraciones deben ser tenidas en cuenta:

- Sólo se debe calcular para variables con todos los valores positivos. Todo índice de variabilidad es esencialmente no negativo. Las observaciones pueden ser positivas o nulas, pero su variabilidad debe ser siempre positiva. De ahí que sólo debemos trabajar con variables positivas, para la que tenemos con seguridad que la media debe ser mayor que 0.
- No es invariante ante cambios de origen. Es decir, si a los resultados de una medida le sumamos una cantidad positiva,  $b > 0$ , para tener  $Y = X + b$ , entonces  $CV(y) < CV(x)$ , ya que la desviación típica no es sensible ante cambios de origen, pero sí la media. Lo contrario ocurre si restamos ( $b < 0$ ).

$$CV(y) = \frac{DS(y)}{M(y)} = \frac{DS(x)}{M(x) + b} < \frac{DS(x)}{M(x)}$$

- Es invariante a cambios de escala. Si multiplicamos  $x$  por una constante  $a$ , para obtener  $y = ax$ , entonces

$$CV(y) = \frac{DS(y)}{M(y)} = \frac{DS(ax)}{aM(x)} < \frac{aDS(x)}{aM(x)} = CV(x)$$

*Interpretación del Coeficiente de Variación*

El Coeficiente de Variación, mide la variabilidad relativa a la Media. Expresa la proporción de variabilidad de una característica por cada unidad de la Media.

Mencionaremos algunos criterios encontrados, para interpretar los valores que alcanza este coeficiente:

1)

- Si  $CV \leq 20\%$  se dice que el promedio es representativo, o que los datos son homogéneos
- Si el CV es mayor al 20%, el promedio no es representativo de los datos, o los mismos no son homogéneos.

2)

| <i>Coeficiente de Variación</i> | <i>Apreciación</i> |
|---------------------------------|--------------------|
| 26% o más                       | Muy heterogéneo    |
| Del 16% a menos del 26%         | Heterogéneo        |
| Del 11% a menos del 16%         | Homogéneo          |
| 0% a menos del 11%              | Muy Homogéneo      |



3)

| Valor del Coeficiente de Variación (%) | Interpretación del coeficiente |             |
|----------------------------------------|--------------------------------|-------------|
|                                        | Variabilidad                   | Estabilidad |
| Igual a 0                              | Nula                           | Muy alta    |
| Mayor de 0 hasta 20                    | Baja                           | Alta        |
| Mayor de 20 hasta 60                   | Moderada                       | Moderada    |
| Mayor de 60 hasta 90                   | Alta                           | Baja        |
| Mayor de 90                            | Muy alta                       | Nula        |

4)

| Coeficiente de Variación    | Apreciación                                      |
|-----------------------------|--------------------------------------------------|
| $\leq 10\%$                 | Poca variabilidad                                |
| $>10 \text{ y } \leq 33\%$  | Variabilidad Aceptable                           |
| $>33 \text{ y } \leq 50 \%$ | Mucha variabilidad pero tolerable                |
| $>50 \%$                    | Variabilidad excesiva y pérdida de su naturaleza |

Es importante destacar lo mencionado anteriormente, en relación a que el *coeficiente de variación* sirve para comparar las variabilidades de dos conjuntos de valores (muestras o poblaciones). Si deseamos comparar a dos *individuos* de cada uno de esos conjuntos, deberá emplearse el *Puntaje típico o Puntaje estándar*, es decir *valores tipificados*. Por ello, es necesario introducir una nueva variable llamada Variable Desvío Estandarizada o Tipificada que se define como el cociente de un valor aislado de la variable ( $y_i$ ) menos su media ( $\bar{y}$ ), dividido por su desviación estándar ( $DS(y)$ ).

Simbólicamente:

$$z_i = \frac{y_i - \bar{y}}{DS(y)}$$

Entonces tendremos las siguientes variables:

|                     |                                     | Media                  |
|---------------------|-------------------------------------|------------------------|
| Variable Natural    | $y_i$                               | $M(y) = \bar{y}$       |
| Variable Desvío     | $y_i - \bar{y}$                     | $M(y_i - \bar{y}) = 0$ |
| Variable Tipificada | $z_i = \frac{y_i - \bar{y}}{DS(y)}$ | 0                      |

Nos interesa la posibilidad que existe de llevar todas las distribuciones de distintas variables a una única escala de valores relativos, que por ser tales pierden ya sus respectivas unidades de medida y pasan a ser valores abstractos, y como consecuencia, podrán ser analizadas con una única distribución de probabilidad, como modelo teórico explicativo, que es la conocida Distribución Normal Estandarizada, que veremos más adelante.



### 5. Medidas De Apuntamiento o Puntigudez

Según ya mencionáramos, estas medidas miden el grado de variación, o la velocidad con que sube o baja la curva de izquierda a derecha.

El concepto de curtosis o apuntamiento de una distribución surge al comparar la forma de dicha distribución con la forma de la distribución normal. De esta forma, clasificaremos las distribuciones según sean más o menos apuntadas que la distribución normal.

Dicha variación, es medida a través del coeficiente de curtosis de Fisher, que analiza el grado de concentración que presentan los valores alrededor de la zona central de la distribución. Basándose en el dato de que en una distribución normal se verifica que:


$$\frac{\mu_4}{s^4} = 3$$

$$k_4 = \frac{\mu_4}{s^4} - 3, \text{ donde } \mu_4 = \frac{\sum_{i=1}^m (y_i - \bar{y})^4 n_i}{n} = \sum_{i=1}^m (y_i - \bar{y})^4 h_i$$

A partir de los resultados que pueden obtenerse, se definen tres tipos de distribuciones según su grado de curtosis:

- Mesocúrtica:** Si el resultado del coeficiente de curtosis es igual a 0, lo que indica que presenta un grado de concentración medio alrededor de los valores centrales de la variable;
- Leptocúrtica:** Si el resultado del coeficiente de curtosis es mayor que 0, lo que indica que presenta un elevado grado de concentración alrededor de los valores centrales de la variable;
- Platicúrtica:** Si el resultado del coeficiente de curtosis es menor que 0, lo que indica que presenta un reducido grado de concentración alrededor de los valores centrales de la variable.

Gráficamente:





## CAPITULO N.º 3 : Introducción al Análisis de Regresión

---

### Contenidos

#### 1-Introducción

#### 2- Análisis de Correlación

2.1 Correlación entre dos variables: Diagrama de Dispersión

2.2 Correlación entre dos variables: Covarianza

2.3 Correlación entre dos variables: Coeficiente de correlación lineal

#### 3- Análisis de regresión

3.1 Regresión entre dos variables: Modelo lineal simple

3.2 Regresión entre dos variables: Varianza y Desviación estándar de la regresión

### 1- INTRODUCCIÓN

En el Análisis estadístico de datos aplicado en la Investigación Científica es habitual recopilar valores de dos (o más) variables cuantitativas en los elementos o casos de una población bajo estudio; en particular, el estudio de “asociación entre dos variables” se realiza cuando interesa:

- \* Describir el tipo de correlación que pueden presentar los valores observados de las dos variables
- \* Predecir o estimar el valor de una variable que se considera dependiente o explicada
- \* Cuantificar el efecto de una variable considerada explicativa o independiente sobre la variable explicada o dependiente

En esta Unidad se exponen ciertas técnicas estadísticas de Correlación y de Regresión que se emplean para iniciar el mencionado estudio.

### 2- Análisis de Correlación

#### 2.1. Correlación entre dos variables: Diagrama de Dispersión

Con el fin de describir el comportamiento conjunto de los valores observados de dos variables cuantitativas se elabora un diagrama de dispersión, esto permite visualizar algún patrón o tendencia que indique la posible naturaleza de la asociación.


El diagrama utiliza el sistema de coordenadas cartesianas para asentar “n” pares ordenados de valores recopilados desde cierta cantidad “n” de elementos o casos de una población ya que en los ejes se diseña una escala que corresponda a cada variable, por este motivo se observa una colección o nube de puntos una vez confeccionado.

De acuerdo con la manera en que están dispuestos los pares ordenados (forma de la nube de puntos) en un diagrama se pueden interpretar varios tipos de asociación: una correlación directa, una correlación inversa, una correlación lineal o no lineal (exponencial, forma de U) o una correlación nula.




Trabajamos los conceptos con un ejemplo:

En cierta cantidad de localidades se recopilaron datos de las variables índice de tabaquismo e índice de mortalidad por cáncer de pulmón, por la forma que se observa de la “nube de puntos” en el diagrama elaborado se interpreta que existiría en la población de localidades una correlación lineal directa entre estas variables. En este tipo de correlación la colección de puntos presenta una tendencia creciente o positiva implicando que, en general, a “mayor o superior” valor de una variable se observa “mayor o superior” valor de la otra, a “menor o inferior” valor de una variable se observa valor “menor o inferior” de la otra y a “intermedio” valor de una variable se observa valor “intermedio” de la otra.



Analizamos otra situación....

En cierta cantidad de empresas que producen distintos bienes se recopilaron datos de las variables Razón costo laboral/costo total y Personal empleado, por la forma que se observa de la “nube de puntos” en el diagrama elaborado se interpreta que no existiría en la población de empresas, correlación entre estas variables (correlación nula). En este caso la colección de puntos está muy dispersa no presentando una tendencia visible neta (no es creciente, no es decreciente, tampoco lineal ni exponencial); por ejemplo, a “menor o inferior” valor de una variable se observa valor “menor o inferior”, “intermedio” y “mayor o superior” de la otra.







## 2.2. Correlación entre dos variables: Covarianza

La Covarianza es una medida estadística descriptiva de la variación conjunta o indicador del tipo de correlación de los valores de dos variables, su resultado puede ser un número positivo, negativo o cero.

- ✓ Si se calcula un valor de covarianza igual a cero se concluye que no habría correlación lineal entre las variables en la población bajo estudio,
- ✓ Si se calcula un valor positivo de covarianza se concluye que habría correlación lineal directa entre las variables en la población,
- ✓ Si se calcula un valor negativo de covarianza se concluye que habría correlación lineal inversa entre las variables en la población.

Sin embargo, un resultado de covarianza distinto de cero no es indicador del “grado de correlación o variación conjunta” entre los valores de las variables en la población de elementos o casos (el valor de la covarianza no permite concluir si la correlación es “muy baja”, “baja”, “regular”, “buena” o “muy buena”)

Trabajamos con un ejemplo para interpretar los conceptos ...

De cierta cantidad de elementos N comprendidos en una población se recopilamos ( $n = 8$ ) datos de las variables X e Y; es decir, se disponen de una colección de 8 pares ordenados para calcular la Covarianza (Cov)

$$Cov(x, y) = M(x \cdot y) - M(x) \cdot M(y) = \overline{x \cdot y} - \bar{x} \cdot \bar{y} = \frac{\sum x \cdot y}{n} - \frac{\sum x}{n} \cdot \frac{\sum y}{n}$$

| x  | y  | x · y |
|----|----|-------|
| 7  | 11 | 77    |
| 4  | 9  | 36    |
| 12 | 15 | 180   |
| 5  | 11 | 55    |
| 10 | 12 | 120   |
| 15 | 16 | 240   |
| 2  | 8  | 16    |
| 11 | 14 | 154   |
| 66 | 96 | 878   |

$$Cov(x, y) = \frac{878}{8} - \frac{66}{8} \cdot \frac{96}{8} = 109,75 - 8,25 \cdot 12 = 10,75$$

El valor de la covarianza es positivo, se interpreta que se presentaría correlación lineal directa entre las variables X e Y en la población. Pero el valor obtenido de la covarianza no permite concluir si la correlación es “muy baja”, “baja”, “regular”, “buena” o “muy buena”



### 2.3. Correlación entre dos variables: Coeficiente de correlación lineal

El Coeficiente de correlación lineal o de Pearson es una medida estadística descriptiva del grado de variación conjunta o indicador de la intensidad que presenta la correlación entre los valores de dos variables; su resultado puede ser un número positivo, negativo o cero, pero comprendido entre -1 y 1.

- ✓ Si se calcula un valor del coeficiente igual a cero se interpreta que no habría correlación lineal entre las variables en la población.
- ✓ Si se calcula un valor del coeficiente igual a 1 se interpreta que habría correlación lineal directa perfecta entre las variables en la población.
- ✓ Si se calcula un valor del coeficiente igual a -1 se interpreta que habría correlación lineal “inversa perfecta” entre las variables en la población.

El siguiente cuadro expone la interpretación/descripción cualitativa sobre el grado o intensidad de la correlación lineal de acuerdo con rangos de referencia del coeficiente:

| Valor del Coeficiente | Interpretación/descripción cualitativa        |
|-----------------------|-----------------------------------------------|
| Igual a -1            | Correlación inversa perfecta                  |
| Entre -0,9 y -0,99    | Correlación inversa muy buena o muy alta      |
| Entre -0,7 y -0,89    | Correlación inversa buena o alta              |
| Entre -0,4 y -0,69    | Correlación inversa regular o moderada        |
| Entre -0,2 y -0,39    | Correlación inversa mala o baja               |
| Entre -0,01 y -0,19   | Correlación inversa muy mala o muy baja       |
| Igual a 0             | No existe correlación (ni directa ni inversa) |
| Entre 0,01 y 0,19     | Correlación directa muy mala o muy baja       |
| Entre 0,2 y 0,39      | Correlación directa mala o baja               |
| Entre 0,4 y 0,69      | Correlación directa regular o moderada        |
| Entre 0,7 y 0,89      | Correlación directa buena o alta              |
| Entre 0,9 y 0,99      | Correlación directa muy buena o muy alta      |
| Igual a 1             | Correlación directa perfecta                  |

Cuando se disponen de valores observados de dos variables (X e Y) recopilados en cierta cantidad de elementos comprendidos en una población, para calcular el coeficiente de correlación lineal (r) en primera instancia se utiliza la expresión:

$$r = \frac{n \cdot \sum x \cdot y - \sum x \cdot \sum y}{\sqrt{n \cdot \sum x^2 - (\sum x)^2} \cdot \sqrt{n \cdot \sum y^2 - (\sum y)^2}}$$

Tomando el mismo ejemplo que se utilizó para calcular la covarianza, vamos a calcular el coeficiente de correlación lineal.

Para ello armaremos una tabla para cálculos intermedios que nos permitirán definir el valor final de “r”



Con la colección de pares ordenados recopilados que se utilizó para determinar el resultado de la Covarianza se calcula a continuación el Coeficiente

| $x$ | $y$ | $x \cdot y$ | $x^2$ | $y^2$ | $(x - \bar{x})^2$ | $(y - \bar{y})^2$ |
|-----|-----|-------------|-------|-------|-------------------|-------------------|
| 7   | 11  | 77          | 49    | 121   | 1,562             | 1                 |
| 4   | 9   | 36          | 16    | 81    | 18,062            | 9                 |
| 12  | 15  | 180         | 144   | 225   | 14,062            | 9                 |
| 5   | 11  | 55          | 25    | 121   | 10,562            | 1                 |
| 10  | 12  | 120         | 100   | 144   | 3,062             | 0                 |
| 15  | 16  | 240         | 225   | 256   | 45,562            | 16                |
| 2   | 8   | 16          | 4     | 64    | 39,062            | 16                |
| 11  | 14  | 154         | 121   | 196   | 7,562             | 4                 |
| 66  | 96  | 878         | 684   | 1208  | 139,5             | 56                |

$$r = \frac{8 \cdot 878 - 66 \cdot 96}{\sqrt{8 \cdot 684 - 66^2} \sqrt{8 \cdot 1208 - 96^2}} = 0,973$$

Podemos también calcular de otra forma el valor del coeficiente de correlación lineal, utilizando para ello, la Covarianza dividida por el producto de la desviación estándar de cada variable.

$$r = \frac{Cov(x, y)}{\sqrt{s_x^2} \cdot \sqrt{s_y^2}} = \frac{10,75}{\sqrt{\frac{139,5}{8}} \cdot \sqrt{\frac{56}{8}}} = 0,973$$

Recordando que la desviación es la raíz de la varianza y calculando la media.

$$\sqrt{s_x^2} = \sqrt{\frac{\sum (x - \bar{x})^2}{n}} \quad ; \quad \bar{x} = \frac{\sum x}{n}$$

$$\sqrt{s_y^2} = \sqrt{\frac{\sum (y - \bar{y})^2}{n}} \quad ; \quad \bar{y} = \frac{\sum y}{n}$$

Para este caso, se estima que entre las variables X e Y habría una correlación lineal directa Muy buena pero no perfecta en la población (el resultado es positivo y con un valor comprendido entre 0,90 y 0,99)



### 3- Análisis de Regresión

#### 3.1 Regresión entre dos variables: Modelo lineal simple

Además de la comprobación de correlación, en determinados casos del estudio de asociación entre dos variables también se aplica el “análisis de regresión”, cuando se reconoce una relación causal tal que los valores de una variable “Y” pueden ser explicados u ocasionados por los valores de una variable “X” en la población bajo estudio, en símbolos

$$y=f(x)$$

Plantear un modelo de regresión adecuado significa seleccionar uno, de entre los modelos que la teoría estadística de asociación entre variables ofrece, con el fin de representar y describir estadísticamente la relación entre dos (o más) variables cuantitativas; en consecuencia, con el modelo seleccionado será posible:

- ✓ Predecir o estimar el valor medio de una variable Y dependiente o explicada en base a un valor de al menos una variable X independiente o explicativa
- ✓ Cuantificar el efecto de una variable X explicativa o independiente sobre la variable Y explicada o dependiente; esto es, estimar una tasa de cambio promedio de los valores de la variable dependiente Y que se genera por un cambio “unitario” en los valores de una variable X independiente.

Uno de los modelos de regresión que puede emplearse en primer instancia es el “Lineal simple”, en este caso el profesional o investigador asume que los valores de la variable dependiente se “forman o se pueden describir” en la población con una ecuación lineal o ecuación de la recta y en función de valores de una variable independiente; esto implica suponer que un cambio de valor de la variable independiente explicará un cambio de valor de la variable dependiente a una tasa constante (estimar un efecto fijo de una variable en la otra).

Ecuación de regresión o recta de regresión entre dos variables presentes en los elementos o casos de una población:

$$Y = \alpha + \beta.X + \varepsilon$$

Y: variable dependiente o explicada

X: variable independiente o explicativa

$\alpha$ : parámetro de la regresión constante, ordenada al origen de una recta

$\beta$ : parámetro de la regresión, pendiente de una recta

$\varepsilon$ : efecto residual o error

Cuando se disponen de observaciones de las dos variables recopiladas de cierta cantidad “n” de elementos o casos de una población (colección de “n” pares ordenados), corresponde realizar estimaciones de los parámetros de la regresión (o simplemente estimar la ecuación o recta de regresión) y comenzar a aplicar el análisis.



Estimación de los parámetros de la ecuación de regresión lineal o estimación de la “recta de regresión”.

Estimador mínimo cuadrático insesgado del parámetro “pendiente de la recta”:  $\beta=b$

$$b = \frac{n \cdot \sum x \cdot y - \sum x \cdot \sum y}{n \cdot \sum x^2 - (\sum x)^2}$$

Estimador “mínimo cuadrático” insesgado del parámetro “ordenada al origen”:  $\alpha=a$

$$a = \frac{\sum y}{n} - b \frac{\sum x}{n} = \bar{y} - b\bar{x}$$

De cierta cantidad de parcelas de tierra comprendidos en una población N, se recopilieron (n=8) datos de las variables X: cantidad de fertilizante aplicado (kilos) e Y: producción de cierto cereal (toneladas); es decir, se disponen de una colección de 8 pares ordenados para estimar los parámetros de la recta de regresión

| x  | y  | x · y | x <sup>2</sup> |
|----|----|-------|----------------|
| 7  | 11 | 77    | 49             |
| 4  | 9  | 36    | 16             |
| 12 | 15 | 180   | 144            |
| 5  | 11 | 55    | 25             |
| 10 | 12 | 120   | 100            |
| 15 | 16 | 240   | 225            |
| 2  | 8  | 16    | 4              |
| 11 | 14 | 154   | 121            |
| 66 | 96 | 878   | 684            |

$$b = \frac{n \cdot \sum x \cdot y - \sum x \cdot \sum y}{n \cdot \sum x^2 - (\sum x)^2} = \frac{8 \cdot 878 - 66 \cdot 96}{8 \cdot 684 - 66^2} = 0,62$$

$$a = \frac{\sum y}{n} - b \frac{\sum x}{n} = \bar{y} - b\bar{x} = \frac{96}{8} - 0,62 \frac{66}{8} = 12 - 0,62 \cdot 8,25 = 6,89$$

Estimación de la ecuación lineal de regresión o “recta estimada” de regresión:

$$\hat{y} = 6,89 + 0,62 \cdot x$$

En principio, con esta expresión es posible explicar de manera aproximada cómo se “forman” los valores de la variable dependiente o explicada (producción o cosecha obtenida de cierto cereal, toneladas) en función de valores de la variable independiente o explicativa (fertilizante aplicado, kilos) en la población de parcelas de tierra.




- ✓ Interpretación de la estimación de la pendiente de la recta: “la producción o cosecha del cereal puede incrementarse, aproximadamente, a un promedio de 0,62 tonelada ante un incremento de un kilo en la aplicación de fertilizante en la población de ciertas parcelas de tierra”.
- ✓ Interpretación de la estimación de la ordenada al origen de la recta: “la producción o cosecha del cereal sería de aproximadamente 6,89 toneladas en el caso que no se aplique fertilizante en parcelas de tierra de cierto tipo”.

Al ser estimaciones realizadas con estimadores derivados del “método de mínimos cuadrados”, la suma de los cuadrados de las separaciones entre los valores observados y los estimados con la ecuación lineal estimada es la menor posible; es decir  $\sum(y - \hat{y})^2$  es mínimo (a esta suma de cuadrados se la denomina “No explicada o de los errores”).

En consecuencia, la recta que se obtiene a partir de la ecuación lineal estimada es la que mejor “ajusta o representa” a la nube de puntos (del diagrama de dispersión) o colección de pares ordenados que comprenden a los valores observados de la variable dependiente asociados a los valores de la variable independiente

| $x$ | $y$ | $\hat{y} = 6,89 + 0,62.x$ |
|-----|-----|---------------------------|
| 2   | 8   | 8,13                      |
| 4   | 9   | 9,37                      |
| 5   | 11  | 9,99                      |
| 7   | 11  | 11,23                     |
| 10  | 12  | 13,09                     |
| 11  | 14  | 13,71                     |
| 12  | 15  | 14,33                     |
| 15  | 16  | 16,19                     |

Es posible elaborar el diagrama de dispersión con los valores observados de las dos variables, en el eje de ordenadas corresponde asentar la escala correspondiente a la variable dependiente o explicada “y”; además, en el análisis de regresión lineal simple se agregan los valores estimados o predichos con la recta de regresión estimada que se visualizan sobre una recta





### 3.2. Regresión entre dos variables: Varianza y Desviación estándar de la regresión

Generalmente, la estimación de la recta de regresión está acompañada con el resultado de la Desviación estándar de la regresión ( $s_{yx}$ ) que es una medida descriptiva de la dispersión o separación de las observaciones con respecto a las estimaciones de la variable dependiente o explicada, también se interpreta como un indicador de la diseminación alrededor de la recta de regresión (que contiene a los valores estimados) de los valores observados de la variable dependiente.

Al ser una desviación estándar se calcula su resultado con la raíz cuadrada positiva de la varianza de la regresión  $s_{yx}^2$ :

$$s_{yx} = \sqrt{s_{yx}^2} = \sqrt{\frac{\sum (y - \hat{y})^2}{n}}$$

| x  | y  | $\hat{y} = 6,89 + 0,62 \cdot x$ | $y - \hat{y}$ | $(y - \hat{y})^2$ |
|----|----|---------------------------------|---------------|-------------------|
| 2  | 8  | 8,13                            | -0,13         | 0,0169            |
| 4  | 9  | 9,37                            | -0,37         | 0,1369            |
| 5  | 11 | 9,99                            | 1,01          | 1,0201            |
| 7  | 11 | 11,23                           | -0,23         | 0,0529            |
| 10 | 12 | 13,09                           | -1,09         | 1,1881            |
| 11 | 14 | 13,71                           | 0,29          | 0,0841            |
| 12 | 15 | 14,33                           | 0,67          | 0,4489            |
| 15 | 16 | 16,19                           | -0,19         | 0,0361            |
|    |    |                                 |               | 2,984             |

$$s_{yx} = \sqrt{\frac{2,984}{8}} = 0,6$$

Se interpretaría que “en promedio, los valores observados de la producción del cereal se separan de sus valores estimados para las correspondientes aplicaciones de fertilizantes en 0,6 tonelada”; por lo tanto, la dispersión “promedio” de los valores observados alrededor de la recta de ajuste estimada es 0,6 (algunos valores de la producción del cereal o cosecha se separan del correspondiente estimado en una cantidad mayor a 0,6 tonelada; otros valores de la producción o cosecha del cereal se separan del correspondiente estimado en una cantidad menor a 0,6 tonelada).

Los diagramas de dispersión son ideales cuando se tienen datos numéricos emparejados y se desea ver si una variable afecta a la otra. Sin embargo, recuerde que la correlación no es causal y otra variable inadvertida puede estar influyendo en los resultados.